



机器学习

实验一：决策树分类算法的实现与应用

2026年春

目录

CONTENTS

1

实验目的

2

实验环境准备

3

scikit-learn 示例

4

知识点回顾

5

实验任务

6

实验提交

一、实验目的

- 熟悉 Python 机器学习实验的基本环境与常用工具
- 掌握基于 scikit-learn 实现分类建模的完整流程
- 理解决策树 ID3 算法的核心思想与构建原理
- 能够在指定数据集上独立完成决策树分类实验，并对实验结果进行对比、分析与总结

二、实验环境准备

➤ 核心编程语言：Python

为什么选择 Python?



PYTHON

CORE LANGUAGE



语法简洁

代码结构清晰，可读性极高，易于学习和调试，让开发者更专注于算法逻辑本身。



生态丰富

拥有NumPy、Pandas、PyTorch等大量成熟的科学计算和机器学习库，开箱即用。



社区活跃

全球拥有庞大的开发者社区，遇到技术难题时，能快速在StackOverflow等平台找到解决方案。

二、实验环境准备

➤ 必备工具库：四大核心库



NumPy

数组、数值计算

提供高效的数组和矩阵运算能力，底层由C语言实现，是Python科学计算生态的基石。



Pandas

数据读取、预处理

专为表格数据设计的利器，支持数据的快速读取、清洗、筛选、转换及缺失值处理。



Matplotlib

绘图、结果可视化

Python最常用的绘图库，支持绘制折线图、柱状图、散点图等，直观展示数据分布。



scikit-learn

建模、调参与评估

提供了完善的监督/无监督学习算法，封装了模型训练、调参、预测、评估等全流程功能。


二、实验环境准备

➤ 环境搭建工具：Anaconda

什么是 Anaconda?

一站式数据科学平台

Anaconda 是一个免费、开源的 Python 发行版，专为数据科学和机器学习 workflow 设计。它解决了库依赖和环境配置难题，让数据科学家能更专注于分析本身。



开箱即用

一键安装 Python 及数百个常用科学计算库（如 NumPy, Pandas）无需逐个下载配置。



环境隔离

利用 Conda 创建独立虚拟环境，完美解决不同项目间的 Python 版本与库依赖冲突问题。



全平台兼容

完美支持 Windows、macOS 和 Linux 三大主流操作系统，确保团队协作环境的一致性。



极简包管理

提供图形界面 (Anaconda Navigator) 与强大的命令行工具，轻松实现包的安装、更新与删除。

官方下载地址：<https://www.anaconda.com/download>

二、实验环境准备

➤ 代码运行方式: Jupyter Notebook

—— 基于网页的交互式编程环境



代码分段运行

支持逐行或逐块执行代码，便于调试与观察中间变量




混合文档支持

可插入富文本、LaTeX公式与可视化图表



运行即时反馈

代码运行结果即刻呈现，所见即所得的分析体验



直观、灵活、所见即所得的数据分析工作台


三、scikit-learn 示例

➤ 乳腺癌预测：一个完整的二分类示例

Breast Cancer Wisconsin (Diagnostic) 数据集（常被称为 WDBC）是医学图像分析和分类任务中，最经典、最常用的基准数据集之一。其核心任务是根据乳腺肿块的细针穿刺（FNA）图像特征，判断肿瘤是良性（Benign）还是恶性（Malignant）。

- 数据文件：wdbc.csv
- **样本数量：569个 样本**（良性：357个，恶性212个）
- 特征数量：每个样本有 30 个实数值特征
- **任务类型：二分类问题**


配套文件：lab1_sklearn_example.ipynb



三、scikit-learn 示例

➤ 乳腺癌预测：一个完整的二分类示例

完整的二分类任务流程： 读取数据 → 数据检查 → 特征与标签构造 → 训练/验证/测试集划分 → 模型训练与调参 → 测试集评估 → 可视化 (详见示例代码 [lab1_sklearn_example.ipynb](#))



配套文件: [lab1_sklearn_example.ipynb](#)

三、scikit-learn 示例

➤ 乳腺癌预测：一个完整的二分类示例

1. 数据集划分

① 留出法 (Hold-out Method)

- 训练集：用于训练模型
- 验证集：用于比较不同参数，选择较优模型
- 测试集：用于最终评估，通常只使用一次



测试集不参与调参

先在验证集上比较模型，确定参数后，再在测试集上做最终评估

训练集

训练模型

验证集

比较参数

测试集

最终评估

一次划分，三部分各司其职

三、scikit-learn 示例

➤ 乳腺癌预测：一个完整的二分类示例

1. 数据集划分

② K折交叉验证 (K-Fold Cross-Validation)

通常先留出测试集，再在训练数据内部进行 K 折交叉验证，用于更稳健地比较参数与估计模型性能。

5折交叉验证流程说明：

- ① **划分数据：**先留出测试集，再将训练数据随机均匀分成 5 个折。
- ② **迭代训练验证：**共进行 5 轮；每轮用 4 个折训练，1 个折验证。
- ③ **计算平均验证性能：**取 5 轮结果的平均值，作为该参数配置下的性能估计。
- ④ **最终评估：**选出较优参数后，用完整训练集重训，并在测试集上评估。

K=5 时，每一折都会轮流作为验证集

轮次	第1折	第2折	第3折	第4折	第5折
第1轮	验证	训练	训练	训练	训练
第2轮	训练	验证	训练	训练	训练
第3轮	训练	训练	验证	训练	训练
第4轮	训练	训练	训练	验证	训练
第5轮	训练	训练	训练	训练	验证

三、scikit-learn 示例

➤ 乳腺癌预测：一个完整的二分类示例

2. 模型评估

二分类任务中各评估指标的计算基础都来自于对正负样本的分类结果，用**混淆矩阵**表示为：

	预测为正	预测为负
真实为正	TP（真正例）	FN（假负例， 漏判 ）
真实为负	FP（假正例， 误判 ）	TN（真负例）

评估指标	公式	含义
准确率 (Accuracy)	$(TP+TN)/(TP+TN+FP+FN)$	模型正确预测的比例
精确率 (Precision)	$TP/(TP+FP)$	预测为正的样本中，真正是正样本的比例 (准不准)
召回率 (Recall)	$TP/(TP+FN)$	真实为正的样本中，被模型正确识别的比例 (全不全)
F1-score	$2 \times Precision \times Recall / (Precision + Recall)$	精确率和召回率的调和平均数， 当样本不平衡时，它比准确率更能反映模型的真实性能

三、scikit-learn 示例


➤ 乳腺癌预测：一个完整的二分类示例

3. 参数调优

状态	定义	训练集表现	测试集表现
欠拟合	没学到位： 模型太简单，连训练数据的基本规律都没掌握	✗差 (误差大)	✗差 (误差大)
适度拟合	恰到好处： 模型复杂度适中，抓住了数据的本质规律	✓好 (误差低)	✓好 (误差低)
过拟合	死记硬背： 模型太复杂，把噪声和特例也当成了规律	✓极好 (误差极低)	✗差 (误差大)

本例重点关注以下参数：

- **criterion**：划分准则，常用基尼系数 (gini) 或信息熵 (entropy)
- **max_depth**：树的最大深度，用来控制模型复杂度
- **min_samples_split**：一个节点继续分裂所需的最小样本数
- **min_samples_leaf**：叶子节点中包含的最少样本数





四、知识点回顾

❖ ID3 算法

一个超小贷款例子

样本	有房	有工作	是否批准
1	有	有	批准
2	有	无	批准
3	无	有	批准
4	无	无	拒绝
5	无	无	拒绝
6	有	无	批准

➤ 思考：先按哪个问题分，能让样本更“纯”？



结论：优先选择“有房”，因为它让节点更“纯”。

• ID3 的目标：每一步都选当前能让分完以后“每个子集更纯，类别更集中”的特征。

四、知识点回顾

❖ ID3 算法：用“混乱度”判断哪个问题更好

概念先记三句话

1 熵 (Entropy)

- 表示当前整体有多“乱”；
- 一半批准、一半拒绝时最乱；如果全是同一类，熵为 0。

2 条件熵

- 先按某个特征分组，再看每个子集还剩多少“乱”；
- 子集越纯，条件熵越小。

3 信息增益 (Gain)

- 信息增益 = 分组前的混乱 - 分组后的混乱；
- 信息增益越大，说明这个问题分得越好。

公式只记住这三个

熵：
$$H(D) = - \sum_{k=1}^K p_k \log_2 p_k$$

条件熵：
$$H(D | A) = \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} H(D_v)$$

信息增益：
$$\text{Gain}(D, A) = H(D) - H(D | A)$$

回到上一页的小例子

如果按“有房”分组后两边更纯，那么“有房”的条件熵更小。条件熵更小，就表示 $\text{Gain}(\text{有房})$ 更大，所以第一层先选“有房”。

ID3 的规则就是：每一步都选信息增益最大的特征。

四、知识点回顾

❖ ID3 算法：核心函数与功能

函数	功能说明
calc_entropy	计算当前数据集的熵，用于衡量样本类别的混乱程度
calc_info_gain	计算某个特征的信息增益，用于选择当前最优划分特征
majority_class	返回当前数据集中的多数类，常用于叶子节点或 fallback 处理
build_tree	递归构建多叉决策树；建议在内部节点保存 majority，用于预测时的 fallback
predict_one	对单个样本进行预测；若样本取值未在当前节点出现过，则返回tree["majority"]
predict	对数据集进行批量预测，通常内部会逐行调用 predict_one

五、实验任务

任务背景： 银行贷款审批通常依据历史客户的相关特征建立**分类模型**，对未来申请人的贷款风险进行判断。若申请人符合贷款条件，则予以批准；否则不予批准。

银行贷款审批数据集	
训练集	800
测试集	200
样本属性	9
分类类别	2



五、实验任务

nameid	profession	education	house_loan	car_loan	married	child	revenue	approve
1	5	1	0	0	1	1	8204	1
2	3	1	1	1	0	0	5674	0
3	2	3	1	0	1	0	10634	1

字段说明

nameid	样本编号，不参与建模
profession	职业类别
education	教育程度
house_loan	是否有房贷（1=有，0=无）
car_loan	是否有车贷（1=有，0=无）
married	是否结婚（1=是，0=否）
child	是否有小孩（1=有，0=无）
revenue	月收入（数值型）
approve	标签（1=批准贷款，0=不批准贷款）

五、实验任务

❖ 请在框架代码 `ML_Lab1_Bank_Student_Framework.ipynb` 的基础上，完成 **任务1 & 任务2**

➤ **任务1：使用 scikit-learn 实现决策树分类**

① 数据读取与预处理

- ✓ 读取 `bank_train.csv` 和 `bank_test.csv` 数据集
- ✓ 分离数据集的特征 (X) 与目标变量 (y)

② 模型训练与参数调优

- ✓ 至少设置并比较 **3 组不同参数**
- ✓ 通过**验证集**或**交叉验证**选择较优参数

③ 模型评估

在测试集上给出模型评估结果，包括：**评价指标、混淆矩阵以及决策树可视化结果**

五、实验任务

❖ 请在框架代码 `ML_Lab1_Bank_Student_Framework.ipynb` 的基础上，完成**任务1 & 任务2**

➤ **任务2：手写ID3决策树算法**

- ① 对 **revenue** 特征先进行离散化处理
- ② 采用**离散特征**，手写**多叉树**版本ID3 算法
- ③ 预测时若遇到未出现过的特征取值，需要进行合理的 **fallback** 处理
- ④ 计算模型的 Precision、Recall 和 F1-score，并与 **scikit-learn** 决策树的结果进行对比分析

➤ **选做题：预剪枝 (Pre-Pruning) (10%加分，总分不超过100)**

- ① 为手写 ID3 决策树加入**预剪枝**机制（例如限制 `max_depth`）
- ② 比较不同树深度下 **Precision、Recall、F1-score** 等指标的变化情况，并分析其原因

六、实验提交

- 作业提交平台: grader.hitsz.edu.cn/courses
- 截止时间:
 - 第一组: 5 月 20 日晚 23:59
 - 第二组: 5 月 24 日晚 23:59
 - 补交按得分80%计算分数
- 压缩包命名: 学号_姓名_机器学习实验一.zip
- 提交内容: 实验报告、代码文件 (.ipynb) , 按框架代码要求完成