


机器学习


课程总结



1. 什么是机器学习?
2. 为什么我们学习机器学习课程?
3. 机器学习都讲了哪些内容?
4. 机器学习有哪些应用?
5. 机器学习在你的未来研究和工作中重要吗?
6. 教材上学习系统太多了, 跨越是不是太大了!
7. 机器学习系统如何设计比较难掌握, 怎么办?
8.

本课程的总体章节安排：

- 第1章：绪论
- 第2章：概念学习 (Concept Learning)
- 第3章：决策树学习 (Decision Tree learning)
- 第4章：人工神经网络学习 (Neural Network Learning)
- 第5章：贝叶斯学习 (Bayesian Learning)
- 第6章：基于实例的学习 (Instance-Based Learning)
- 第7章：演化/遗传算法学习 (Evolutionary Learning)
- 第8章：特征选择学习 (Feature Selection Learning)
- 第9章：线性学习 (Linear Classifier)
- 第10章：回归学习 (Regression Learning)
- 第11章：无监督学习 (Unsupervised learning)
- 第12章：深度学习简介 (Deep Learning)



一、绪论

- 机器学习的应用
- 机器学习的定义
 - 学习 (T、P、E)
 - 机器学习
- 机器学习的设计方法
 - 选择训练经验
 - 选择目标函数
 - 选择目标函数的表示
 - 选择函数逼近算法
 - 最终设计

二、概念学习

- 概念与概念学习的定义
 - 概念学习的任务 (X 、 H 、 c 、 D)
- Find-S: 寻找极大特殊假设
 - 假设的一般到特殊序 (偏序)
 - Find-S 算法
- 变型空间和候选消除算法
 - 变型空间 (一致 vs 满足)
 - 候选消除学习算法
- 归纳偏置
 - 无偏的学习器
 - 无偏学习的无用性
 - 归纳偏置

三、决策树学习

- 基本概念
 - 什么是决策树学习
- 决策树学习
 - 特点：
 - 从根结点到叶结点对进行排序从而实现分类
 - 叶子结点提供分类
 - 每个结点指定一种属性
 - 每个分支都对应一个属性值
 - 特征变量选择(信息、熵、信息增益)
- 决策树学习的基本算法
 - ID3算法
 - ID3 vs. 候选消除算法 (优选偏置vs限定/限制偏置)
 - 过拟合现象(增加数据, 预剪枝, 错误率降低修剪、规则后修剪)
- 决策树算法的归纳偏置 (偏向于短的假设)

四、神经网络学习

● 基本概念

● 神经网络的定义

● 感知器模型

➤ 感知器的定义

➤ 感知器的逻辑运算(与、或、非)

➤ 感知器的表达能力(线性可分)

➤ 感知器的训练法则

□ 感知器法则


$$w_i \leftarrow w_i + \Delta w_i \quad \Delta w_i = \eta (t - o) x_i$$

□ Delta法则

✓ 训练一个无阈值感知器(线性单元)

✓ 对训练样例拟合的训练误差指定一个度量

✓ 基本思想: 使用梯度下降法搜索可能的权向量的假设空间, 以找到最佳拟合训练实例的权值向量




两者都保证收敛到一个可接受的权向量
有什么区别?

四、神经网络学习

- 梯度下降搜索 $\vec{w} \leftarrow \vec{w} + \Delta \vec{w}$ $\Delta \vec{w} = -\eta \nabla E(\vec{w})$
 - 确定一个使E最小的权向量
 - 从任意的初始权向量w开始，以很小步伐反复修改这个向量
 - 每一步沿误差曲面产生最陡峭下降的方向修改权向量w
 - 迭代直到得到全局最小误差点
- 梯度下降的随机近似（增量/随机梯度下降）
 - GD法则对D中所有训练样例求和后计算权值更新，SGD根据每一个单独样例的误差增量计算权值更新，得到近似的梯度下降搜索
 - 修改的训练规则：只在迭代更新每一个样例时更新权值
$$\Delta w_i = \eta \sum_{d \in D} (t_d - o_d) x_{id} \quad (\text{GD})$$
$$\Delta w_i = \eta (t_d - o_d) x_i \quad (\text{SGD})$$
- 标准GD和SGD的关键区别（书上讲3点）
 - 权值更新训练样本数量、步长、SGD逃离局部极小值的几率更大

四、神经网络学习



● 多层网络

- 可微阈值单元
- 梯度下降法则推导 (Sigmoid单元)

● 反向传播算法

- 算法步骤
- 如何计算 (前馈计算, 误差计算, 权值更新)
- 基本过程 (前向传播, 误差逆向传播, 权值和阈值更新)
- 标准BP算法、累积BP算法、终止条件
- 增加动量项

● BP算法可能面临的问题

- 结构学习、初始化、步长、权值与阈值更新
- 过拟合 (解决办法: 权值衰减、早停、正则化、交叉验证)

● 前馈网络的表达能力

- 布尔函数 (两层)、有界的连续函数 (两层)、任意函数 (三层)

五、贝叶斯学习

- 贝叶斯学习基础知识

- 先验概率、后验概率、类条件概率

- 贝叶斯法则

- 贝叶斯公式
- 极大后验假设、极大似然假设

- 贝叶斯法则与一致学习器

- 一致学习器 & Find-S

- 极大似然与最小误差平方假设

- 用于预测概率的极大似然假设

- 交叉熵损失
- 神经网络学习所学习预测概率是基于预测概率的极大似然假设

- 贝叶斯最优分类器

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

- 朴素贝叶斯分类器

- 属性条件独立性假设 $P(a_1, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j) \\ &= \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j) \end{aligned}$$

六、基于实例的学习

- 最近邻算法

- 最近邻和k-近邻算法

- 局部加权回归

- 使用附近的或距离加权的训练样例来构造目标函数f的局部逼近
- 局部、加权、回归
- 一般方法（构造逼近函数拟合邻域样本、计算 $\hat{f}(x_q)$ 、删除 $\hat{f}(x_q)$ ）

- 径向基函数

- 用于函数逼近、类似局部加权回归、ANN

$$\hat{f}(x) = w_0 + \sum_{u=1}^k w_u K_u(d(x_u, x))$$

- 消极学习和积极学习

- 消极学习概念、实例（K-NN, 局部加权回归）
- 积极学习概念、实例（径向基函数网络的学习方法）

七、遗传算法

● 遗传算法

- 算法基本流程
- 研究的问题：搜索候选假设空间并确定最佳假设
- 最佳假设：最优的适应度
- 共同结构：迭代更新一个假设池，评估适应度、生成新群体
举例：二进制编码、生成群体、选择、交叉、变异

● 遗传算法原型

- 基本算法（初始化群体、评估、迭代（选择、交叉、变异、更新、评估）、返回适应度最高假设）
- 表示假设
- 遗传算子
- 适应度函数和假设选择方式

● 假设空间搜索（拥挤）

八、特征选择

● 基本概念

- 特征：描述物体的属性
- 特征分类：相关特征、无关特征、冗余特征
- 特征选择的概念：从给定特征集合中选出任务相关的特征子集，必须确保不丢失重要特征

● 特征选择

- 可行方法：产生候选子集、评价候选子集好坏、产生下一个候选子集

● 子集搜索和子集评价

- 子集搜索：前向搜索机制、后向搜索机制、双向搜索机制
- 子集评价：信息增益

● 特征选择方法

- 过滤式：对数据集进行特征选择，然后训练学习器 (Relief&Relief-F)
- 包裹式：直接把最终使用的学习器性能作为特征子集的评价准则 (LVW)
- 嵌入式：特征选择过程与学习器训练过程融为一体 (LR, SC)

九、线性分类器

● 线性判别函数

- 线性可分和线性不可分
- 线性判别函数的一般形式
- 几何意义 以及 **几何解释**：可以看作模式 x 到决策面 H 的距离的函数
- 线性分类器设计的主要步骤
- 多类决策问题：拆分策略：1对其余；1对1；多对多

● 最小距离准则

- 实质上是线性分类器

● 感知器准则

- 几个基本概念（线性可分、规范化、解向量和解区、解区的限制）
- 感知器准则函数（只考虑线性可分的情况）& 梯度下降算法求解

● 最小平方误差准则

- 最小平方误差准则函数（对于规范化增广样本： $w^T y_i = b_i > 0$ ；矩阵形式）
- 如何求解：求导（伪逆解）

十、回归学习

● 回归学习

➤ 线性回归

- ✓ 通过属性的线性组合来进行预测线性模型，目的是什么？
(监督学习)
- ✓ 利用线性回归方程的最小平方函数对一个或者多个自变量和因变量之间关系进行建模的一种回归分析

➤ 代价函数：概念，数学定义，求解（梯度下降）

● 逻辑回归

- 概念，数学定义，如何构造损失函数，求解

● 正则化

➤ 过拟合问题

➤ 正则化系数对模型的影响

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^n \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n \theta_j^2$$

● Softmax回归

$$p(y = i | x; \theta) = \frac{e^{\eta_i}}{\sum_{j=1}^k e^{\eta_j}} = \frac{e^{\theta_i^T x}}{\sum_{j=1}^k e^{\theta_j^T x}}$$

十一、无监督学习

● 基本概念

- 监督学习与无监督学习（聚类）
- 聚类、聚类的目的

● K-均值聚类

- 算法步骤
- 影响因素：k值选择、初始划分、距离计算、终止条件
- K-均值算法的硬盘版本

● 聚类的表示

- 聚类的一般表示方法（聚类中心） & 分类模型 & 最常见的值 & 任意形状的聚类

● 层次聚类

- 合并聚类（自下而上） & 分裂聚类（自上而下）

十一、无监督学习

● 层次聚类

➤ 聚类簇之间的距离计算

□ 单链接方法（最近）全链接方法（最远）

平均链接方法（多个点）聚类中心方法（聚类中心）

● 距离函数

➤ 不同数据类型：数值型、布尔型（混淆矩阵、对称和非对称）、符号型

➤ 不同应用领域：文本文档

● 数据标准化

➤ 区间度量属性（范围标准化、z-score标准化）

➤ 比例度量属性

➤ 符号属性

➤ 顺序属性

● 混合属性的处理（转换选主导；合并距离）

● 聚类算法的选择和评估

希望通过本课的学习，为同学们打下专业基础！

欢迎大家提出宝贵的意见或建议！

祝同学们取得好的成绩！

随时欢迎来我课题组交流学习~~~

谢谢大家！

张 正（信息楼1523）

zhengzhang@hit.edu.cn（会及时回复）

<http://faculty.hitsz.edu.cn/zhangzheng>