

# 第3章：决策树学习

张正



哈尔滨工业大学（深圳）

[zhengzhang@hit.edu.cn](mailto:zhengzhang@hit.edu.cn)

<http://faculty.hitsz.edu.cn/zhangzheng>

# 复习

---

- 满足和一致
- 假设的一般到特殊序
- 变型空间
- Find-S 算法
- 候选消除算法
- 不完全学习、有偏假设空间
- 无偏学习器
- 什么是归纳偏置
- 候选消除算法的归纳偏置

# 机器学习的流派之争

## 符号主义者



起源：逻辑学、哲学 | 核心思想：认知即计算，符号的演绎和逆演绎  
问题：知识结构 | 代表算法：逆演绎算法，**决策树**  
应用：知识图谱 | 代表人物是：**Tom Mitchell**, Steve Muggleton, Ross Quinlan



## 联结主义者



起源：神经科学 | 核心思想：对大脑进行仿真  
问题：信度分配 | 代表算法：BP、深度学习  
应用：CV、SR | 代表人物是：Bengio, Hinton, LeCun



## 进化主义



起源：进化生物学 | 核心思想：进化模拟，遗传算法和遗传编程  
问题：结构发现 | 代表算法：基因编程（Genetic programming）  
应用：海星机器人 | 代表人物：John Koda、John Holland、Hod Lipson



## 贝叶斯派




起源：统计学 | 核心思想：概率估计，概率修正，最优决策  
问题：不确定性 | 代表算法：概率推理（贝叶斯，马尔科夫）  
应用：概率预测 | 代表人物：David Heckerman, Judea Pearl, Michael Jordan



## 行为类比主义



起源：心理学 | 核心思想：新旧知识间的相似性  
问题：相似性 | 代表算法：核机器、近邻算法  
应用：Netflix推荐系统 | 代表人物：Peter Hart, Vladimir Vapnik, Douglas Hofstadter





Zhi-Hua Zhou

[Nanjing University](#)

Verified email at nju.edu.cn - [Homepage](#)

[Artificial Intelligence](#) [Machine Learning](#) [Data Mining](#)




Cited by

[VIEW ALL](#)

|           | All    | Since 2021 |
|-----------|--------|------------|
| Citations | 114102 | 56846      |
| h-index   | 135    | 87         |
| i10-index | 512    | 397        |

| TITLE                                                                                                                                                                         | CITED BY | YEAR |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------|------|
| <a href="#">Isolation forest</a><br>FT Liu, KM Ting, ZH Zhou<br>ICDM, 413-422                                                                                                 | 10242    | 2008 |
| <a href="#">Top 10 algorithms in data mining</a><br>X Wu, V Kumar, JR Quinlan, J Ghosh, Q Yang, H Motoda, GJ McLachlan, ...<br>Knowledge and information systems 14 (1), 1-37 | 8422     | 2008 |
| <a href="#">Ensemble Methods: Foundations and Algorithms</a><br>ZH Zhou<br>Chapman & Hall/CRC Press                                                                           | 5750 *   | 2012 |
| <a href="#">ML-KNN: A lazy learning approach to multi-label learning</a>                                                                                                      | 4467     | 2007 |



Public access

[VIEW ALL](#)


4. **Apriori**: a seminal algorithm for finding frequent itemsets
5. **EM**: maximum likelihood estimation of mixture distribution
6. **PageRank**: search ranking algorithm using hyperlinks (Google)
7. **AdaBoost**: one of the most important ensemble methods
8. **KNN**: simplest classifier
9. **Naïve Bayes**: simplest Bayes, independent Bayes
10. **CART**: classification and regression Trees

# 生活中的决策树

小明的爱好是爬山，周末决定是否去爬山，影响是否去爬山有很多因素，其中天气是很重要的因素，还有可能其他因素，决策过程如下：

## 决策规则：

1. 如果天气阴天，又刚好是团体活动，虽然天气一般，也会参加，决定去！
2. 如果天气阴天，也没团队活动，由于天气一般，兴致不够，那就不去了！
3. 如果暴雨天，肯定不去了！
4. 如果天气很好，又不用加班，那就去！
5. 如果天气很好，但是要加班，那就不去吧！



机器学习中的决策树是模拟人类决策过程的典型模型，与人决策不同的是，人的决策往往带有一定的随机性，决策结果未必最优，但决策树模型则从理论上保证了模型结果是最优的（在一定的变量空间范围内）。

# 本章内容

---

一、简介

二、决策树学习

三、决策树学习基本算法

四、决策树学习的常见问题及解释


# 一、决策树学习简介

---

- 决策树学习(Decision Tree Learning) 是机器学习中一类最常见的方法之一。顾名思义，决策树学习就是学习用来作决策的树。
- 决策树学习是一种逼近离散值目标函数的方法，学习到的函数被表示为一棵决策树。

# 一、决策树学习简介

- 一棵决策树一般包含一个根结点、若干个内部结点和若干个叶子结点。
  - 叶子结点对应于决策结果；
  - 每个内部结点对应于一个属性测试，每个内部结点包含的样本集合根据属性测试的结果被划分到它的儿子结点中；
  - 根结点包含全部训练样本。
  - 从根结点到每个叶子结点的路径对应了一条决策规则。





## 二、决策树学习

---

- 决策树学习的目的就是为了构造一棵泛化能力强，即处理待测样本能力强的决策树，基本算法遵循自顶向下、分而治之的策略，具体步骤如下（4步）：
  - 选择最好的属性作为测试属性并创建树的根结点
  - 为测试属性每个可能的取值产生一个分支
  - 训练样本划分到适当的分支形成儿子结点
  - 对每个儿子结点，重复上面的过程，直到所有的结点都是叶子结点

## 二、决策树学习

---

- 决策树学习的特点
  - 通过在树中从根结点到叶结点对实例进行排序从而实现分类
  - 叶子结点提供分类
  - 每个结点指定一种属性
  - 每个分支都对应一个属性值
- 决策树可以表示对属性值的约束连接的分离

## 二、决策树学习

决策树分为分类决策树和回归决策树，主要讨论分类决策树，即一种描述样本数据进行分类的树形结构模型，有结点和有向边组成。

### 如何生成一棵决策树呢？

#### 1. 学习特征变量的分枝策略

- ✓ 特征变量很多，从哪一个变量进行分枝？
- ✓ 有连续变量，有离散变量，应该如何选择切分点？

#### 2. 根据特征变量，将数据划分为多个子集


- ✓ 根据上面分枝策略，对样本进行测试，将样本划分为多个数据子集（子结点）。

#### 3. 构建子树 (高还是胖？)

- ✓ 在每一个数据子集上，创建多棵子树。
- ✓ 针对每一棵子树重复1、2步骤，直到停止生长。


#### 4. 树需要剪枝

- ✓ 可能会形成过渡拟合现象，需要通过剪枝以获得最好的泛化效果。




## 二、决策树学习

### 打网球的决策树例子




## 二、决策树学习

### 打网球的决策树例子



## 二、决策树学习

决策树的合取       $\text{Outlook} = \text{Sunny} \wedge \text{Wind} = \text{Weak}$




分类的过程就是顺着树  
从根结点走到叶结点

## 二、决策树学习


### 决策树的析取

Outlook=Sunny  $\vee$  Wind=Weak



## 二、决策树学习

决策树的异或      Outlook=Sunny **XOR** Wind=Weak





## 二、决策树学习

通过训练得到的一个决策树，每一个叶子结点对应了一个分类器，通过测试新样例在叶子结点的归属，可以实现对新样例的分类预测。

如何利用一棵决策树进行分类呢？

1. 叶子结点中哪一个类别的样本多，就把叶子结点归为该类别


- ✓ 一般情况下，叶子结点会包含各个类别的样本，统计各类别的占比，将叶子结点的类别归为样本数最大的类别

2. 每一个叶子结点对应一条规则

- ✓ 从根结点到叶子结点，形成一条规则，且该规则被认为是完备的，即每一个样本必属于某一条规则

3. 每个叶子结点组成的规则形成一个决策树分类器

- ✓ 预测某个测试样例，只要它能够被预测属于哪一条规则，即可得到对应的分类归属



## 二、决策树学习


反过来想如何构建一棵决策树呢？

回顾：构建过程

1. 学习特征变量的分枝策略
2. 根据特征变量，将数据划分为多个子集
3. 构建子树
4. 树需要剪枝

注意到树的内部结点就是属性，现在问题是：

怎样决定用哪一个属性做根结点？



## 二、决策树学习

### ● 决策树模型的三个关键过程

- **特征变量的选择**，通过信息增益等方法来选择合适的分裂变量
- **决策树的生成**，例如ID3, CART等算法提供了决策树的一套完整算法
- **决策树的剪枝**，通过剪枝来避免过度拟合，提升在未见数据上的预测效果

### 特征变量的选择

● 如何从大量特征变量中选择合适的变量来构造决策树，直接决定了模型最终预测效果，因此，需要有学习方法或策略来确定特征变量的选择。

#### 三种最为常用的策略

信息增益

信息增益比

Gini指数

### 决策树的生成

● 如何从根结点开始来构造决策树？什么时候树应该停止增长？树如何对样本进行预测？

#### 常用的决策树算法

ID3算法


C4.5算法

CART算法

### 决策树的剪枝

● 完全的决策树在训练集上可能预测极佳，但可能会出现过拟合现象，即对测试用例来说结果不佳，需要对决策树进行适当的剪枝。

#### 树的适当剪枝



## 二、特征变量选择

### ● 从信息量到信息熵

- 信息中包含信息量的大小与该消息所表达的事件发生概率有关
- 如果是必然事件（100%出现），则该消息所包含的信息量为0
- 如果不可能发生(或概率极低)，则该消息的信息量为无穷大

### ● 信息是不是可以量化呢？


假如在没有出现信息量的定义之前,我们会怎么考虑呢？直观上原则：

- 信息量不能是负数：信息总是越来越多,不可能变为负数,变得越来越少
- 信息量之间应该可以相加：A和B告诉你的信息，可以相加
- 信息量应该依赖于概率：假如发生的微小的变化( $10^{-5}$ )，不应该导致信息量的大幅变化
- 信息量应该随着概率单调变化：某事件的概率越大，则信息量越少

### ● 信息量的定义

1928年，R.V.L.哈特莱提出了采用了事件出现概率倒数的对数作为信息的度量单位：

$$I = \log_2 \frac{1}{p} = -\log_2 p$$



## 二、特征变量选择

### ● 从信息量到信息熵

- 熵(Entropy)概念最早出现在热力学,热熵表示分子状态混乱程度的物理量。
- 香农将热力学的熵引入到信息论领域,并提出“信息熵”概念,用于表示信息不确定性的一种度量。无论是热熵还是信息熵都是表达事物的混乱程度,越高越混乱,越低与有序。

### ● 熵的定义

- 熵是表示随机变量的不确定性度量  
假设 $X$ 是一个取有限 $n$ 个值的离散随机变量,其概率分布为:

$$P(X = x_i) = p_i$$

- 则随机变量 $X$ 的熵定义为:

$$H(X) = -\sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n p_i (-\log p_i)$$

- 对应到具体样本数据集上, $p_i$ 可由样本中每个类别的经验概率代替:

$$H(D) = -\sum_{k=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

$K$ 个类别,  $|C_k|$ 对应类别的样本个数

### ● 从信息量的角度理解熵

- 可以理解为某一个随机变量的平均信息量,即随机变量信息量的期望

$$H(X) = \sum_{i=1}^n p_i (-\log p_i)$$

事件可能取值的概率

对应的信息量

### ● 从纯度的角度理解熵

- 某种意义上可以理解为对某一个随机变量不纯度的衡量。
- 熵越高越混乱,熵越低纯度越高

## 二、特征变量选择

➤ 则随机变量X的熵定义为：

$$H(X) = -\sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n p_i (-\log p_i)$$

➤ 对应到具体样本数据集上 $p_i$ ：

$$H(D) = -\sum_{i=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

例：假设你有一个八个面的骰子，要用多少bit才能表示出所有可能性呢？

$$3bits = \log_2 8 = -\sum_{i=1}^8 \frac{1}{8} \log_2 \frac{1}{8} = -\sum_{i=1}^8 p(i) \log_2 p(i) = H(X)$$

答案是3 bits，很简单，就是000，001，010，011，100，101，110，111。  
用着3bits的排列组合可以表示八个数，把八种情况都包含了。


除了只接用 $\log_2(8)$ 来求，还可以表示为右边的形式，因为骰子是均匀的，所以投掷到每一面的概率都是1/8，右边式子的实质就是把发生各个事件的不确定性进行求和，得到的就是整个投掷骰子时间的不确定性 $H(X)$ ，也即投掷骰子的信息熵。

## 二、特征变量选择

● 随机变量 $X$ 的熵定义为:  $H(D) = -\sum_{i=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$

$$\begin{aligned} H(X) &= -\sum_{x \in X} p(x) \log_2 p(x) \\ &= \sum_{x \in X} p(x) \log_2 \frac{1}{p(x)} \\ &= E\left(\log_2 \frac{1}{p(X)}\right) \end{aligned}$$


- 熵就是这么一个用来描述离散变量不确定性的概念。
- 再举个抛硬币的例子，一般来说正面背面都是二分之一的概率。这时 $H(X)$ 就是1。
- 如果有人作弊，做了一个百分百正面的硬币。这时按左式一算， $H(x)$ 就是0了，也即不确定性为0。这是很显然的，都百分百正面了，不确定性当然为0。



- 设抛到正面的概率是 $p$ ，则反面的概率是 $1-p$
- 可以看到概率分布是一个钟形函数。
- 当各个事件发生的概率相等时，总的不确定性最高，我们越难猜出会发生哪一个事件。
- 实际生活中，如果有一个事件发生的概率比较大，我们往往就选择猜这个事件了。

## 二、特征变量选择

- **信息增益**表示在知道某个特征之后使得的不确定性减少的程度
  - 知道某个特征之前的熵与知道某个特征之后的熵的**差**
  - 根据某个变量将样本划分为多个子集，**分割前后样本数据的熵之差为信息增益**，也即不确定性的减少量
  - 信息增益越高，表示该变量对样本数据的分类效果越好



信息增加意味着**不确定性减少**，**熵会减小**，而减小程度用信息增益衡量



## 二、特征变量选择

### ● 信息增益的数学表达

- 特征（属性）A对训练样本D的信息增益 $\text{Gain}(D, A)$ ，定义为集合D经验熵 $H(D)$ 与特征A给定条件下D的经验条件熵 $H(D|A)$ 之差
  - 假设训练样本集合为D， $|D|$ 是数据集中样本个数
  - 假设训练集有K个类别 $C_k (k=1, \dots, K)$ ， $|C_k|$ 表示属于 $C_k$ 类别的样本个数
  - 假设A为训练集D中某一特征变量，该特征变量有n个不同的取值，根据特征A的取值，能够将D划分为n个子集 $D_1, D_2, \dots, D_n$ ， $|D_i|$ 表示子集 $D_i$ 的样本个数，即 $\sum_i |D_i| = |D|$
  - 将子集 $D_i$ 中属于类 $C_k$ 的样本集合记作 $D_{ik}$ ，则 $D_{ik}$ 的样本个数为 $|D_{ik}|$

### ● 信息增益

$$\text{gain}(D, A) = H(D) - H(D|A)$$

分支权重，样本越多的  
分支结点影响越大

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = \sum_{i=1}^n \frac{|D_i|}{|D|} * \left( - \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|} \right) = - \sum_{i=1}^n \frac{|D_i|}{|D|} * \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}$$

# 信息增益的计算

## ● 信息量

- 信息中包含信息量大小与该消息所表达事件发生概率有关，必然事件信息量为0，不可能发生(或概率极低)信息量为无穷大

## ● 信息熵

- 可以理解为某一个随机变量的平均信息量，即随机变量信息量的期望

$$H(X) = -\sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n p_i (-\log p_i)$$

$$H(D) = -\sum_{i=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

## ● 信息增益


- 信息增益表示在知道某个特征之后使得的不确定性减少的程度
- 知道某个特征之前的熵与知道某个特征之后的熵的差
- 是根据该属性对样本进行划分，所导致的熵的期望减少程度
- 条件熵的分支权重，样本越多的分支结点影响越大

$$\text{gain}(D, A) = H(D) - H(D|A)$$


$$\begin{aligned} H(D|A) &= \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) \\ &= \sum_{i=1}^n \frac{|D_i|}{|D|} * \left( -\sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|} \right) \\ &= -\sum_{i=1}^n \frac{|D_i|}{|D|} * \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|} \end{aligned}$$

## 二、特征变量选择

$$\begin{aligned}\text{Entropy}([29+,35-]) &= -29/64 \log_2 29/64 - 35/64 \log_2 35/64 \\ &= 0.99\end{aligned}$$



- $\text{Entropy}([21+,5-]) = 0.71$
- $\text{Entropy}([8+,30-]) = 0.74$
- $\text{Gain}(D,A_1) = \text{Entropy}(D) - 26/64 * \text{Entropy}([21+,5-]) - 38/64 * \text{Entropy}([8+,30-]) = 0.27$



- $\text{Entropy}([18+,33-]) = 0.94$
- $\text{Entropy}([11+,2-]) = 0.62$
- $\text{Gain}(D,A_2) = \text{Entropy}(D) - 51/64 * \text{Entropy}([18+,33-]) - 13/64 * \text{Entropy}([11+,2-]) = 0.12$

## 二、特征变量选择

| ID | Age     | Income | Student | Credit_rating | Buy_computer |
|----|---------|--------|---------|---------------|--------------|
| 1  | <=30    | High   | No      | Fair          | No           |
| 2  | <=30    | High   | No      | Excellent     | No           |
| 3  | 31...40 | High   | No      | Fair          | Yes          |
| 4  | >40     | Medium | No      | Fair          | Yes          |
| 5  | >40     | Low    | Yes     | Fair          | Yes          |
| 6  | >40     | Low    | Yes     | Excellent     | No           |
| 7  | 31...40 | Low    | Yes     | Excellent     | Yes          |
| 8  | <=30    | Medium | No      | Fair          | No           |
| 9  | <=30    | Low    | Yes     | Fair          | Yes          |
| 10 | >40     | Medium | Yes     | Fair          | Yes          |
| 11 | <=30    | Medium | Yes     | Excellent     | Yes          |
| 12 | 31...40 | Medium | No      | Excellent     | Yes          |
| 13 | 31...40 | High   | Yes     | Fair          | Yes          |
| 14 | >40     | Medium | No      | excellent     | No           |

- 用 $D$ 来表示整个训练数据集， $A$ 表示属性，可以得到买电脑这个事件的不确定性：

$$H(D) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0.94$$

- 求条件熵，找出能使条件熵最小的属性，将其设置为根结点。

- 举age属性为例子：

<=30 有2+, 3-  
31...40 有4+, 0-  
>40 有3+, 2-

$$\begin{aligned} H(D|'age') &= \frac{5}{14} * \left( -\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) \\ &+ \frac{4}{14} * \left( -\frac{4}{4} \log_2 \frac{4}{4} - \frac{0}{4} \log_2 \frac{0}{4} \right) \\ &+ \frac{5}{14} * \left( -\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) = 0.694 \end{aligned}$$

## 二、特征变量选择

- 用 $D$ 来表示整个训练数据集， $A$ 表示属性，可以得到买电脑这个事件的不确定性：

$$H(D) = -\frac{9}{14} \log_2 \frac{9}{14} - (1 - \frac{9}{14}) \log_2 (1 - \frac{9}{14}) = 0.94$$

- 求条件熵，找出能使条件熵最小的属性，将其设置为根结点。

$$\text{gain}(D, A) = H(D) - H(D | A)$$

$$\text{gain}(D, \text{'Age'}) = 0.940 - 0.694 = 0.246$$

$$\text{gain}(D, \text{'Income'}) = 0.029$$

$$\text{gain}(D, \text{'Student'}) = 0.151$$

$$\text{gain}(D, \text{'Credit_rating'}) = 0.048$$

- 和条件熵相反，因为信息增益是用来衡量相关度，如果一个属性和类标签的相关度越高，说明该属性对于分类越有帮助。
- 所选结点的条件是条件熵越小越好，信息增益越大越好！
- “age” 这个属性的条件熵最小（等价于信息增益最大），因而首先被选出作为根结点。
- 注意每次选出结点后，数据集根据结点属性值分为若干子集，新的子集要重新计算信息增益，而非采用上一次的信息增益继续做决策。

## 三、决策树学习基本算法

- 大多数算法都是一个核心算法的变体
- 在可能的树空间中采用自顶向下的贪婪搜索
- ID3(Quinlan 1986) C4.5(Quinlan 1993)

约翰·罗斯·昆兰(Ross Quinlan)

- 2011年获得了数据挖掘领域最高荣誉奖KDD创新奖，昆兰发明了著名的决策树学习算法ID3、C4.5，其个人主页公布了C4.5的C代码。
- 这个算法确立了决策树“分而治之”的学习策略，1978年他在学术假时到斯坦福大学访问，选修了图灵的助手D. Michie开设的一门研究生课程，课上有一个大作业，要求写程序来学习出完备正确的规则，以判断国际象棋残局中一方是否会在两步棋后被将死。



## 三、决策树学习基本算法

---

- 大多数算法都是一个核心算法的变体
- 在可能的树空间中采用自顶向下的贪心搜索
- ID3(Quinlan 1986) C4.5(Quinlan 1993)
- ID3
  - 通过自顶向下构造决策树来学习
  - 使用统计测试评估每个属性，以确定它单独分类训练实例的好坏
  - 选择最好的属性作为树的根结点
  - 为该属性的每个可能值创建一个分支
  - 把训练实例排列到适当的分支之下
  - 重复以上过程

# 三、决策树学习基本算法

ID3(Examples, Target\_attribute, Attributes)

专用于学习布尔函数

- 为整个树创建一个根结点
- 如果所有实例都是正的，则返回单结点的树根，其中 label=+ ← 递归返回
- 如果所有实例都是负的，则返回单结点的树根，其中 label=-
- 如果所有属性都为空，则返回单结点的树根，将标签label赋值为  
label=实例Examples中最普遍的目标属性Target\_attribute值 ← 递归返回
- 否则 开始
  - A ← 来自于对实例进行最佳决策的属性
  - 根的决策属性 ← A
  - 对A中每一个可能的属性值  $v_i$ 
    - ✓ 在根下面添加一个新的树分支，对应其测试  $A=v_i$
    - ✓ 令  $Examples_{v_i}$  是Examples中满足属性值为  $v_i$  的实例的子集
    - ✓ 如果  $Examples_{v_i}$  为空 ← 递归返回
      - 在这新分支下面添加一个叶子结点，令label=Examples中最普遍的目标属性Target\_attribute的值
    - 否则：在新分支下添加子树ID3 ( $Examples_{v_i}$ , Target\_attribute, Attributes-{A})
- 结束
- 返回根结点



# 三、决策树学习基本算法

## Algorithm 1 决策树学习基本算法

输入:

- 训练集  $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$ ;
- 属性集  $A = \{a_1, \dots, a_d\}$ .

过程: 函数 TreeGenerate( $D, A$ )

```
1: 生成结点 node;  
2: if  $D$  中样本全属于同一类别  $C$  then  
3:   将 node 标记为  $C$  类叶结点; return  
4: end if  
5: if  $A = \emptyset$  OR  $D$  中样本在  $A$  上取值相同 then  
6:   将 node 标记叶结点, 其类别标记为  $D$  中样本数最多的类; return  
7: end if  
-----  
8: 从  $A$  中选择最优划分属性  $a_*$ ;  
9: for  $a_*$  的每一个值  $a_*^v$  do  
10:   为 node 生成每一个分枝; 令  $D_v$  表示  $D$  中在  $a_*$  上取值为  $a_*^v$  的样本子集;  
11:   if  $D_v$  为空 then  
12:     将分枝结点标记为叶结点, 其类别标记为  $D$  中样本最多的类; return  
13:   else  
14:     以 TreeGenerate( $D_v, A - \{a_*\}$ ) 为分枝结点  
15:   end if  
16: end for
```

输出: 以 node 为根结点的一棵决策树

**(1) 当前结点包含的样本全部属于同一类别, 无需划分**

**(2) 当前属性集为空, 或所有样本在所有属性上取值相同, 无法划分**

**(3) 当前结点包含的样本集合为空, 不能划分**

划分操作停止的三个条件

# 三、决策树学习基本算法


## 训练样例

| Day | Outlook  | Temp. | Humidity | Wind   | Play Tennis |
|-----|----------|-------|----------|--------|-------------|
| D1  | Sunny    | Hot   | High     | Weak   | No          |
| D2  | Sunny    | Hot   | High     | Strong | No          |
| D3  | Overcast | Hot   | High     | Weak   | Yes         |
| D4  | Rain     | Mild  | High     | Weak   | Yes         |
| D5  | Rain     | Cool  | Normal   | Weak   | Yes         |
| D6  | Rain     | Cool  | Normal   | Strong | No          |
| D7  | Overcast | Cool  | Normal   | Weak   | Yes         |
| D8  | Sunny    | Mild  | High     | Weak   | No          |
| D9  | Sunny    | Cool  | Normal   | Weak   | Yes         |
| D10 | Rain     | Mild  | Normal   | Strong | Yes         |
| D11 | Sunny    | Mild  | Normal   | Strong | Yes         |
| D12 | Overcast | Mild  | High     | Strong | Yes         |
| D13 | Overcast | Hot   | Normal   | Weak   | Yes         |
| D14 | Rain     | Mild  | High     | Strong | No          |

选择下一个属性

$D=[9+,5-]$

$E=0.940$



$\text{Gain}(D, \text{Outlook})$

$=0.940 - (5/14) \cdot 0.971$

$- (4/14) \cdot 0.0 - (5/14) \cdot 0.971$

$=0.247$


# 三、决策树学习基本算法

## 训练样例

| Day | Outlook  | Temp. | Humidity | Wind   | Play Tennis |
|-----|----------|-------|----------|--------|-------------|
| D1  | Sunny    | Hot   | High     | Weak   | No          |
| D2  | Sunny    | Hot   | High     | Strong | No          |
| D3  | Overcast | Hot   | High     | Weak   | Yes         |
| D4  | Rain     | Mild  | High     | Weak   | Yes         |
| D5  | Rain     | Cool  | Normal   | Weak   | Yes         |
| D6  | Rain     | Cool  | Normal   | Strong | No          |
| D7  | Overcast | Cool  | Normal   | Weak   | Yes         |
| D8  | Sunny    | Mild  | High     | Weak   | No          |
| D9  | Sunny    | Cool  | Normal   | Weak   | Yes         |
| D10 | Rain     | Mild  | Normal   | Strong | Yes         |
| D11 | Sunny    | Mild  | Normal   | Strong | Yes         |
| D12 | Overcast | Mild  | High     | Strong | Yes         |
| D13 | Overcast | Hot   | Normal   | Weak   | Yes         |
| D14 | Rain     | Mild  | High     | Strong | No          |

选择下一个属性

$D=[9+,5-]$   $\text{Gain}(D, \text{Outlook}) = 0.247$   
 $E=0.940$



$$\begin{aligned}\text{Gain}(D, \text{Temp.}) &= 0.940 - (4/14) * 1.0 \\ &\quad - (6/14) * 0.918 - (4/14) * 0.811 \\ &= 0.0291\end{aligned}$$

# 三、决策树学习基本算法


## 训练样例

| Day | Outlook  | Temp. | Humidity | Wind   | Play Tennis |
|-----|----------|-------|----------|--------|-------------|
| D1  | Sunny    | Hot   | High     | Weak   | No          |
| D2  | Sunny    | Hot   | High     | Strong | No          |
| D3  | Overcast | Hot   | High     | Weak   | Yes         |
| D4  | Rain     | Mild  | High     | Weak   | Yes         |
| D5  | Rain     | Cool  | Normal   | Weak   | Yes         |
| D6  | Rain     | Cool  | Normal   | Strong | No          |
| D7  | Overcast | Cool  | Normal   | Weak   | Yes         |
| D8  | Sunny    | Mild  | High     | Weak   | No          |
| D9  | Sunny    | Cool  | Normal   | Weak   | Yes         |
| D10 | Rain     | Mild  | Normal   | Strong | Yes         |
| D11 | Sunny    | Mild  | Normal   | Strong | Yes         |
| D12 | Overcast | Mild  | High     | Strong | Yes         |
| D13 | Overcast | Hot   | Normal   | Weak   | Yes         |
| D14 | Rain     | Mild  | High     | Strong | No          |

选择下一个属性

$$D=[9+,5-] \quad \text{Gain}(D, \text{Outlook}) = 0.247$$

$$E=0.940 \quad \text{Gain}(D, \text{Temp.}) = 0.0291$$



$$\begin{aligned} \text{Gain}(D, \text{Humidity}) &= 0.940 - (7/14) * 0.985 \\ &\quad - (7/14) * 0.592 \\ &= 0.151 \end{aligned}$$

# 三、决策树学习基本算法

## 训练样例

| Day | Outlook  | Temp. | Humidity | Wind   | Play Tennis |
|-----|----------|-------|----------|--------|-------------|
| D1  | Sunny    | Hot   | High     | Weak   | No          |
| D2  | Sunny    | Hot   | High     | Strong | No          |
| D3  | Overcast | Hot   | High     | Weak   | Yes         |
| D4  | Rain     | Mild  | High     | Weak   | Yes         |
| D5  | Rain     | Cool  | Normal   | Weak   | Yes         |
| D6  | Rain     | Cool  | Normal   | Strong | No          |
| D7  | Overcast | Cool  | Normal   | Weak   | Yes         |
| D8  | Sunny    | Mild  | High     | Weak   | No          |
| D9  | Sunny    | Cool  | Normal   | Weak   | Yes         |
| D10 | Rain     | Mild  | Normal   | Strong | Yes         |
| D11 | Sunny    | Mild  | Normal   | Strong | Yes         |
| D12 | Overcast | Mild  | High     | Strong | Yes         |
| D13 | Overcast | Hot   | Normal   | Weak   | Yes         |
| D14 | Rain     | Mild  | High     | Strong | No          |

选择下一个属性


$D=[9+,5-]$

$E=0.940$

$\text{Gain}(D, \text{Outlook}) = 0.247$

$\text{Gain}(D, \text{Temp.}) = 0.0291$


$\text{Gain}(D, \text{Humidity}) = 0.151$



$$\begin{aligned}\text{Gain}(D, \text{Wind}) &= 0.940 - (8/14) * 0.811 \\ &\quad - (6/14) * 1.0 \\ &= 0.048\end{aligned}$$


# 三、决策树学习基本算法

## ID3 算法




# 三、决策树学习基本算法

## ID3 算法



### 三、决策树学习基本算法

## 假设空间搜索 ID3





# 三、决策树学习基本算法

## ● ID3的能力和限制

- H是一个关于现有属性的有限离散值函数的完整空间
- ID3只维护单一的当前假设h
- 在搜索过程中没有回溯
  - 收敛到局部最优解
- 在每个步骤都使用当前所有训练实例，以统计为基础决定怎样优化
  - 对个别训练例子中的错误不太敏感

## ● 决策树学习中的归纳偏差

- ID3搜索策略
  - 选择较短的树而不是较长的树
  - 选择放置信息增益最高的属性最接近树根
- ID3的近似归纳偏置
  - 较短的树比较长的树更优先
  - BFS-ID3寻找最短的决策树
- 更接近ID3的归纳偏置
  - 矮树比长树更受欢迎
  - 将高信息增益的属性放在靠近根(tree root)的树比其他不这样做的树更受欢迎

# 三、决策树学习基本算法

- ID3 vs. 候选消除算法(C-E)

- ID3搜索一个完整的假设空间，但不完全搜索这个空间。

- C-E搜索一个不完整的H，但它完全地搜索这个空间

- ID3的归纳偏差是假设按其搜索策略排序的结果(搜索策略)

- C-E的归纳偏差是其假设表征的表达能力的结果(搜索空间)

- 优选偏置和限定偏置

- **优选偏置**：ID3的归纳偏置是对某些假设(如对于较短的假设)胜过其他假设的一种优选，对最终可列举假设没有严格限制

- **限定偏置**：C-E的归纳偏差是对待考虑假设的一种限定

- 一般来说，优选偏置比限定偏置更可取

- 有些学习系统综合了优选偏置和限定偏置

# 三、决策树学习基本算法

## 为什么偏好短假设

- ID3的归纳偏置的哲学基础
  - 奥卡姆剃刀：如无必要，勿增实体
    - 优先选择拟合数据的最简单假设
- 论据支持
  - 对行星运动的简单解释胜于复杂的解释
  - 短假设比长假设少
    - 符合数据的简短假设不太可能是统计巧合,但长假设可能
    - 如 20个样例可以找到500个或5个结点的决策树拟合
  - 一个复杂假设 $h$ 能够很好拟合当前数据，但无法泛化到后续数据
- 难题
  - 为什么不找一个刚好拟合的小树？(17个叶子结点，11个非叶子结点)
    - 这样的决策树相当少，如何定义很多小的假设集合难解
  - 假设的大小由学习者内部使用的特定表示决定
    - 两个学习者使用不同的内部表示得到不同的 $h$ ，两者都用奥卡姆剃刀原则得到互相矛盾的结论

## 四、决策树学习的常见问题

---

### 决策树学习中的问题

- 决策树学习中的实际问题
  - 决策树要长多深
  - 处理连续属性
  - 选择适当的属性选择度量标准
  - 处理缺少属性值的训练数据
  - 处理具有不同代价的属性
  - 提高计算效率
- 为了解决这些问题，ID3被扩展到C4.5

# 决策树学习过程

## ● 决策树模型的三个关键过程

- **特征变量的选择**，通过信息增益等方法来选择合适的分裂变量
- **决策树的生成**，例如ID3, CART等算法提供了决策树的一套完整算法
- **决策树的剪枝**，通过剪枝来避免过度拟合，提升在未见数据上的预测效果

### 特征变量的选择

● 如何从大量特征变量中选择合适的变量来构造决策树，直接决定了模型最终预测效果，因此，需要有学习方法或策略来确定特征变量的选择。

#### 三种最为常用的策略

信息增益

信息增益比

Gini指数

### 决策树的生成

● 如何从根结点开始来构造决策树？什么时候树应该停止增长？树如何对样本进行预测？

#### 常用的决策树算法

ID3算法


C4.5算法

CART算法

### 决策树的剪枝

● 完全的决策树在训练集上可能预测极佳，但可能会出现过拟合现象，即对测试用例来说结果不佳，需要对决策树进行适当的剪枝。

#### 树的适当剪枝



避免过拟合，泛化性能更好


# 四、决策树学习的常见问题

## 避免数据过拟合

- 考虑假设 $h$ 的误差
  - 训练数据:  $\text{error}_{\text{train}}(h)$
  - 数据 $D$ 的整体分布:  $\text{error}_D(h)$

假设  $h \in H$  **过拟合** 训练数据, 如果存在一个可替换其他假设  $h' \in H$  满足

$$\text{error}_{\text{train}}(h) < \text{error}_{\text{train}}(h') \text{ 并且} \\ \text{error}_D(h) > \text{error}_D(h')$$



## 四、决策树学习的常见问题

- 什么导致了过拟合

- 训练样例中的随机错误或噪声
- 无噪声，但少量样例被关联到叶子结点
  - 发生巧合的规律性，使得一些属性恰巧可以很好地分割样例，但却与实际的目标函数无关

- 我们如何避免过度拟合？

- 增加数据规模：数据包含足够多的差异性，但不现实（目前现实点）
- 剪枝的策略
  - 预剪枝：在对训练数据进行完美划分之前，及早停止增长树
  - 后剪枝：允许树过度拟合训练数据，然后对树进行再修剪

- 注意

- 第一种剪枝方法似乎更直接，但很难精确估计何时停止增长
- 第二种剪枝方法在实践中更为成功

## 四、决策树学习的常见问题

---

- 避免过拟合的关键问题

- 定义什么样的准则来确定最终正确树的规模

- 解决方法

- 使用一组单独的例子来评估后修剪方法从树上修剪结点的效用（训练集和验证集划分）——卡方测试
- 使用所有可用的数据进行训练，但应用统计测试来评估生长(或修剪)一个特定结点，是否有可能改善样本外数据样例的性能
- 使用一个明确的标准来衡量训练样例和决策树编码的复杂度，当编码长度最小时，停止增长树——最小描述长度准则



# 四、决策树学习的常见问题

## ● 注意

### ➤ 第一种是最常见的(训练和验证集方法)


- 训练集，形成学习到的假设
- 验证集，评估这个假设在后续数据上准确性

### ➤ 动机

- 即使学习者可能会被训练集内的随机错误所误导，但是验证集不太可能表现出相同的随机波动
- 验证集应该足够大，以提供具有统计意义的实例样本
  - 通常是验证集可用实例的三分之一

学习系统设计/评价过程

- 训练和测试过程分开，不同的样本集
- 训练过程中有模型选择问题




## 四、决策树学习的常见问题

### 错误率降低修剪

- 修剪一个结点的步骤
  - 修剪(每一个结点作为候选对象)
    - 删除以该结点为根的子树，使其成为叶结点
  - 指定结点的分类
    - 把和该结点关联的训练样例的最常见分类赋给它
  - 删除一个结点
    - 如果修剪后的树在验证集上的性能不比原始树差，才删剪
  - 重复这一步骤，直到进一步修剪有害为止
- 可用数据被划分为3个子集
  - 训练样本、用于修剪树的验证实例
  - 用于估计实际精度的测试实例
  - 这种方法需要大量的数据

## 四、决策树学习的常见问题



## 四、决策树学习的常见问题

---

### 规则后修剪法


- 步骤

- (1) 从训练推断出一棵树
  - 增长树尽可能地拟合训练数据，并允许发生过拟合
- (2) 将树转换成等价的规则集合
  - 为从根到叶子的每个路径创建一条规则
- (3) 修剪(泛化)每一条规则
  - 删除任何能够导致其估计精度提高的先行词(先决条件)
- (4) 对修剪后的规则进行排序
  - 根据他们所估计的准确性进行排序
  - 按照这个顺序，应用这些规则对后续实例进行分类

## 四、决策树学习的常见问题

- 实例:如图中的决策树

- 生成5条决策规则的集合
- 树中最左边的路径
  - ▣ 如果 $(\text{outlook}=\text{sunny}) \wedge (\text{Humidity}=\text{High})$ , 那么,  $\text{PlayTennis}=\text{No}$
- 考虑移除树的 $(\text{outlook}=\text{sunny})$ 和 $(\text{Humidity}=\text{High})$
- 通过删除不会降低估计精度的先行词来修剪每一个规则



## 四、决策树学习的常见问题

---

- 估计规则精度

- 一种是使用验证集

- 另一种是基于训练集本身评估性能

- 使用保守估计

- ✓ 弥补了训练数据有利于当前规则的估计偏置

- 过程

- ✓ 计算规则在训练样例上的精度

- ✓ 假定估计为二项分布并计算其标准差

- ✓ 对于给定的置信区间，采用下限估计作为规则性能的度量

- 注意

- ✓ 对于大数据集，保守估计非常接近观测精度

- ✓ 在统计上是无效的，但在实践中是有用的

## 四、决策树学习的常见问题

---

- **规则后修剪法**为什么在修剪前要把决策树转换成规则
  - 这样可以区分使用决策结点的不同上下文
    - 对每个结点进行不同的修剪决策
  - 消除了发生在**根结点附近**的属性测试和**叶子结点附近**的属性测试之间的区别
    - 避免了零乱的记录问题，如修剪了根但保留了部分子树，如何进行重新组织这棵树的问题
  - 提高其可读性，规则更容易理解

# 四、决策树学习的常见问题

## 合并连续值属性

- ID3对属性值的限制

- 要预测的**目标属性**为离散值
- 树的**决策结点**的属性是离散值

- 第二个限制可以很容易地取消

- 动态定义新的离散值属性，即连续值离散化

- 案例:

- Temperature = 24.5°C ?  
(Temperature > 20.0°C) = {true, false}
- 阈值应该设置在哪里?
- 选择一个能产生最大**信息增益**的阈值c

|             |      |      |      |      |      |      |
|-------------|------|------|------|------|------|------|
| Temperature | 40°C | 48°C | 60°C | 72°C | 80°C | 90°C |
| PlayTennis  | No   | No   | Yes  | Yes  | Yes  | No   |



# 四、决策树学习的常见问题

## 合并连续值属性

### ● 案例:

- Temperature = 24.5°C ?  
(Temperature > 20.0°C) = {true, false}
- 阈值应该设置在哪里?
- 选择一个能产生最大信息增益的阈值c
  - no一个界, yes 一个界, no再来一个界
  - 根据连续属性A对实例进行排序
  - 确定目标分类不同的相邻实例
  - 创建一组候选阈值, 其在相应的A值之间的中间值
    - ✓可以看出, 使信息增益最大化的c位于该边界(Fayyad1991)
  - 计算各阈值的信息增益

|             |      |      |      |      |      |      |
|-------------|------|------|------|------|------|------|
| Temperature | 40°C | 48°C | 60°C | 72°C | 80°C | 90°C |
| PlayTennis  | No   | No   | Yes  | Yes  | Yes  | No   |

## 四、决策树学习的常见问题

### 处理缺少属性值的训练样例

- 现实任务中常会遇到不完整样本，即样本的某些属性值缺失，尤其是在属性数目较多的情况下，往往会有大量样本出现缺失值。面对缺失属性值，决策树学习会面临两个方面的问题：
  - 如何计算含缺失值属性的划分度量、并进行最佳划分的选择？如何计算信息增益 $\text{Gain}(D, A)$ ？
  - 选择好最佳划分后，若样本在该属性上的值缺失，如何对样本进行划分？

## 四、决策树学习的常见问题

### 处理缺少属性值的训练样例

- 通常有两个办法：

- 放弃含缺失值的样本，仅使用无缺失值的样本来进行学习，这种方法造成了数据信息的浪费。
- 根据此属性值已知的其他样本，来估计这个缺失的属性值。
  - ▣ 赋给它当前结点所有样本中该属性最常见的值
  - ▣ 赋给它当前结点同类样本中该属性最常见的值
  - ▣ 为含缺失值属性的每个可能值赋予一个概率，而不是简单地将最常见的值赋给它

## 四、决策树学习的常见问题

### 属性选择的其他度量标准

- 信息增益的偏置

- 存在一个内在偏置，偏好于支持具有较多值的属性

- 增益率度量

- 通过加入一个称为分裂信息的项来惩罚较多属性值的属性
- 分裂信息用于衡量属性分裂数据的广度和均匀性

$$SplitInformation(D, A) = - \sum_{i=1}^K \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}$$

C4.5

$$GainRatio(D, A) = \frac{Gain(D, A)}{SplitInformation(D, A)}$$

- 分裂信息实际上就是当前结点关于划分属性各值的熵，它可以阻碍选择属性值均匀分布的属性

## 四、决策树学习的常见问题

- 但又产生了一个新的实际问题：当划分属性在当前结点中几乎都取相同的属性值时，会导致**增益率无定义或者非常大**（分母可能为0或者非常小）。
- C4.5决策树算法并不是直接选择增益率最大的划分属性，而是使用了一个**启发式方法**：先计算每个属性的信息增益及平均值，然后仅对信息增益高于平均值的属性应用增益率度量。
- 此外，平均增益AverGain度量[Wang & Jiang, 2007]**用划分属性取值的个数来替换属性的分裂信息**，不仅惩罚了属性值较多的属性，还避免了增益率度量的实际问题，即

$$AverGain(D, A) = \frac{Gain(D, A)}{k}$$

➤ 其中，k 是划分属性取值的个数。

## 四、决策树学习的常见问题

### 处理不同代价的属性

- 实例属性可能与代价相关
  - 尽可能选择使用低代价属性的决策树
    - 仅在需要产生可靠的分类时，才依赖高代价属性
- 通过在属性选择度量中引入一个代价术语来考虑属性代价

$$\frac{\text{信息增益度量}}{\text{属性代价度量}} \quad \frac{Gain(D, A)^2}{Cost(A)} \quad \frac{2^{Gain(D, A)} - 1}{(Cost(A) + 1)^w}$$

- 这样可以使低代价属性会被优先选择
- Tan and Schlimmer(1990) and Tan(1993), Nunez(1988,1991)

# 小结和补充读物

---

- 决策树学习为概念学习和其他离散值函数的学习提供了一种实用的方法
- ID3
  - 贪心搜索
  - 由根向下生长
  - 完整的假设空间 $H$ ，但不彻底搜索
  - 归纳偏置，优选偏置和限定偏置，对小树的偏爱
- 过拟合问题
- 源码
  - ID3, C4.5, C5.0
    - <http://www.rulequest.com/Personal/J48>
    - <http://www.cs.waikato.ac.nz/ml/weka/>

# 小结和补充读物

---

- C4.5是对基本ID3算法的软件扩展设计的:

- 避免过度拟合数据
- 决定决策树的深度
- 减少错误修剪
- post-pruning规则
- 处理连续属性
- 选择适当的属性选择度量
- 处理缺失属性值的训练数据
- 处理具有不同成本的属性

- 作业: 3.3,3.2

- ddl: 9月25日24: 00



# 决策树学习分类问题

---

## 待测样本的分类问题：

- 到此，我们解决了决策树生长的相关问题，那么，决策树学习学到后，怎样应用决策树进行待测样本的分类？
- 分类待测样本的方法：从决策树的根结点开始，测试这个结点指定的划分属性，然后按照待测样本的该属性值对应的树枝向下移动。
- 给定一个叶子结点（其本质就是一个训练样本的集合），计算其后验概率的常用方法包括：投票法、加权投票法、局部概率模型法。当计算得到的后验概率出现相同的情况下，可以采用随机分类或者拒判的方法进行处理。


# 决策树学习分类问题

| Day | Outlook  | Temperature | Humidity | Wind   | PlayTennis |
|-----|----------|-------------|----------|--------|------------|
| D1  | Sunny    | Hot         | High     | Weak   | No         |
| D2  | Sunny    | Hot         | High     | Strong | No         |
| D3  | Overcast | Hot         | High     | Weak   | Yes        |
| D4  | Rain     | Mild        | High     | Weak   | Yes        |
| D5  | Rain     | Cool        | Normal   | Weak   | Yes        |
| D6  | Rain     | Cool        | Normal   | Strong | No         |
| D7  | Overcast | Cool        | Normal   | Strong | Yes        |
| D8  | Sunny    | Mild        | High     | Weak   | No         |
| D9  | Sunny    | Cool        | Normal   | Weak   | Yes        |
| D10 | Rain     | Mild        | Normal   | Weak   | Yes        |
| D11 | Sunny    | Mild        | Normal   | Strong | Yes        |
| D12 | Overcast | Mild        | High     | Strong | Yes        |
| D13 | Overcast | Hot         | Normal   | Weak   | Yes        |
| D14 | Rain     | Mild        | High     | Strong | No         |

Classify an unseen example:  $\langle \text{sunny}, \text{hot}, \text{normal}, \text{weak} \rangle = ?$


# 决策树学习分类问题

Classify an unseen example:  $\langle \text{sunny}, \text{hot}, \text{normal}, \text{weak} \rangle = ?$




# 决策树学习分类问题

Classify an unseen example: *<sunny,hot,normal,weak>=?*




# 决策树学习分类问题

Classify an unseen example:  $\langle \text{sunny}, \text{hot}, \text{normal}, \text{weak} \rangle = ?$



# 决策树学习分类问题

Classify an unseen example:  $\langle \text{sunny}, \text{hot}, \text{normal}, \text{weak} \rangle = \text{Yes}$



应用拉普拉斯估计得到待测样本x属于Yes和No的概率分别为：

$$P(\text{Yes}|x) = \frac{2 + 1}{2 + 2} = \frac{3}{4} ; P(\text{No}|x) = \frac{0 + 1}{2 + 2} = \frac{1}{4}$$