

第5章：贝叶斯学习

张正




哈尔滨工业大学（深圳）

zhengzhang@hit.edu.cn

<http://faculty.hitsz.edu.cn/zhangzheng>

机器学习的流派之争

联结主义者



起源：神经科学


问题：信度分配

应用：CV、SR

核心思想：对大脑进行仿真

代表算法：BP、深度学习

代表人物是：Bengio, Hinton, LeCun



Authors:

Ian Goodfellow

OpenAI

Yoshua Bengio

Université de Montréal

Aaron Courville

Université de Montréal

802 pages

20 Chapters

机器学习的流派之争


贝叶斯派

Likelihood | Prior
Posterior | Margin

起源：统计学 | 核心思想：概率估计，概率修正，最优决策

问题：不确定性 | 代表算法：概率推理 (Probabilistic inference)

应用：概率预测 | 代表人物：David Heckerman, Judea Pearl, Michael Jordan



Series Editors:

Michael I. Jordan

University of California, Berkeley

Jon Kleinberg

Cornell University

Bernhard Scholkopf

Max Planck Institute

758 pages

14 Chapters

本章内容

一、贝叶斯学习基础知识

二、贝叶斯法则

三、极大似然和最小误差平方假设

四、用于预测概率的极大似然假设

五、贝叶斯最优分类器

六、朴素贝叶斯分类器

一、贝叶斯学习基础知识

- 为什么要把贝叶斯学习引入机器学习
 - 贝叶斯学习为推理提供了一种概率手段
 - 能够计算显式的假设概率
 - 朴素贝叶斯分类器比其他算法相当或更优性能
 - 为理解其他未直接操纵数据的学习算法提供一种有效手段
 - Find-S的最优假设
 - 候选消除算法的最优假设
 - 神经网络的最小化
 - 决策树的归纳偏差
 - 最小描述长度原则

一、贝叶斯学习基础知识

- 用 $P(h)$ 表示在没有观察到训练数据之前假设 h 拥有的初始概率， $P(h)$ 被称为假设 h 的先验概率。
- 先验概率反映了关于假设 h 是一正确假设的机会的背景知识；如果没有这一先验知识，可以简单地将每一候选假设赋予相同的先验概率。
- 类似地， $P(D)$ 表示训练数据 D 的先验概率，那么 $P(D|h)$ 就表示假设 h 成立时 D 的概率。
- 在分类问题中，我们关心的是 $P(h|D)$ ，即给定 D 时 h 的成立的概率，称为 h 的后验概率。

一、贝叶斯学习基础知识

- 交换规则： $P(A, B) = P(B, A)$
- 乘法规则： $P(A, B) = P(A|B)P(B) = P(B|A)P(A) = P(B, A)$
- 加法规则： $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$
- 贝叶斯定理： $P(h|D) = P(D|h)P(h)/P(D)$
- 全概率法则： 如果事件 $A_1 \dots A_n$ 互斥，且满足：
$$\sum_{i=1}^n P(A_i) = 1, \text{ 则 } P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

二、贝叶斯法则

- 机器学习的任务：根据观察到的训练数据 D ，找到最佳假设。
 - **最佳假设**：给定数据 D 以及 H 中不同假设的先验概率的有关知识下，最可能的假设
 - 贝叶斯理论提供了一种直接根据**训练数据**和**先验知识**来计算这种概率可能性的方法
 - 贝叶斯法则提供了一种计算假设概率的方法，它基于**先验概率**、**给定假设下观察到不同数据的概率**，以及**观察到的数据本身**
- 贝叶斯决策论（Bayesian decision theory）是在概率框架下实施决策的基本方法
 - 在分类问题情况中，在所有相关概率都已知的理想情形下，贝叶斯决策考虑**如何基于这些概率和误判损失来选择最优的类别标记**

二、贝叶斯法则

- 贝叶斯定理提供了从先验概率 $P(h)$ 、 $P(D)$ 以及 $P(D|h)$ 计算后验概率 $P(h|D)$ 的方法

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- $P(h|D)$ 随着 $P(h)$ 和 $P(D|h)$ 的增长而增长，而随着 $P(D)$ 的增长而减少。
 - 这是很合理的，因为如果 D 独立于 h 时被观察到的可能性越大，那么 D 对 h 的支持度就越小。

二、贝叶斯法则

- 学习器寻找候选假设集合H中对给定数据D时可能性的最大假设 $h \in H$ (或其中一个)。
- 这种具有最大可能性的假设称为**极大后验**(Maximum a posteriori, MAP)假设：

$$h_{MAP} = \arg \max_{h \in H} P(h | D)$$

类标记 h 相对于样本 D 的“类条件概率”或“似然”

$$= \arg \max_{h \in H} \frac{P(D | h) P(h)}{P(D)}$$

$$= \arg \max_{h \in H} P(D | h) P(h)$$

“证据” (evidence) 因子
与类标记无关

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

二、贝叶斯法则

- 某些情况下，可以假定H中每一个假设都有相同的先验，即 $P(h_i)=P(h_j)$ ，则：

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} \frac{P(D | h)P(h)}{P(D)} \quad \Rightarrow \quad \begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h) \end{aligned} \\ &= \arg \max_{h \in H} P(D | h)P(h) \end{aligned}$$

- 只考虑 $P(D|h)$ 来寻找极大可能假设，它称之为给定h时，数据D的似然度(likelihood)，其最大化问题称为极大似然假设。

二、贝叶斯法则

举例：

- 两个可选假设：病人有某种类型的癌症、病人无癌症
- 实验测试有两种可能输出：+ 和 -
- 先验知识：所有人口中只有0.008的人患有该病
- 该测试只是该病的不完全预测
 - 对有病的患者有98%的可能性返回 + 结果
 - 对无病的患者有97%的可能性返回 - 结果
- 概率式概括
$$P(\text{cancer}) = 0.008, \quad P(\neg \text{cancer}) = 0.992$$
$$P(+|\text{cancer}) = 0.980, \quad P(-|\text{cancer}) = 0.020$$
$$P(+|\neg \text{cancer}) = 0.030, \quad P(-|\neg \text{cancer}) = 0.970$$

二、贝叶斯法则

- **问题**：对于测试返回阳性结果的患者，该病人到底有没有癌症？

$$\begin{aligned} P(\text{cancer}) &= 0.008, & P(\neg \text{cancer}) &= 0.992 \\ P(+|\text{cancer}) &= 0.980, & P(-|\text{cancer}) &= 0.020 \\ P(+|\neg \text{cancer}) &= 0.030, & P(-|\neg \text{cancer}) &= 0.970 \end{aligned}$$

$$\begin{aligned} h_{\text{MAP}} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h)P(h) \end{aligned}$$

- 计算极大后验假设

- $P(h_1 = \text{cancer} | +)$

$$P(+|\text{cancer})P(\text{cancer}) = (0.98) * (0.008) = 0.0078$$

- $P(h_2 = \neg \text{cancer} | +)$

$$P(+|\neg \text{cancer})P(\neg \text{cancer}) = (0.03) * (0.992) = 0.0298$$

- $h_{\text{MAP}} = h_2 = \neg \text{cancer}$

- ▣ $P(D)?$

- 贝叶斯推断在很大程度上取决于先验概率

二、贝叶斯法则与概念学习

Brute-Force 贝叶斯概念学习

- **概念学习问题**: 定义在实例空间 X 上的有限假设空间 H , 任务是学习某个目标概念 $c: X \rightarrow (0,1)$
- **Brute-Force MAP 学习算法**
 - 对于 H 中的每个 h , 计算后验概率: $P(h|D) = \frac{P(D|h)P(h)}{P(D)}$
 - 输出有最高后验概率的假设 h_{MAP} : $h_{MAP} = \operatorname{argmax}_{h \in H} P(h|D)$
- **注意**
 - 需要大量的计算
 - 对于大的假设空间显得不切实际
 - 但是, 它提供了一个**标准依据**来判断其他概念学习算法的性能

二、贝叶斯法则与概念学习

Brute-Force 贝叶斯概念学习

- 训练数据

- 给定序偶 $\langle x_1, d_1 \rangle, \langle x_2, d_2 \rangle, \dots, \langle x_m, d_m \rangle$
- 假定实例序列 $\langle x_1, x_2, \dots, x_m \rangle$ 固定不变，训练数据 D 可被认为是目标概念序列 $D = \langle d_1, d_2, \dots, d_m \rangle$

- 前提条件

- 训练数据 D 是无噪声的(即 $d_i = c(x_i)$)
- 目标概念 c 包含在假设空间 H 中
- 没有任何理由认为某假设比其他假设的可能性更大

- 则有：
$$P(h) = \frac{1}{|H|} \quad P(D|h) = \begin{cases} 1 & \forall d_i, d_i = h(x_i) \\ 0 & otherwise \end{cases}$$

- Brute-Force 贝叶斯概念学习该如何推导呢？

二、贝叶斯法则与概念学习

Brute-Force 贝叶斯概念学习

- Brute-Force贝叶斯概念学习该如何推导呢？
- 使用贝叶斯公式计算h的后验概率

➤ h与训练数据D不一致($P(D|h)=0$): $P(h|D) = \frac{0 \cdot P(h)}{P(D)} = 0$

➤ h与训练数据D一致($P(D|h)=1$): $P(h|D) = \frac{1 \cdot \frac{1}{|H|}}{P(D)} = \frac{\frac{1}{|H|}}{\frac{|VS_{H,D}|}{|H|}} = \frac{1}{|VS_{H,D}|}$

$VS_{H,D}$ 是H中与D一致的假设子集

- 从全概率公式及所有假设互斥条件, 推导出 $P(D)$:

$$\begin{aligned} P(D) &= \sum_{h_i \in H} P(D|h_i)P(h_i) = \sum_{h_i \in VS_{H,D}} 1 \times \frac{1}{|H|} + \sum_{h_i \notin VS_{H,D}} 0 \times \frac{1}{|H|} \\ &= \sum_{h_i \in VS_{H,D}} 1 \times \frac{1}{|H|} = \frac{|VS_{H,D}|}{|H|} \end{aligned}$$

- 贝叶斯公式说明, 给定 $P(h)$ 和 $P(D|h)$, 后验概率可以计算为:




$$P(h|D) = \begin{cases} \frac{1}{|VS_{H,D}|} & \text{如果 } h \text{ 与 } D \text{ 一致} \\ 0 & \text{其他情况} \end{cases}$$

二、贝叶斯法则与概念学习

Brute-Force 贝叶斯概念学习

- 后验概率

$$P(h|D) = \begin{cases} \frac{1}{|VS_{H,D}|} & \text{如果 } h \text{ 与 } D \text{ 一致} \\ 0 & \text{其他情况} \end{cases}$$



- 观测结果

- 初始化所有假设概率相同
- 训练数据逐步增加，不一致假设概率为0
- 整个概率的和仍为1，它们均匀地分布到剩余的一致假设中

- 结论：** 选定 $P(h)$ 和 $P(D|h)$ 取值下，每个一致假设的后验概率为 $\frac{1}{|VS_{H,D}|}$ ，每一个不一致的为0，因此**每个一致的假设都是MAP假设**。

二、贝叶斯法则与一致学习器

- 一致学习器

- 输出的假设在训练样例上有零错误率的某学习算法

- 任意一致学习器将输出一个MAP假设

- 假定 H 上有均匀的先验概率 ($P(h_i) = P(h_j)$)

- 训练数据是确定性的和无噪声的 (一致, $P(D|h) = 1$, 否则, 0)

- Find-S

- 在上述概率分布下输出MAP假设

- 偏向于输出更特殊假设的MAP假设

- ✓ 输出极大特殊假设, 对于先验概率偏袒于更特殊假设的任何概率分布

- ✓ 如果 h_i 比 h_j 更特殊, $p(h_i) \geq p(h_j)$

二、贝叶斯法则与一致学习器

- 贝叶斯框架能够刻画学习算法的行为
 - 算法输出最佳假设时所定义的 $P(h)$ 和 $P(D|h)$
 - $P(h)$ 和 $P(D|h)$ 可以看作是算法表现最佳行为时的隐含假定
 - ✓ $P(h)$: H 上的先验概率
 - ✓ $P(D|h)$: 数据在拒绝或接受假设方面的强度
 - 实际上, $P(h)$ 和 $P(D|h)$ 也是学习器的归纳偏置
 - 在第二章中, 我们将归纳偏置定义为断言集合 B
 - 候选消除算法的归纳偏置
 - 学习算法的输出是由归纳偏置+隐含假定演绎得出
 - 基于贝叶斯理论可以将归纳推理建模为等效的概率推理系统
 - 基于贝叶斯理论的概率推理系统将产生出与这些算法等效的输入-输出行为

三、极大似然与最小误差平方假设

- 贝叶斯分析表明

- 在特定前提下，任一学习算法如果使输出的假设预测和训练数据之间的误差平方最小化，它将输出一个极大似然假设
- 意义：对于神经网络和曲线拟合的方法而言，使用了误差平方和最小化，就可以用贝叶斯理论来论证（在特定前提下）

- 概率密度函数的极大似然估计问题

- 假定 $X \sim N(\mu, \sigma^2)$ ， μ 和 σ^2 是估计参数

- X 的概率密度函数：
$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 似然函数可以表示为：
$$L(\mu, \sigma^2) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

- 取log可得：
$$\log L(x, \sigma^2) = m \log \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^m -\frac{(x_i - \mu)^2}{2\sigma^2}$$

- 分别求导可得：
$$\mu = \frac{1}{m} \sum_{i=1}^m x_i \quad \sigma^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu)^2$$

三、极大似然与最小误差平方假设

最小误差平方下，对参数的估计是当前样本下的最大似然估计

- 给定样本 $\langle x_i, y_i \rangle$ ，对样本的预测为 $\hat{y}_\theta$ ，误差为 ε ，那么，

$$y_i = \hat{y}_\theta + \varepsilon$$

- 假设 ε 服从正态分布，即 $\varepsilon \sim N(0, \sigma^2)$

则 $y_i - \hat{y}_\theta \sim N(0, \sigma^2) \rightarrow y_i \sim N(\hat{y}_\theta, \sigma^2)$

- 如果要求极大似然估计，那么要求我们现在得到的这个真实存在的 y 在 θ 不同取值下，出现概率最大，我们看这个概率：

$$L(\theta) = P(y | x; \theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}}$$

- 为了简化，采用log函数 $\hat{L}(\theta) = \log P(y | x; \theta) = m \log \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^m -\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}$
- 如上两个 L 和 $\hat{L}$ 是等价关系，最大化 $\hat{L}$ 即平方求和最小

$$\hat{L}(\theta) = \log P(y | x; \theta) = -\frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

三、极大似然与最小误差平方假设

● 问题设定

➤ 学习器 $L(X, H, D)$

- 实例空间 X 和假设空间 H (实数值函数)
- 给定 m 个训练样例的集合 D ，每个训练样例的目标值被某随机干扰，此随机噪声服从正态分布
 - ✓ 序偶 $\langle x_i, y_i \rangle$ ，其中 $y_i = f(x_i) + e_i$
 - ✓ $f(x_i)$: 目标函数的无噪声值
 - ✓ e_i 是随机噪声，独立抽取且服从均值为0的正态分布

➤ 定义数据分布

- 噪声 $e_i \sim N(0, \sigma^2)$
- y_i 肯定遵循 $y_i \sim N(f(x_i), \sigma^2)$
- $p(y_i|h)$ 可以写成 $p(y_i|h) \sim N(f(x_i), \sigma^2)$

➤ 学习器的任务

- 在所有假设有相等先验概率的前提下，输出一个极大似然假设

三、极大似然与最小误差平方假设


误差平方和最小的假设即为极大似然假设

- 给定有噪声的训练集合，以及一个线性目标函数 f

证明：最小平方训练误差的假设是对样例的极大似然假设

注意：极大似然假设不一定等于正确假设 f (有限的带噪声数据得到)

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h) \end{aligned}$$



- 定义概率密度函数：考虑概率密度和正态分布的概念
- 讨论 e 这样的连续变量上的概率，我们引入概率密度

$$p(x_0) = \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} P(x_0 \leq x < x_0 + \varepsilon)$$

三、极大似然与最小误差平方假设

误差平方和最小的假设即为极大似然假设

- 讨论 e 这样的连续变量上的概率，我们引入概率密度函数

$$h_{MAP} = \arg \max_{h \in H} P(h | D) = \arg \max_{h \in H} P(D | h)$$

$$\Rightarrow h_{MAP} = \arg \max_{h \in H} P(h | D) = \arg \max_{h \in H} f(D | h)$$


- $y_i = f(x_i) + e_i$ & $e \sim N(0, \sigma^2) \rightarrow y_i \sim N(f(x_i), \sigma^2)$

- 所以：
$$h_{ML} = \arg \max_{h \in H} P(h | D) = \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i - f(x_i))^2}{2\sigma^2}}$$

- 直接取对数，可得

$$h_{ML} = \arg \max_{h \in H} P(h | D) = \arg \max_{h \in H} -\frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - f(x_i))^2$$

- 正好得到：最大似然假设是 $(h_i - y_i)$ 的最小误差平方



三、极大似然与最小误差平方假设

- 最小误差平方, 最小平方误差, 又称最小二乘

- 思想就是要使得观测点和估计点的距离平方和达到最小
- “二乘”指的是用平方来度量观测点与估计点的远近(在古汉语中“平方”称为“二乘”), “最小”指的是参数的估计值要保证各个观测点与估计点的距离的平方和达到最小

$$\frac{1}{2} \sum_{d \in D} (y_d - \hat{y}_d)^2$$

- 极大似然估计

- 给定模型随机抽取的n组样本观测样例, 最合理的参数估计量应该使得从模型中获得样本观测值的概率最大

- 区别

- 最小误差平方采用了估计值与观测值之差的平方和最小; 最大似然法是从模型中抽取样本观测值得概率最大, 通过选择参数, 使已知数据在某种情况下最可能出现

三、极大似然与最小误差平方假设

回到教材的解释

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y_i - \mu)^2}$$

➤ 替换 $\mu = f(x_i) = h(x_i)$, 得到:

$$\begin{aligned} &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y_i - h(x_i))^2} \\ &= \arg \max_{h \in H} \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} (y_i - h(x_i))^2 \\ &= \arg \max_{h \in H} \sum_{i=1}^m -\frac{1}{2\sigma^2} (y_i - h(x_i))^2 \\ &= \arg \min_{h \in H} \sum_{i=1}^m (y_i - h(x_i))^2 \end{aligned}$$

➤ 最大似然假设是使 y_i 与 $h(x_i)$ 之间的平方误差之和最小的假设

□ 约束条件:

- ✓ 通过将随机噪声添加到真实目标值来生成 x_i
- ✓ 这种随机噪声服从零均值的正态分布



三、极大似然与最小误差平方假设

- 最大似然假设是目标概念与预测值之间的最小误差平方
 - 最小平方误差的学习（梯度下降）就是最大似然估计
 - 成立的前提是 $y_i = h(x_i) + e_i$, e_i 一定是高斯误差
 - 最小平方误差用于神经网络权重学习，线性回归以及多项式拟合以及曲线逼近
- 为什么选择正态分布来描述噪声？
 - 数学计算的简洁性
 - 它是物理系统中许多类型噪声的良好近似（平滑的钟形）
 - 中心极限定理显示：足够多的独立同分布的随机变量之和服从一正态分布，与独立变量本身的分布情况无关

四、用于预测概率的极大似然假设

神经网络学习的预测又有怎样的准则呢？

- 学习一个不确定性函数的框架
 - 为什么？
 - 确定性函数 $f: X \rightarrow \{0,1\}$
 - 多数情况下， f 的预测是不确定性的
 - 不可预测性来源于未能观察到的数据特征
 - 学习任务：神经网络的输出是 $f(x)=1$ 的概率
 - $f': X \rightarrow [0,1]$ ，使得 $f' = P(f(x) = 1)$



四、用于预测概率的极大似然假设

- 学习 f' 的两种方法

- 蛮力方法 (Brute-Force way)

- 收集对 x 的每个可能值观察到的1和0的频率

- 训练神经网络，对每个 x 输出目标频率

- 直接从确定性函数 f 的训练样例中训练神经网络，而且仍能推导出 f' 的极大似然假设

- 如何寻找极大似然假设呢？优化准则？

- 给定训练数据 $D = \{ \langle x_1, d_1 \rangle, \langle x_2, d_2 \rangle, \dots, \langle x_m, d_m \rangle \}$

- d_i 为观察到的 $f(x_i)$ 的目标值是0或1

- **此处**， x_i 和 d_i 都作为随机变量，样例随机独立抽取

四、用于预测概率的极大似然假设

● 优化标准

➤ $D = \{ \langle x_1, d_1 \rangle, \langle x_2, d_2 \rangle, \dots, \langle x_m, d_m \rangle \}$, 随机变量 x_i 和 d_i , $f' = P(f(x) = 1)$

➤ 似然概率: $P(D|h) = \prod_{i=1}^m P(x_i, d_i|h)$

➤ 如果每个实例 x_i 与假设 h 独立

$$P(D|h) = \prod_{i=1}^m P(x_i, d_i|h) = \prod_{i=1}^m P(d_i|h, x_i)P(x_i)$$

➤ 可以推导出: $P(d_i|h, x_i) = \begin{cases} h(x_i) & d_i = 1 \\ 1 - h(x_i) & d_i = 0 \end{cases} \iff h(x_i)^{d_i}(1 - h(x_i))^{1-d_i}$

➤ 似然的数学表达: $P(D|h) = \prod_{i=1}^m h(x_i)^{d_i}(1 - h(x_i))^{1-d_i}P(x_i)$

➤ 求最大似然假设:

$$\begin{aligned} h_{ML} &= \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} p(x_i) \\ &= \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} \\ &= \arg \max_{h \in H} \sum_{i=1}^m d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)) \end{aligned}$$

四、用于预测概率的极大似然假设

➤ 极大似然假设

$$\begin{aligned} h_{ML} &= \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1-h(x_i))^{1-d_i} \\ &= \arg \max_{h \in H} \sum_{i=1}^m d_i \ln h(x_i) + (1-d_i) \ln(1-h(x_i)) \end{aligned}$$

➤ 注意这个结果与信息熵函数的一般式（在第三章中讨论过）的相似性

$$\begin{aligned} \max \sum_{i=1}^m d_i \ln h(x_i) + (1-d_i) \ln(1-h(x_i)) \quad & H(X) = \sum_{i=1}^m p_i (-\log p_i) \\ \Leftrightarrow \min \sum_{i=1}^m -d_i \ln h(x_i) - (1-d_i) \ln(1-h(x_i)) \end{aligned}$$

这个结果被称为交叉熵（cross-entropy）

$$\sum_i^c -p_i \log_2 p_i$$

神经网络学习所学习预测概率是基于预测概率的极大似然假设


四、用于预测概率的极大似然假设

$$\max \sum_{i=1}^m d_i \ln h(x_i) + (1-d_i) \ln(1-h(x_i)) \Leftrightarrow \min \sum_{i=1}^m -d_i \ln h(x_i) - (1-d_i) \ln(1-h(x_i))$$

与网络优化求解有什么关系呢？

➤ 为神经网络推导一个权值训练法则

$$\begin{aligned} \frac{\partial G(h, D)}{\partial w_{jk}} &= \sum_{i=1}^m \frac{\partial G(h, D)}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\ &= \sum_{i=1}^m \frac{\partial (d_i \ln h(x_i) + (1-d_i) \ln(1-h(x_i)))}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\ &= \sum_{i=1}^m \frac{d_i - h(x_i)}{h(x_i)(1-h(x_i))} \frac{\partial h(x_i)}{\partial w_{jk}} \end{aligned}$$



四、用于预测概率的极大似然假设


- 假定神经网络从一个单层的sigmoid单元建立，那么

$$\frac{\partial h(x_i)}{\partial w_{jk}} = \sigma'(x_i) x_{ijk} = h(x_i)(1-h(x_i)) x_{ijk}$$

- 最大化 $P(D|h)$ ，使用梯度下降

$$\begin{aligned} \frac{\partial G(h, D)}{\partial w_{jk}} &= \sum_{i=1}^m \frac{d_i - h(x_i)}{h(x_i)(1-h(x_i))} \frac{\partial h(x_i)}{\partial w_{jk}} \\ &= \sum_{i=1}^m \frac{d_i - h(x_i)}{h(x_i)(1-h(x_i))} h(x_i)(1-h(x_i)) x_{ijk} \\ &= \sum_{i=1}^m (d_i - h(x_i)) x_{ijk} \end{aligned}$$

$$\Delta w_{jk} = \eta \sum_{i=1}^m (d_i - h(x_i)) x_{ijk} \quad w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$



四、用于预测概率的极大似然假设

- 这种权值更新法则与BP的关系

$$\Delta w_{jk} = \eta \sum_{i=1}^m (d_i - h(x_i)) x_{ijk}$$

- 相似之处

- 相差一个 $h(x_i)(1-h(x_i))$

$$BP: \Delta w_{jk} = \eta \sum_{i=1}^m h(x_i)(1-h(x_i))(d_i - h(x_i)) x_{ijk}$$

- 两个权值更新法则在不同的问题背景下均收敛到极大似然假设

- 寻找 h_{ML} 的前提不同

- 最小化平方误差总和的假设 (预测值与目标值)

- $\langle x_i, d_i \rangle$, 其中 $d_i = f(x_i) + e_i$

- 最小化交叉熵的假设 (观察到的布尔值与输入实例)

- $f': X \rightarrow [0,1]$, 使得 $f' = P(f(x) = 1)$

五、贝叶斯最优分类器

- 两个问题

- “给定训练数据，最可能的假设 h 是什么？”
 - 学习到一个假设
- “给定训练数据，对新实例的最可能分类是什么？”
 - 分类器

- 例子

- 三个假设, h_1, h_2, h_3
 - $P(h_1|D) = 0.4, P(h_2|D) = 0.3, P(h_3|D) = 0.3$
 - h_1 是 MAP 假设
- 对一个新实例 x , $h_1(x)=1, h_2(x)=0, h_3(x)=0$
- 任务: x 的类别?
 - MAP假设: $h_1(x) = 1$
 - 考虑所有假设, $p(x=1) = 0.4$ 和 $p(x=0) = 0.6$
 - 我们发现最可能的分类和 h_{MAP} 给出的不同

五、贝叶斯最优分类器

- 如何得到最可能的分类

- 合并所有假设的预测得到，用后验概率来加权

- $P(v_j|D)$ 是将新实例正确划分为 v_j 的概率

$$P(v_j | D) = \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

- 新实例的最优分类为使 $P(v_j|D)$ 最大的 v_j 值

- 贝叶斯最优分类器(学习器)

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

- 举例

- 条件

- ✓ 可能的分类集合 $V = \{+, -\}$

- ✓ $P(h_1|D) = 0.4, P(-|h_1) = 0, P(+|h_1) = 1$

- ✓ $P(h_2|D) = 0.3, P(-|h_2) = 1, P(+|h_2) = 0$

- ✓ $P(h_3|D) = 0.3, P(-|h_3) = 1, P(+|h_3) = 0$

$$\sum_{h_i \in H} P(+ | h_i) P(h_i | D) = 0.4$$

$$\sum_{h_i \in H} P(- | h_i) P(h_i | D) = 0.6$$

$$\arg \max_{v_j \in \{+, -\}, h_i \in H} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D) = 0.6$$

五、贝叶斯最优分类器

● 贝叶斯最优分类器总结

- 使用相同的假设空间和先验概率，没有更好的方法比使用平均性能更好
- 在给定可用数据、假设空间以及这些假设的先验条件下，贝叶斯最优分类器使新实例被正确分类的可能性达到最大
- 一个有趣的属性是预测可以对应于 H 中不存在的假设
 - ▣ 所定义的实例标注不一定对应于 H 中的任一假设 h 对实例的标注
 - ▣ 搜索另外一个假设空间 H'
 - ✓ H' 包含了一组假设，它在 H 中多个假设的线性组合所作的预测中进行比较

五、贝叶斯最优分类器

GIBBS 算法

- 贝叶斯最优分类器的问题
 - 获得最好性能
 - 开销很大
- GIBBS算法一个替代的、非最优的方法
 - 按照 H 上的后验概率分布，从 H 中随机选择假设 h
 - 使用 h 来预言下一个实例 x 的分类
- 分类错误率
 - 随机抽取假设进行分类
 - 一定条件下，GIBBS分类错误率的期望值最差是贝叶斯最优分类器的两倍

六、朴素贝叶斯分类器

Knowl Inf Syst (2008) 14:1–37
DOI 10.1007/s10115-007-0114-2

SURVEY PAPER

Top 10 algorithms in data mining

Xindong Wu · Vipin Kumar · J. Ross Quinlan · Joydeep Ghosh · Qiang Yang · Hiroshi Motoda · Geoffrey J. McLachlan · Angus Ng · Bing Liu · Philip S. Yu · Zhi-Hua Zhou · Michael Steinbach · David J. Hand · Dan Steinberg

Received: 9 July 2007 / Revised: 28 September 2007 / Accepted: 8 October 2007
Published online: 4 December 2007
© Springer-Verlag London Limited 2007

Abstract This paper presents the top 10 data mining algorithms identified by the IEEE International Conference on Data Mining (ICDM) in December 2006: C4.5, k -Means, SVM, Apriori, EM, PageRank, AdaBoost, k NN, Naive Bayes, and CART. These top 10 algorithms are among the most influential data mining algorithms in the research community. With each algorithm, we provide a description of the algorithm, discuss the impact of the algorithm, and review current and further research on the algorithm. These 10 algorithms cover classification, clustering, statistical learning, association analysis, and link mining, which are all among the most important topics in data mining research and development.

六、朴素贝叶斯分类器

- 为什么要用朴素贝叶斯？

- 实用性最高的贝叶斯学习方法
- 某些领域可与神经网络和决策树学习相当

- 学习任务

- 每个实例 x 可由属性值的合取描述
- 目标函数 $f(x)$ 从某个有限集合 V 中取值
- 给定训练样例，预测新实例的目标值(或分类)

- 学习方法

- 给定描述实例的属性值 $\langle a_1, \dots, a_n \rangle$, 计算最可能的目标值 v_{MAP}

$$v_{MAP} = \arg \max_{v_j} P(v_j | a_1, \dots, a_n)$$

六、朴素贝叶斯分类器

● 学习方法

- 分类目标：给定描述实例的属性值 $\langle a_1, \dots, a_n \rangle$, 计算最可能的目标值 v_{MAP}

$$v_{MAP} = \arg \max_{v_j} P(v_j | a_1, \dots, a_n)$$

- 使用贝叶斯公式将此表达式重写

Diagram illustrating the derivation of the MAP hypothesis using Bayes' theorem, with annotations:

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) && \text{先验概率} \\ &= \arg \max_{h \in H} \frac{P(D | h) P(h)}{P(D)} && \text{类条件概率} \quad \text{先验概率} \\ &= \arg \max_{h \in H} P(D | h) P(h) && \text{"证据" 类无关} \end{aligned}$$

$$\begin{aligned} v_{MAP} &= \arg \max_{v_j \in V} \frac{P(a_1, \dots, a_n | v_j) P(v_j)}{P(a_1, \dots, a_n)} \\ &= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j) \end{aligned}$$

六、朴素贝叶斯分类器

- 估计贝叶斯方程中两个数据项的值

$$v_{MAP} = \arg \max_{v_j \in V} \frac{P(a_1, \dots, a_n | v_j) P(v_j)}{P(a_1, \dots, a_n)}$$

- $P(v_j)$ 的估计

- 目标值 v_j 出现在训练数据中的频率

$$= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j)$$

- $P(a_1, \dots, a_n | v_j)$ 的估计：非常困难？

- 所有属性上的联合概率难以从有限的训练样本估计获得，需要巨大的训练数据集
- 采用了“属性条件独立性假设” (attribute conditional independence assumption)：每个属性独立地对分类结果发生影响

$$P(a_1, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$$

- 也就是简单的假定：在给定目标值时属性值之间相互条件独立

六、朴素贝叶斯分类器

朴素贝叶斯分类器

- 基于属性条件独立性假设

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j) \\ &= \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j) \end{aligned}$$

- 注意： $P(a_i | v_j)$, $P(a_1, \dots, a_n | v_j)$ 的数量
- 只要所需的条件独立性能够被满足，朴素贝叶斯分类 v_{NB} 等于MAP分类
- 与其他学习方法的差别？
 - ✓ 没有明确的搜索可能假设空间的过程
 - ✓ 假设的形成不需要搜索，只是简单计算训练样例中不同数据组合的出现频率

六、朴素贝叶斯分类器

举例

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No
15	Sunny	Cool	High	Strong	?

六、朴素贝叶斯分类器

- 如何利用朴素贝叶斯分类器进行分类呢？

- 每一天由属性 $\langle sunny, cool, high, strong \rangle$ 来描述

- 估计
$$v_{NB} = \arg \max_{v_j \in \{yes, no\}} P(v_j) \prod_i P(a_i | v_j)$$
$$= \arg \max_{v_j \in \{yes, no\}} P(v_j) P(sunny | v_j) P(cool | v_j) P(high | v_j) P(strong | v_j)$$

- 计算不同目标值的概率

- $P(yes) = 9/14 = 0.64$

- $P(no) = 5/14 = 0.36$

- $P(wind=strong|yes) = 3/9 = 0.33$ $P(wind=strong|no) = 3/5 = 0.60$

- 计算 v_{NB}

- $P(yes)P(sunny|yes)P(cool|yes)P(high|yes)P(strong|yes) = 0.0053$

- $P(no)P(sunny|no)P(cool|no)P(high|no)P(strong|no) = 0.0206$

- $v_{NB} = no$

15	Sunny	Cool	High	Strong	?
----	-------	------	------	--------	---

六、朴素贝叶斯分类器

估计概率能否准确反映现实情况呢？

- m-估计

- 当样本数据很小，我们使用m-估计

$$\frac{n_c + mp}{n + m}$$

- p: 将要确定的概率的先验估计

- m: 称为等效样本大小的常量

- 在缺少其他信息时，p一般假定为均匀的先验概率

- 如果一个属性有k个可能值， $p=1/k$

- m被称为等效样本大小

- 将n个实际的观察扩大，加上m个按p分布的虚拟样本

实例：学习分类文本

- 学习的目标概念
 - “我感兴趣的电子新闻稿”或“讨论机器学习的万维网页”
- 朴素贝叶斯算法的问题框架
 - 实例空间 X 包含了所有的文本文档
 - 训练集
 - 目标函数 $f(x)$ ：目标值集合 $V(V = \{like, dislike\})$
- 文本分类的两个主要设计问题
 - 怎样将任意文档表示为属性值的形式
 - 如何估计朴素贝叶斯分类器所需的概率
- 表示任意文本文档
 - 对每个单词的位置定义一个属性
 - 该属性的值为在此位置上找到的英文单词

实例：学习分类文本

- 文本分类例子

- 700个被分类为dislike的文档
- 300个被分类为like
- 任务：分类以下新文档
 - ✓ 文档: This is an example document for the naive Bayes classifier. This document contains only one paragraph, or two sentences.
 - ✓ 19个属性，对应19个单词位置
- 计算朴素贝叶斯分类器

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in \{like, dislike\}} P(v_j) \prod_{i=1}^{19} P(a_i | v_j) \\ &= \arg \max_{v_j \in \{like, dislike\}} P(v_j) P(a_1 = "this" | v_j) \dots P(a_{19} = "sentences" | v_j) \end{aligned}$$

实例：学习分类文本

- 朴素贝叶斯分类是使得该文档中单词在此处被观察到的概率最大的一个分类，遵循朴素贝叶斯条件独立性假设。
- 但是，在一个位置上出现某单词的概率独立于另外一个位置的单词吗？
 - 我们别无选择，必须作此假定
 - ✓ 没有这个假定，要计算的概率项将极为庞大
 - 在实践中朴素贝叶斯学习器在许多文本分类问题中性能非常好

实例：学习分类文本

- 估计 $P(v_i)$ 和 $P(a_i = w_k | v_i)$

- $P(v_i)$: 700个dislike & 300个被分类为like

- $P(a_i = w_k | v_i)$, 我们需要估计大约 $2 \times 50000 \times 19$ 个项吗?

- 假定遇到一个单词的概率独立于单词所在位置

$$P(a_i = w_k | v_i) = P(w_k | v_j)$$

- 优点：使可用于估计每个所需概率的样例数增加了，因此增加了估计的可靠程度

- 采纳 m-估计?

$$P(w_k | v_j) = \frac{n_k + 1}{n + |\text{Vocabulary}|}$$

- 总之：假定了单词出现频率与他在文本中的位置无关

实例：学习分类文本

- `Learn_Naive_Bayes_Text( Examples, V )` 学习概率项 $P(w_k|v_j)$ 和 $P(v_j)$

- 收集单词

单词(Vocabulary)←收集Examples中所有单词、标点符号及其他记号

- 计算 $P(v_j)$ 及 $P(w_k|v_j)$

- 对V中每个目标值 v_j ：

- ✓ $\text{docs}_j \leftarrow$ Examples中目标值为 v_j 的文档子集

- ✓ $P(v_j) \leftarrow |\text{docs}_j| / |\text{Examples}|$

- ✓ $\text{Text}_j \leftarrow$ 将 docs_j 中所有成员连接起来建立的单个文档

- ✓ $n \leftarrow$ 在 Text_j 中不同单词位置的总数

- ✓ 对Vocabulary中每个单词 w_k ：

- $n_k \leftarrow$ 单词 w_k 出现在 Text_j 中的次数

- $P(w_k|v_j) \leftarrow (n_k + 1) / (n + |\text{Vocabulary}|)$

- `Classify_Naive_Bayes_Text( Doc )`

对文档Doc返回其估计的目标值: a_i 代表在Doc中的第 i 个位置上出现的单词

- $\text{positions} \leftarrow$ 在Doc中的所有单词位置，包含能在Vocabulary中找到的记号

- 返回 v_{NB} ，其中
$$v_{NB} = \underset{v_j \in V}{\operatorname{argmax}} P(v_j) \prod_{i \in \text{positions}} P(a_i|v_j)$$

贝叶斯最优分类器

→ m					
Instance ID	A ₁	A ₂	...	A _m	C
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

n

a₁

a₂

...

a_m

C=?

$$c(x) = \arg \max_{c \in C} P(c|a_1, a_2, \dots, a_m)$$

↓
贝叶斯定理

$$c(x) = \arg \max_{c \in C} \frac{P(a_1, a_2, \dots, a_m|c)P(c)}{P(a_1, a_2, \dots, a_m)}$$

↓
全概率法则

$$c(x) = \arg \max_{c \in C} \frac{P(a_1, a_2, \dots, a_m|c)P(c)}{\sum_c P(a_1, a_2, \dots, a_m|c)P(c)}$$

↓
NP-Hard Problem
(Chickering, 1996)

朴素贝叶斯分类器

Instance ID	A ₁	A ₂	...	A _m	C
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

a ₁	a ₂	...	a _m	c=?
----------------	----------------	-----	----------------	-----

属性条件独立

$$P(a_1, a_2, \dots, a_m | c) = \prod_{i=1}^m P(a_i | c)$$

朴素贝叶斯分类器

$$c(x) = \arg \max_{c \in C} \frac{P(c) \prod_{i=1}^m P(a_i | c)}{\sum_c P(c) \prod_{i=1}^m P(a_i | c)}$$

分类：去分母

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | c)$$

朴素贝叶斯分类器

Instance ID	A_1	A_2	...	A_m	C
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

a_1 a_2 ... a_m $c=?$


朴素贝叶斯分类器

Naive Bayes (NB)

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i|c)$$

$$P(c) = \frac{\sum_{j=1}^n \delta(c_j, c) + 1}{n + n_c}$$

$$P(a_i|c) = \frac{\sum_{j=1}^n \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^n \delta(c_j, c) + n_i}$$



朴素贝叶斯分类器

Machine Learning, 29, 131–163 (1997)

© 1997 Kluwer Academic Publishers. Manufactured in The Netherlands.

Bayesian Network Classifiers*

NIR FRIEDMAN

nir@cs.berkeley.edu

Computer Science Division, 387 Soda Hall, University of California, Berkeley, CA 94720

DAN GEIGER

dang@cs.technion.ac.il

Computer Science Department, Technion, Haifa, Israel, 32000

MOISES GOLDSZMIDT

moises@erg.sri.com

SRI International, 333 Ravenswood Ave., Menlo Park, CA 94025

Editor: G. Provan, P. Langley, and P. Smyth

Abstract. Recent work in supervised learning has shown that a surprisingly simple Bayesian classifier with strong assumptions of independence among features, called *naïve Bayes*, is competitive with state-of-the-art classifiers such as C4.5. This fact raises the question of whether a classifier with less restrictive assumptions can perform even better. In this paper we evaluate approaches for inducing classifiers from data, based on the theory of learning *Bayesian networks*. These networks are factored representations of probability distributions that generalize the


朴素贝叶斯分类器改进

Instance ID	A_1	A_2	...	A_m	C
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

a_1 a_2 ... a_m $c=?$

朴素贝叶斯分类器 Naive Bayes (NB)

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | c)$$



- 1) 处理算法：结构扩展
- 2) 处理数据：面向特征（特征选择、特征加权）
面向实例（实例选择、实例加权）

总结

- 贝叶斯的基础知识
 - 先验、类条件、后验
- 贝叶斯法则
 - 极大后验假设、极大似然假设
- 贝叶斯学习与概念学习
 - Brute-Force贝叶斯概念学习
- 一致学习器
 - 均匀先验、 D 是确定性+无噪声
- 极大似然与最小误差平方假设
- 用于预测概率的极大似然假设 (Cross-entropy)
- 贝叶斯最优分类器
 - 后验概率加权
- 朴素贝叶斯分类器