

第6章：基于实例的学习

张正



哈尔滨工业大学（深圳）


zhengzhang@hit.edu.cn

<http://faculty.hitsz.edu.cn/zhangzheng>

引言

- 机器学习 $\approx$ 构建一个映射函数

$$y = f(x; \theta)$$

— 语音识别 $f(\text{ ) = \text{“你好”}$

— 图像识别 $f(\text{ ) = \text{“猫”}$


— 围棋 $f(\text{ ) = \text{“5-5” (落子位置)}$

— 对话系统 $f(\text{“你好”}) = \text{“今天天气真不错”}$

引言

什么是机器学习?

- **机器学习**: 从数据中获得决策（预测）函数使得机器可以根据数据进行自动学习，通过算法使得机器从大量历史数据中学习规律从而对新的样本做决策



引言

- 机器学习的任务：根据观察到的训练数据 D ，找到最佳假设。
 - **最佳假设**: 给定数据 D 以及 H 中不同假设的先验概率的有关知识下，最可能的假设
 - 贝叶斯理论提供了一种直接根据**训练数据**和**先验知识**来计算这种概率可能性的方法
 - 贝叶斯法则提供了一种计算假设概率的方法，它基于**先验概率**、**给定假设下观察到不同数据的概率**，以及**观察到的数据本身**
- 贝叶斯决策论（Bayesian decision theory）是在概率框架下实施决策的基本方法
 - 在分类问题情况中，在所有相关概率都已知的理想情形下，贝叶斯决策考虑**如何基于这些概率和误判损失来选择最优的类别标记**

引言

- 贝叶斯定理提供了从先验概率 $P(h)$ 、 $P(D)$ 以及 $P(D|h)$ 计算后验概率 $P(h|D)$ 的方法

类标记 h 相对于样本 D 的“类条件概率”或“似然”

“证据” (evidence) 因子与类标记无关

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计


$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} \frac{P(D | h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(D | h)P(h) \end{aligned}$$

- 某些情况下，可以假定 H 中每一个假设都有相同的先验，即 $P(h_i)=P(h_j)$ ，则：


$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h) \end{aligned}$$

引言


- 贝叶斯分类需要知道样本的概率分布，但估计样本分布有时并不容易
- 直接对数据进行划分的方法
 - 线性方法：简单、实用、经济
 - 但线性不可分时错误率较大



线性可分的实例



线性不可分的实例



引言




- 非线性方法：解决线性不可分问题

- 在分段线性判别函数中，利用每一类的代表点设计分类器，这是最简单和直观的设计方法

- 基本思路

- 如果两类可以划分为线性可分的若干子类，则可以设计多个线性分类器，实现分段线性分类器

- 但是，这个代表点有时候不一定能很好地代表各个类



引言

- 非线性方法：解决线性不可分问题



- 在分段线性判别函数中，利用每一类的代表点设计分类器，这是最简单和直观的设计方法

- 基本思路

- 如果两类可以划分为线性可分的若干子类，则可以设计多个线性分类器，实现分段线性分类器

- 但是，这个代表点有时候不一定能很好地代表各个类

- 作为一种分段线性判别函数的极端情况，将各类中全部样本都作为代表点，这样的决策方法就是近邻法的基本思想



引言

- 近邻法是非参数法中最重要的方法之一。
- 主要介绍最近邻法，k-近邻法，快速近邻法算法及变型算法
- 目标：
 - 理解并能熟练运用近邻方法进行分类
 - 了解最近邻方法的局限、缺点以及优化策略
 - 距离加权最近邻算法、距离加权回归
 - 径向基函数及网络
 - 理解和掌握基于距离度量的机器学习系统
 - 利用近邻法及改进算法解决实际应用问题

本章内容

一、简介

二、k-近邻算法

三、局部加权回归

四、径向基函数

五、消极学习和积极学习

一、简介

- 基于实例的学习

- 学习过程: 只简单存储已知的训练样本
- 分类: 从存储器取出一系列相似实例, 并用来查询新样例

- 与其它算法的关键差异

- 为不同的待分类查询实例, 建立不同的目标函数逼近
- 优点: 用多个简单局部函数逼近复杂的目标函数
- 缺点
 - 分类新实例的开销可能很大
 - ✓ 如何高效检索训练样本
 - 检索相似样例过程中, 一般会考虑实例的所有属性
 - ✓ 若目标概念仅依赖于几个属性, 真正最相似的实例可能很远
 - ✓ 人脸识别的属性是很高维度

二、k-近邻算法

- 适用问题

- 实例表示为 R^n 空间中的点，特征向量 $\langle a_1(x), \dots, a_n(x) \rangle$
- 任意两个实例 x_i 和 x_j 之间的距离定义：

$$d(x_i, x_j) = \sqrt{\sum_{r=1}^n (a_r(x_i) - a_r(x_j))^2}$$

- 学习目标函数 $f: R^n \rightarrow V$

- V : 离散值或实数值


- 学习离散值目标函数 $f: R^n \rightarrow V$, $V = \{v_1, \dots, v_s\}$

- **训练算法**：对于每一个训练样例 $\langle x, f(x) \rangle$ ，把这个样例加入到训练样本集中
- **分类算法**：给定一个待分类实例，选出最相似的 k 个，然后投票决定类别

二、k-近邻算法

- **最近邻算法**基本思想：以全部训练样本作为“代表点”，计算测试样本与这些“代表点”，即所有样本的距离，并以最近邻者的类别作为决策。
- 将与测试样本最近邻样本的类别作为决策的方法称为**最近邻法**
- 对未知 x ，求**训练样本**中与之距离最近的样本 x' ，类别为


$$\delta_i(x, x') = \min_{j=1, \dots, N} \delta(x, x_j) = \|x - x_j\|$$



二、k-近邻算法

- **最近邻算法**基本思想：以全部训练样本作为“代表点”，计算测试样本与这些“代表点”，即所有样本的距离，并以最近邻者的类别作为决策。
- 将与测试样本最近邻样本的类别作为决策的方法称为**最近邻法**
- 对未知 x ，**训练样本**中与之距离最近的样本 x' 对应类别
- 还可以采用所有**类别距离**来计算，最近邻的**类别**

$$g_j(x) = \min_{i=1, \dots, c} \min_k \|x - x_i^k\|, x_i^k \in \omega_i, \omega_i \text{表示第} i \text{个类别}$$



二、k-近邻算法

- 最近邻法的一个明显的推广是k-近邻法
- k近邻一般采用k为奇数，跟投票表决一样，避免因两种票数相等而难以决策
- 训练样本集的数量总是有限的，有时候多一个或者少一个训练样本将会对测试样本分类的结果产生较大的影响，因此k-近邻法的错误率是比较难以计算的
- 算法思想：取未知样本 x_q 的k个近邻，看这k个近邻中多数属于哪一类，就把 x_q 归为哪一类
- 分类算法
 - 待分类（查询）实例 x_q
 - ▣ 在训练样例中，选择 k 个 x_q 的最近邻 $x_1 \dots x_k$
 - ▣ 返回： $\hat{f}(x_q) \leftarrow \operatorname{argmax}_{v \in V} \sum_{i=1}^k \delta(v, f(x_i))$, $\delta(a, b) = \begin{cases} 1 & a = b \\ 0 & a \neq b \end{cases}$
其中，如果 $a=b$ ，那么 $\delta(a,b)=1$ ，否则 $\delta(a,b)=0$

二、k-近邻算法

- 解释：

- $\hat{f}(x_q)$: k -近邻中最普遍类别



- $\hat{f}(x_q)$: 结果依赖于近邻数目

- k -近邻算法学习到的隐含的一般假设

- 仅在需要时计算每个新查询实例的分类

- 1-近邻决策 v.s. 5-近邻决策

- Voronoi图(1-近邻)



二、k-近邻算法

- 学习连续值目标函数

- 用k个最近邻训练样例的平均值表示
- 逼近一个实值目标函数 $f: R^n \rightarrow R$
- 修改分类算法的决策

$$\hat{f}(x_q) \leftarrow \frac{\sum_{i=1}^k f(x_i)}{k}$$

- 分类算法：待分类（查询）实例 x_q
 - ▣ 在训练样例中，选择 k 个 x_q 的最近邻 $x_1 \dots x_k$
 - ▣ 返回： $\hat{f}(x_q) \leftarrow \underset{v \in V}{\operatorname{argmax}} \sum_{i=1}^k \delta(v, f(x_i))$, $\delta(a, b) = \begin{cases} 1 & a = b \\ 0 & a \neq b \end{cases}$
其中，如果 $a=b$ ，那么 $\delta(a,b)=1$ ，否则 $\delta(a,b)=0$

二、k-近邻算法

距离加权最近邻算法

- k-近邻改进

- 根据距离对k-近邻样本进行加权
- 距离近的近邻赋予较大的权值

- 离散值目标函数

$$\hat{f}(x_q) \leftarrow \operatorname{argmax}_{v \in V} \sum_{i=1}^k \mathbf{w}_i \delta(v, f(x_i)) \quad \mathbf{w}_i = \frac{1}{d(x_q, x_i)^2}$$

- 如果 $d(x_q, x_i)^2=0$, $\hat{f}(x_q)=f(x_i)$.
- 如果存在多个零距离样本, $\hat{f}(x_q)$ 为样本数最多的类别

- 实值目标函数

$$\hat{f}(x_q) \leftarrow \frac{\sum_{i=1}^k w_i f(x_i)}{\sum_{i=1}^k w_i}$$

$$\hat{f}(x_q) \leftarrow \operatorname{argmax}_{v \in V} \sum_{i=1}^k w_i \delta(v, f(x_i))$$

二、k-近邻算法

- 以上k-近邻算法的所有变体都只考虑了k个近邻用以分类查询点，是否用所有样本呢？
- 用全部训练样本分类查询点
 - 基于全部样本计算距离加权离散值目标函数
 - 所有训练样例均影响 x_q 的分类
 - 远距离样本对 $\hat{f}(x_q)$ 影响极小
 - 不足：分类运行得更慢
 - 全局方法与局部方法
- Shepard 方法
 - 用全局方法逼近实值目标函数

$$\hat{f}(x_q) \leftarrow \frac{\sum_{i=1}^n w_i f(x_i)}{\sum_{i=1}^n w_i}$$

二、k-近邻算法的说明

- 距离加权k-NN对噪声有鲁棒性
 - 可以平滑掉孤立的噪声样例的影响
- k-近邻的归纳偏置
 - x_q 的类别与在欧式空间中它附近的实例的类别相似
- k-近邻实践中的问题：维度灾难(curse of dimensionality)
 - 每一个实例有20个维度描述，但是只有2个维度是分类有关的，那么分类的结果会被不相关的属性所支配
 - 基于实例的所有属性计算距离
 - 实际中分类相关属性只占少数（人脸识别为例）
 - ✓ 依赖于全属性的相似性度量会误导k-近邻分类
 - ✓ 存在很多不相关属性所导致的难题
 - ✓ 分类的结果会被不相关的属性所支配

二、k-近邻算法的说明

● 克服维度灾难的方法

- 对属性加权，相当于按比例缩放坐标轴
 - ✓ 缩短不相关属性的坐标轴，拉长更相关属性的坐标轴
 - ✓ 每个坐标轴应伸展多少用交叉验证来自动决定
 - ✓ 利用 z_j 伸展第 j 个根坐标轴，然后交叉验证，以此迭代
- 这种伸展坐标轴以优化k-近邻算法的过程，提供了一种抑制无关属性影响的机制
- 更强有力的做法
 - 完全消除最不相关的属性，即设置某个属性的缩放因子 $z_j=0$
 - 选取留一法 (leave-one-out) 来选择属性
- 以上都可以看作以某个常量因子伸展属性坐标轴，其他方法：变化的值伸展坐标轴

二、k-近邻算法的说明

- 实践问题：如何建立搜索近邻样本的高效索引

- 方法举例：KD-tree

- 实例存储在树的叶子结点内，其近邻存储在同一个或附近的结点内
- 通过测试新查询 x_q 的选定属性，把查询结点 x_q 排列到相关的叶

- 统计模式识别术语

- 回归 (Regression)：逼近一个实数
- 残差 (Residual)：逼近目标函数时的
- 核函数 (Kernel function)
 - 用来决定每个训练样例权值的距
 - 函数 K : $w_i = K(d(x_i, x_q))$



三、局部加权回归

- 最近邻方法是在**单一查询点** x_q 逼近目标函数 $f(x)$
- **局部加权回归**是对k-近邻的推广
 - 可采用线性函数，二次函数，神经网络逼近 f
 - 在环绕在 x_q 的**局部区域内**为目标函数 f 建立明确的逼近
 - 该算法使用**附近的或距离加权的训练样例**来构造目标函数 f 的**局部逼近**
 - **局部**：目标函数的逼近仅仅根据查询点附近的数据
 - **加权**：距离贡献的加权用于假设的逼近
 - **回归**：逼近实数值函数的问题
- 局部加权回归的一般方法
 - 构造一个逼近函数 $\hat{f}$ 拟合 x_q **邻域内** 的训练样例
 - 计算 $\hat{f}(x_q)$ ，即 x_q 估计的目标输出
 - 删除 $\hat{f}(x_q)$ **为什么要删除？**

三、局部加权回归

- 用线性函数逼近 x_q 邻域的目标函数 f

➤ $a_i(x)$: 实例 x 的第 i 个属性

$$\hat{f}(x) = w_0 + w_1 a_1(x) + \dots + w_n a_n(x)$$

- 定义误差函数

$$E = \frac{1}{2} \sum_{x \in D} (f(x) - \hat{f}(x))^2$$

- 训练规则

$$\Delta w_j = \eta \sum_{x \in D} (f(x) - \hat{f}(x)) a_j(x)$$

三、局部加权回归

目标函数的全局逼近，那是否可以采用局部趋近呢？

- 三种误差函数 $E(x_q)$

- k-近邻上的误差平方和最小

$$E_1(x_q) = \frac{1}{2} \sum_{x \in x_q \text{ 的 } k \text{ 个近邻}} (f(x) - \hat{f}(x))^2$$

- 使整个数据集D上误差平方和最小，但对每一个训练样例加权，权值为关于距离的递减函数（重要性）

$$E_2(x_q) = \frac{1}{2} \sum_{x \in D} (f(x) - \hat{f}(x))^2 K(d(x_q, x))$$

- 两种结合

$$E_3(x_q) = \frac{1}{2} \sum_{x \in x_q \text{ 的 } k \text{ 个近邻}} (f(x) - \hat{f}(x))^2 K(d(x_q, x))$$

三、局部加权回归

- 准则2: 也许是最好的, 允许每一个训练样例对 x_q 的分类产生影响, 但计算量大

$$E_2(x_q) = \frac{1}{2} \sum_{x \in D} (f(x) - \hat{f}(x))^2 K(d(x_q, x))$$

- 准则3: 近似准则2, 但计算独立于训练样例总数, 而仅依赖于所考虑的最近邻数 k , 即

$$E_3(x_q) = \frac{1}{2} \sum_{x \in x_q \text{ 的 } k \text{ 个近邻}} (f(x) - \hat{f}(x))^2 K(d(x_q, x))$$

相似度的相似度

- 准则3的梯度公式:

$$\Delta w_i = \eta \sum_{x \in x_q \text{ 的 } k \text{ 个近邻}} K(d(x_q, x)) (f(x) - \hat{f}(x)) a_i(x)$$

全局:
$$\Delta w_j = \eta \sum_{x \in D} (f(x) - \hat{f}(x)) a_j(x)$$

三、局部加权线性回归的说明

- 上面考虑了使用一个线性函数在查询实例 x_q 的邻域内逼近 f ，那么还有其它方法吗？
- 可用常量、线性函数、二次函数等局部逼近目标函数，更复杂的函数形式不太常见，因为：
 - 代价高昂
 - 在足够小的实例空间子域上，使用简单的近似已相当好地模拟目标函数


四、径向基函数(Radial Basis Functions)

- 径向基函数

- 用于函数逼近

- 类似于距离加权回归、ANN

- 假设表示：

$$\hat{f}(x) = w_0 + \sum_{u=1}^k w_u K_u(d(x_u, x))$$


- $\hat{f}(x)$ 是 $f(x)$ 的全局逼近函数

- $K_u(d(x_u, x))$ 是高斯函数

$$K_u(d(x_u, x)) = e^{-\frac{1}{2\sigma_u^2} d^2(x_u, x)}$$

- $K_u(d(x_u, x))$ 有局部化特性

- (Hartman 1990年) $\hat{f}(x)$ 能够足够以任意小的误差逼近任何函数，只要高斯核的数量 k 足够大，并且可以分别指定每一个核的宽度 σ^2

四、径向基函数(Radial Basis Functions)

- $\hat{f}(x)$ (Gaussian Kernel) 以任意小的误差逼近任何函数的条件


- 高斯核的个数 k 足够大
- 每一个核的带宽可以分别指定

- $\hat{f}(x)$ 可表示为一个两层网络

- 第一层计算 $K_u(d(x_u, x))$
- 第二层计算第一层单元值的线性组合

- 两阶段训练RBF

- 确定隐藏单元数量 k , 选择定义核函数的 x_u 及 σ^2
- 定义全局误差准则, 学习权 w_u



$$E = \frac{1}{2} \sum_{x \in D} (f(x) - \hat{f}(x))^2$$

四、径向基函数(Radial Basis Functions)

- 如何选择核函数数量(隐藏单元数量)

- 每一训练样本 $\langle x_i, f(x_i) \rangle$ 分配一个高斯核函数

- x_i 为中心点, 所有核函数的宽度 σ^2 赋予**相同值**
- 每一个训练样本 $\langle x_i, f(x_i) \rangle$ 都只在 x_i 的邻域内局部影响 $\hat{f}(x_i)$
- **优点**: RBF网络可**精确地**拟合训练数据
 - ✓ 任意 m 个训练样例集合, 合并 m 个高斯核函数的权值 $w_0 \dots w_m$
 - ✓ 实现对于每一个训练样例, 都满足 $\hat{f}(x_i) = f(x_i)$

- 核函数的数目小于训练样本数

- 提高计算效率
- 核函数分布在整个实例空间, 中心之间有**均匀间隔**
- **或者**非均匀分布核函数中心(特别当实例本身非均匀分布)
 - ✓ 随机选取训练样本一个子集作为核函数的中心
 - ✓ 聚类, 聚类中心作为核函数的中心

四、径向基函数(Radial Basis Functions)

- 对目标函数的全局逼近
 - 用多个局部核函数的线性组合表示的RBF网络
- 输入样本的局部有效性
 - 仅当输入 x 落入某个核函数的中心和宽度所定义的区域时，这个核函数的值才是不可忽略的
- 径向基函数网络：目标函数的多个局部逼近的平滑线性组合
- 优点：训练高效（由于输入层、输出层单独训练）

五、消极学习和积极学习讨论

- **消极学习**：k-NN，局部加权回归

- 延迟了如何从训练数据中泛化的决策，直到遇到新的查询样例时才进行
- “**懒惰学习**” (lazy learning)：此类学习技术在训练阶段仅仅是把样本保存起来，训练时间开销为零，待收到测试样本后再进行处理。

- **积极学习**：学习径向基函数网络的方法 (RBF)

- 在新样例出现之前就做好了泛化的工作，在训练时定义了目标函数逼近的网络结构和权值
- “**急切学习**” (eager learning)：在训练阶段就对样本进行学习处理的方法
- 反向传播和C4.5都是积极学习

被深度学习的预训练+微调模式打破了

五、消极学习和积极学习评论

- 消极学习：k-NN，局部加权回归
- 积极学习：学习径向基函数网络的方法(RBF)
- 分类包含两个阶段：训练阶段和工作阶段
- 两者差异
 - 计算时间：训练时间，分类时间
 - 归纳偏置：泛化时是否考虑查询点 x_q 的信息
 - ✓ 消极方法在决定如何从训练数据D中泛化时考虑查询实例 x_q
 - ✓ 积极方法在见到查询 x_q 之前，已经选取了对目标函数的(全局)逼近

五、消极学习和积极学习评论

- 泛化精度

- 核心观点

- 消极学习器通过（查询点附近）多个局部逼近的组合表示目标函数
 - 积极学习器必须在训练时提交单个全局逼近
 - 主要差异在于目标函数的全局逼近和局部逼近

- 积极方法能否使用多个局部逼近？

- 径向基函数网络

- RBF学习方法是在训练时，提交目标函数全局逼近的积极方法

- 一个RBF网络把这个全局函数表示为多个局部核函数的线性组合实现

- 但是，是以训练样例为中心的局部逼近，并非消极学习中针对查询点的局部逼近

本章总结

- 基于实例的学习
 - 属消极学习方法
 - 无需构造明确假设来定义整个实例空间上的完整目标函数
 - 为每个查询实例形成一个不同目标函数的局部逼近
- 基于实例的学习优点
 - 用不太复杂的局部逼近来模拟复杂目标函数
 - 不会损失训练样例蕴含的任何信息(被储存)
- 基于实例的学习不足
 - 分类效率低
 - 难以选择用来检索相关实例的合适的距离度量
 - 无关特征对距离度量的负作用

本章总结

- k-近邻算法

- 可以逼近实数值或离散值目标函数的基于实例算法

- 局部加权回归法

- k-NN的推广
- 为每一个查询实例建立一个明确的目标函数的局部逼近

- 径向基函数网络

- 空间局部化核函数构成的神经网络
- 可看作基于实例的方法（每个核函数的影响是被局部化的）及ANN（在训练期形成了对目标函数的全局逼近，而不是在查询期形成的局部逼近）的混合

扩展：距离计算

常用的距离度量

距离的度量策略不同，直接影响算法的性能。

以向量为例列举一些常用的距离度量方法

- | | |
|-----------|-----------|
| 1、欧氏距离 | 6、杰卡德相关系数 |
| 2、马氏距离 | 7、余弦相似度 |
| 3、曼哈顿距离 | 8、切比雪夫距离 |
| 4、闵可夫斯基距离 | 9、皮尔逊相关系数 |
| 5、汉明距离 | |

扩展：距离计算

常用的距离度量

1、欧氏距离

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

其实就是应用勾股定理计算两个点的直线距离，它会受指标不同单位刻度影响，所以，在使用前一般要先标准化，距离越大，个体间差异越大。

在数学中，欧几里得距离或欧几里得度量是欧几里得空间中两点间“普通”（即直线）距离。使用这个距离，欧氏空间成为度量空间。相关联的范数称为欧几里得范数。

扩展：距离计算

2、马氏距离

马氏距离（Mahalanobis）是由马哈拉诺比斯（P. C. Mahalanobis）提出的，表示数据的协方差距离。与欧氏距离不同的是它考虑到数据的分布。对于均值为 $\mu=(\mu_1, \mu_2, \mu_3, \dots, \mu_p)^T$ ，协方差为 Σ 的多变量向量 x

$$D_M(x) = \sqrt{(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

如果协方差矩阵是单位阵（独立同分布）时，马氏距离为欧式距离。与量纲尺度无关，可以排除变量之间的相关性的干扰。

主成分分析算法

扩展：距离计算

3、曼哈顿距离

曼哈顿距离衡量要从一个十字路口到另外一个十字路口的实际行驶距离，而不是两点间的直线距离。曼哈顿距离也称为“城市街区距离”。假设两个点的坐标分别为 $a(x_1, y_1)$ 和 $b(x_2, y_2)$ ，其曼哈顿距离为

$$d_{12} = |x_1 - x_2| + |y_1 - y_2|$$

n维空间的向量**a**和**b**的曼哈顿距离为：

$$d_{12} = \sum_{i=1}^n |a_i - b_i|$$

扩展：距离计算

4、海明距离

两个等长字符串s1与s2的汉明距离为：将其中一个变为另外一个所需要作的最小字符替换次数。

例如：

The Hamming distance between "1011101" and "1001001" is 2.

The Hamming distance between "2143896" and "2233796" is 3.

The Hamming distance between "toned" and "roses" is 3.

扩展：距离计算

5、余弦距离

几何中，夹角余弦可用来衡量两个向量方向的差异，那么余弦距离借用此概念来计算样本向量间的距离。

给定属性向量 a 和 b 的余弦相似度为

$$similarity = \cos(\theta) = \frac{a \cdot b}{\|a\| \cdot \|b\|} = \frac{\sum_{i=1}^n a_i \times b_i}{\sqrt{\sum_{i=1}^n (a_i)^2} \times \sqrt{\sum_{i=1}^n (b_i)^2}}$$

夹角余弦取值范围为 $[-1,1]$ 。余弦越大表示两个向量的夹角越小，余弦越小表示两向量的夹角越大。

扩展：距离计算

- 近邻法是典型的非参数法，其优点是
 - 实现简单
 - 分类结果相对比较好
- 近邻法的主要缺点是
 - 对计算机的存储量和计算量的要求很大，耗费大量测试时间
 - 没有考虑决策的风险：票数接近？有噪声？
 - 对其错误率的分析都是建立在渐进理论基础上的。
 - 有限样本下性能如何？

扩展：核函数

- $k(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^T \mathbf{x}_2 \longrightarrow$ Linear Kernel
- $k(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^T \Sigma^{-1} \mathbf{x}_2$ (Σ^{-1} is symmetric positive definite)
- $k(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1^T \mathbf{x}_2 + 1)^d \longrightarrow$ Polynomial Kernel
- $k(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\|\mathbf{x}_1 - \mathbf{x}_2\|^2 / 2\sigma^2) \longrightarrow$ RBF Kernel
- $k(\mathbf{x}_1, \mathbf{x}_2) = \exp(-1/2 \mathbf{x}_1^T \Sigma^{-1} \mathbf{x}_2)$ (Σ^{-1} is symmetric positive definite)
- $k(\mathbf{x}_1, \mathbf{x}_2) = p(\mathbf{x}_1)p(\mathbf{x}_2)$

核函数要满足的条件称为Mercer's condition: <http://www.svms.org/mercer/>