

第8章：特征选择

张正



哈尔滨工业大学（深圳）


zhengzhang@hit.edu.cn

<http://faculty.hitsz.edu.cn/zhangzheng>

总体课程安排


本课程的授课思路：以数据挖掘中的分类和聚类任务为例，首先经典的学习模型，然后增加特征学习的算法模型和技术：

- 第1章：绪论
- 第2章：概念学习（Concept Learning）
- 第3章：决策树学习（Decision Tree Learning）
- 第4章：人工神经网络学习（Neural Network Learning）
- 第5章：贝叶斯学习（Bayesian Learning）
- 第6章：基于实例的学习（Instance-Based Learning）
- 第7章：演化/遗传算法学习（Evolutionary Learning）
- 第8章：特征选择学习（Feature Selection Learning）
- 第9章：线性学习（Linear Classifier）
- 第10章：回归学习（Regression Learning）
- 第11章：无监督学习（Unsupervised Learning）
- 第12章：深度学习简介（Deep Learning）



模式分类的三大核心问题:


- 特征数据采集
- 分类识别
- 特征提取与选择




分类识别的正确率取决于对象的表示、训练学习和分类识别算法。本节介绍的特征提取与选择问题则是对象表示的一个关键问题。

引言

模式分类过程







核心技术：模式分类 (Pattern Recognition)


- 分类 (classification)：模式识别的同义词 (狭义)
- 检测：二分类 (binary)
- 判别：二分类，多分类
- 分类器设计：学习机器 (一般是监督学习)
- 相关问题：特征生成、特征提取 (变换)、特征选择、聚类 (无监督)

引言

目标识别过程




训练/测试过程中的模式预处理-特征提取必须完全一致



引言

目标识别过程



本章内容

一、基本概念

二、特征选择

三、子集搜索与评价

四、特征选择方法

一、基本概念

- 模式 (Pattern)：对客体（研究对象）特征的描述（定量的或结构的描述），是取自客观世界的某一样本的测量值的集合（或综合）。
- 样本 (Sample)：一个具体的研究（客观）对象。如患者，某人写的一个汉字，一幅图片等。
- 特征 (Features)：能描述模式特性的量（测量值）。在统计模式识别方法中，通常用一个矢量表示，称为特征矢量，记为
$$\vec{x} = (x_1, x_2, \dots, x_n)'$$
- 类别 (Class)：具有某些共同特性的对象的集合。

一、基本概念

两种数据测量情况

- (1) 由于测量上可实现性的限制或经济上的考虑，所获得的测量值为数不多。
- (2) 能获得的性质测量值很多。如果全部直接作为分类特征，耗费机时，且分类效果不一定好。有人称之为“特征维数灾难”。

特征选择和提取的目的：经过选择或变换，组成识别特征，尽可能保留分类信息，在保证一定分类精度的前提下，减少特征维数，使分类器的工作既快又准。

基本任务：如何从许多特征中找出那些最有效的特征。

一、基本概念

特征的类别：物理的、结构的、数学的三类。

- 物理和结构特征：容易被人类感知器官发现，但是在使用计算机去构造识别系统时应用这些特征比较复杂。
- 数学特征：计算机在抽取数学特征方面比人强得多，所以在使用计算机来构造自动识别系统时通常采用数学特征。
- 特征形成：根据被识别的对象产生出一组基本特征，它可以是由计算得到的，也可以是用仪表或传感器测量（感知）出来的，这样产生出来的特征称为原始特征。在大多数情况下，不能直接对原始特征进行分类器设计。

一、基本概念

对特征的要求

- (1) 具有**很大**的识别**信息量**。即应具有很好的可分性。
- (2) 具有**可靠性**。模棱两可、似是而非、时是时非等不易判别的特征应丢掉。
- (3) 尽可能强的**独立性**。重复的、相关性强的特征只选一个。
- (4) 数量尽量少，同时损失的信息尽量小。

如何出现了多标签、多实例、零样本呢？

一、基本概念

特征选择和特征提取的异同

- (1) **特征选择**：从 L 个度量值集合 $\{x_1, x_2, \dots, x_L\}$ 中按一定准则选出供分类用的子集，作为降维（ m 维， $m < L$ ）的分类特征。
- (2) **特征提取**：使一组度量值 $(x_1, x_2, \dots, x_L)$ 通过某种变换 $h_i(\cdot)$ 产生新的 m 个特征 $(y_1, y_2, \dots, y_m)$ ，作为降维的分类特征，其中 $i = 1, 2, \dots, m$ ； $m < L$ 。

一、基本概念

特征选择和特征提取的异同（续）

共同点： 都是要达到特征降维的目的


不同点：

- 特征提取：**特征变换**组合原始高维特征，得低维新特征；
- 特征选择：根据专家知识或评价准则来**挑选**出那些对分类最有影响力的**特征**，并未形成新的特征。

一、基本概念

当目标在空间中发生移动、旋转、缩放时，特征值应保持不变，保证仍可得到同样的识别效果。

例：特征选择与特征提取的区别：对一个条形和圆进行识别。



解：[法1]

① 特征提取：测量三个结构特征

(a) 周长


(b) 面积

(c) 两个互相垂直的内径比

② 分析：(c)是具有分类能力的特征，故选(c)，
扔掉(a)、(b)。

—— 特征选择：一般根据物理特征或结构特征进行压缩。

一、基本概念



[法2]: ① **特征提取**: 测量物体向两个坐标轴的投影值, 则A、B各有2个值域区间。可以看出, 两个物体的投影有重叠, 直接使用投影值无法将两者区分开。

② **分析**: 将坐标系按逆时针方向做一旋转变换, 或物体按顺时针方向变, 并适当平移等。根据物体在 x_2' 轴上投影的坐标值的正负可区分两个物体。

——**特征提取**, 一般用数学的方法进行压缩。

一、基本概念

特征提取与选择的目标

通常在得到实际对象的若干具体特征之后，再由这些原始特征产生出对分类识别最有效、数目最少的特征，这就是特征提取与选择的任务。从本质上讲，我们的目的是使在最小维数特征空间中异类模式点相距较远（类间距离较大），而同类模式点相距较近（类内距离较小）。

本章我们主要关注特征选择的问题！


二、特征选择

- 特征

- 描述物体的属性

- 特征的分类

- 相关特征：对当前学习任务**有用的**属性
- 无关特征：与当前学习任务**无关的**属性
- 冗余特征*：其所包含信息能由其他特征推演出来




二、特征选择

- 特征选择

- 从给定的特征集合中选出**任务相关**特征子集
- 必须确保不丢失重要特征

- 原因

- 减轻维度灾难：在少量属性上构建模型
- 降低学习难度：留下关键信息




二、特征选择

如何进行特征选择呢？

特征选择是一个优化问题


- 第一步：选择可能的特征子集空间
- 第二步：选择一个子集，它是最优的或者基于某一个目标函数下的近似最优



二、特征选择

如何进行特征选择呢？

- 遍历所有可能的子集
 - 计算上遭遇组合爆炸，不可行
- 可行方法




两个关键环节：子集搜索和子集评价

三、子集搜索与评价

子集搜索

用贪心策略选择包含重要信息的特征子集



三、子集搜索与评价

子集搜索


用贪心策略选择包含重要信息的特征子集

- 前向搜索：最优子集初始为空，逐渐增加相关特征
- 后向搜索：从完整的特征集合开始，逐渐减少特征
- 双向搜索：每一轮逐渐增加相关特征，同时减少无关特征

三、子集搜索与评价

● 前向搜索

- 最优子集初始为空集，逐渐增加相关特征
- 特征集合初始时包括所有给定特征



三、子集搜索与评价


前向搜索

- 把每个特征看作一个候选子集，特征集 $\{a_1, a_2, a_3 \dots a_d\}$
- 对单个特征子集进行评价，选定 $\{a_2\}$ 最优。
- 将 $\{a_2\}$ 作为第一轮选定集，然后在上一轮选定集中加一特征，构成两特征候选子集，在这 $d-1$ 个候选子集中选出 $\{a_2, a_4\}$ 最优，且优于 $\{a_2\}$ ，则将 $\{a_2, a_4\}$ 作为本轮选定集。
- 重复上述步骤，不断添加特征子集，直到当前最优子集不再优于上一轮的选定集，则停止搜索。

三、子集搜索与评价

前向搜索

```
function SFG( $F$  - full set,  $U$  - measure)
  initialize:  $S = \{\}$ 
  repeat
     $f = \text{FINDNEXT}(F)$ 
     $S = S \cup \{f\}$ 
     $F = F - \{f\}$ 
  until  $S$  satisfies  $U$  or  $F = \{\}$ 
  return  $S$ 
end function
```



S-stores the selected features

三、子集搜索与评价


后向搜索

- 把每个特征看作一个候选子集，特征集 $\{a_1, a_2, a_3 \dots a_d\}$
- 最优特征集从全集出发（初始化）
- 第一次拿出一个识别率最低的属性，然后依次拿出属性直到拿出一个属性后该属性集合的性能不升高反而下降，就停止搜索

三、子集搜索与评价

后向搜索

```
function SBG( $F$  - full set,  $U$  - measure)
  initialize:  $S = \{\}$ 
  repeat
     $f = \text{GETNEXT}(F)$ 
     $F = F - \{f\}$ 
     $S = S \cup \{f\}$ 
  until  $S$  does not satisfy  $U$  or  $F = \{\}$ 
  return  $F \cup \{f\}$ 
end function
```



S-holds the removed features

三、子集搜索与评价

双向搜索

- **算法描述**：使用序列前向选择（SFS）与序列后选择（SBS）分别从两端开始搜索，两者搜索到一个相同的特征子集 Y 才停止搜索。
- **条件**：为了确保序列前向选择与序列后向选择会搜索到相同的子集，需要确保：
 - 被SFS选中的特征SBS就不能去除
 - 被SBS去除的特征SFS就不能选择
- **算法评价**：BDS结合了SFS与SBS，其时间复杂度比SFS与SBS小，但是兼有SFS与SBS的缺点。

三、子集搜索与评价

双向搜索算法流程：

1. Start SFS with the empty set $Y_F = \{\Phi\}$

2. Start SBS with the full set $Y_B = X$;

3. Select the best feature:


$$x^+ = \arg \max_{\substack{x \notin Y_{F_k} \\ x \in Y_{B_k}}} [J(Y_{F_k} + x)]$$

$$Y_{F_{k+1}} = Y_{F_k} + x^+$$

4. Remove the worst feature:

$$x^- = \arg \max_{\substack{x \in Y_{B_k} \\ x \notin Y_{F_{k+1}}}} [J(Y_{B_k} - x)] \quad Y_{B_{k+1}} = Y_{B_k} - x^-; \quad k = k + 1$$

5. Go to 2



三、子集搜索与评价

双向搜索算法流程:

function BG(F_f , F_b - full set, U - measure)

initialize: $S_f = \{\}$

initialize: $S_b = \{\}$

repeat

$f_f = \text{FINDNEXT}(F_f)$

$f_b = \text{GETNEXT}(F_b)$

$S_f = S_f \cup \{f_f\}$

$F_b = F_b - \{f_b\}$

$F_f = F_f - \{f_f\}$

$S_b = S_b \cup \{f_b\}$

until (a) S_f satisfies U or $F_f = \{\}$ or (b) S_b does not satisfy U or $F_b = \{\}$

return S_f if (a) or $F_b \cup \{f_b\}$ if (b)


end function

▷ S_f holds the selected features

▷ S_b holds the removed features

三、子集搜索与评价

双向搜索算法流程：



- O点代表搜索起点
- A点代表搜索目标
- 灰色的圆代表单向搜索可能的搜索范围
- 绿色的2个圆表示某次双向搜索的搜索范围
- 容易证明绿色的面积必定要比灰色的要小

三、子集搜索与评价

子集评价

- 特征子集 A 确定了对数据集 D 的一个划分
 - 每个划分区域对应着特征子集 A 的某种取值
- 样本标记 Y 对应着对数据集的真实划分
- 通过估算这两个划分的差异，就能对特征子集进行评价；与样本标记对应的划分的差异越小，则说明当前特征子集越好

如何评价呢？

- 通过计算属性子集的信息增益，评价子集的好坏
 - A 上的取值将数据集 D 分为 V 份，每一份用 D^v 表示
 - $Ent(D^v)$ 表示 D^v 上的信息熵
 - 信息增益：
$$Gain(A) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v)$$
 - 信息熵：
$$Ent(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

信息增益越大
越有助于分类

四、特征选择方法

基于评价准则划分特征选择方法

将特征子集搜索机制与子集评价机制相结合，即可得到特征选择方法

常见的特征选择方法大致分为如下三类：

- 过滤式
- 包裹式
- 嵌入式

四、特征选择方法

- 过滤式选择

- 先对数据集进行特征选择，然后再训练学习器，特征选择过程与后续学习器无关
- 先用特征选择过程过滤原始数据，再用过滤后的特征来训练模型
- 代表性算法
 - ▣ Relief (Relevant Features) 方法 [Kira and Rendell, 1992]

四、特征选择方法

过滤式选择-- Relief算法

- Relief算法最早由Kira提出，**最初**局限于两类数据的分类问题
 - 为每个初始特征赋予一个“**相关统计量**”度量特征的重要性，总的统计量形成一个向量（每一个统计量对应一个向量的一个元素）
 - **特征子集的重要性**由子集中每个特征所对应的相关统计量分量之和来决定（权重）
 - 最终，**只需设计一个阈值**，然后选择比阈值大的相关统计量分量所对应的特征
 - 也可以利用：指定欲选取的特征个数 k ，然后选择相关统计量分量中，最大的 k 个特征
- Relief的关键是如何确定相关统计量

四、特征选择方法

过滤式选择-- Relief算法（另外一种描述）

- Relief算法是一种特征权重算法(Feature weighting alg.)
 - 根据各个特征和类别的**相关性**赋予特征**不同的权重**（相关统计量）
 - 设定一个阈值，权重小于某个阈值的特征将被移除
 - 算法中特征和类别的相关性是基于**特征对近距离样本**的区分能力
 - **Relief的关键是如何确定权重（相关统计量）？**

四、特征选择方法

● Relief(Relevant Feature)方法

- Relief算法从训练集D中随机选择一个样本 x_i ，然后
 - 从和 x_i 同类的样本中寻找其最近邻样本，称为**猜中近邻**(near-hit)，记为 $x_{i,nh}$
 - 从和 x_i 不同类的样本中寻找其最近邻样本，称为**猜错近邻**(near-miss)，记为 $x_{i,nm}$
- 根据以下规则**更新每一个特征的权重**：
 - 如果 x_i 与猜中近邻在某一个属性(特征) j 上的距离**小于** x_i 和猜错近邻上的距离，则说明该特征 j 对区分同类和不同类的最近邻是**有益的**，则**增大该特征的权重**；
 - 反之，如果 x_i 和猜中近邻在某个特征的距离**大于** x_i 和猜错近邻上的距离，说明该特征对区分同类和不同类的最近邻起**负作用**，则**降低该特征的权重**。
- 以上过程**重复m次**，最后得到个特征的平均权重。

相关统计量：

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

四、特征选择方法

过滤式选择-- Relief算法

- 猜中近邻(near-hit): x_i 的同类样本中的最近邻 $x_{i,nh}$
- 猜错近邻(near-miss): x_i 的异类样本中的最近邻 $x_{i,nm}$
- 相关统计量对应于属性 j 的分量为

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

若 j 为离散型, 则 $x_a^j = x_b^j$ 时
 $\text{diff}(x_a^j, x_b^j) = 0$, 否则为1; 若
 j 为连续型, 则 $\text{diff}(x_a^j, x_b^j) =$
 $|x_a^j - x_b^j|$, 注意 x_a^j, x_b^j 已规范化
到 $[0,1]$ 区间

- 相关特征**权重**越大, 在属性 j 上表示该特征的分类能力越强。
反之, 表示该特征分类能力越弱。
- 相关**统计量**越大, 属性 j 上, 猜对近邻比猜错近邻越近, 即属性 j 对区分对错越有用
- Relief方法的**时间开销**随着采样次数以及原始特征数量线性增长, 运行效率较高。

四、特征选择方法

过滤式选择-- Relief算法

输入：样本集 S , 抽样次数 m , 特征权重阈值 τ

输出：选择后的特征集

把 S 分成 $S^+ = \{\text{正例}\}$ 和 $S^- = \{\text{负例}\}$

权重 $W = (0, 0, \dots, 0)$

For $i=1$ to m

 随机选择一个样例 $X \in S$

 随机选择一个距离 X 最近邻的一个正例 $Z^+ \in S^+$

 随机选择一个距离 X 最近邻的一个负例 $Z^- \in S^-$

 if X 是一个正例

 then Near-hit= Z^+ ; Near-miss= Z^-

 else Near-hit= Z^- ; Near-miss= Z^+

 for $i = 1$ to p //计算相关统计量

$$W_i = W_i - \text{diff}(x_i, \text{near-hit}_i)^2 + \text{diff}(x_i, \text{near-miss}_i)^2$$

relevance = $1/m \sum W$

for $i = 1$ to p

 if $\text{relevance}_i \geq \tau$

 then f_i 是一个相关的特征

 else f_i 不是相关的特征

三、Relief算法小测

Relief算法是分别考虑每个属性的重要性。试设计一个能考虑每一对属性重要性的改进算法。

参考答案：

组合选取每一对属性的near-hit和near-miss，然后计算这一对属性的相关统计量 δ^{ij} 。

得到这个**二维的相关统计量矩阵**后，就可以通过最大生成树等算法来做特征选择。

如果这里存在组合爆炸的问题，可以通过采样等方式减缓。

四、特征选择方法

- Relief算法比较简单，运行效率高，并且结果也比较令人满意，因此得到目前学习算法的广泛应用，但是其局限性在于只能处理两类区分数据
- 1994年Kononenko进行了扩展，得到了Relief-F算法，可以处理多类别问题，用于处理目标属性为连续值的回归问题。
 - Relief-F算法在处理多类问题时，每次从训练样本集中随机取出一个样本 x_i
 - 从和 x_i 同类的样本集中，找出 x_i 的k个猜中近邻样本
 - 从每个 x_i 的不同类的样本集中，均找出k个猜错近邻样本
 - 然后，更新每个特征的权重

四、特征选择方法

扩展变体Relief-F[Kononenko, 1994]能处理多分类问题

- 假定数据 D 中的样本来自 $|\mathcal{Y}|$ 个类别，实例 x_i 属于第 k 类 ($k \in \{1, 2, \dots, |\mathcal{Y}|\}$)
- **猜中近邻**：第 k 类样本中寻找 x_i 的最近邻实例 $x_{i,nh}$
- **猜错近邻**：第 k 类之外的**每个类**中找到一个 x_i 的最近邻实例，记为 $x_{i,l,nm}$ ($l = 1, 2, \dots, |\mathcal{Y}|; l \neq k$)
- 相关统计量对应于属性 j 的分量为

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \sum_{l \neq k} \left(p_l \times \text{diff}(x_i^j, x_{i,l,nm}^j)^2 \right)$$

其中， p_l 为第 l 类样本在数据集 D 中所占的比例

四、特征选择方法

- 选用的数据：威斯康星州乳腺癌数据集，数据来源美国威斯康星大学医院的临床病例报告，每条数据具有9个属性。

属性名称	说明	特征编号
------	----	------


块厚度	范围 1 - 10	1
细胞大小均匀性	范围 1 - 10	2
细胞形态均匀性	范围 1 - 10	3
边缘粘附力	范围 1 - 10	4
单上皮细胞尺寸	范围 1 - 10	5
裸核	范围 1 - 10	6
Bland 染色质	范围 1 - 10	7
正常核仁	范围 1 - 10	8
核分裂	范围 1 - 10	9

- 数据处理思路：先采用Relief-F特征提取算法计算各个属性的权重，剔除相关性最小的属性，然后采用K-means聚类算法对剩下的属性进行聚类分析

四、特征选择方法

● 乳腺癌数据集特征提取

- 采用Relief-F算法来计算各个特征的权重，权重小于某个阈值的特征将被移除
- 针对乳腺癌的实际情况，将对权重最小的2-3种剔除
- 将Relief-F算法运行20次，得到了各个特征属性的权重趋势图



特征属性权重的均值

属性 1	0.2237	属性 2	0.1494
属性 3	0.1588	属性 4	0.1408
属性 5	0.0732	属性 6	0.2408
属性 7	0.1243	属性 8	0.1979
属性 9	0.0503		

● 按照从小到大顺序排列，可知，各个属性的权重关系如下

- 属性9<属性5<属性7<属性4<属性2<属性3<属性8<属性1<属性6
- 我们选定权重阈值为0.14，则属性9、属性5和属性7剔除

四、特征选择方法

● 乳腺癌数据特征分析

- 从上面的特征权重可以看出，属性6“裸核”大小是最主要的影响因素，说明乳腺癌患者的症状最先表现了裸核大小上。
- 该病症将直接导致“裸核”大小的变化，其次是属性1和属性8等，后几个属性权重大小接近。



特征属性权重的均值

属性1	0.2237	属性2	0.1494
属性3	0.1588	属性4	0.1408
属性5	0.0732	属性6	0.2408
属性7	0.1243	属性8	0.1979
属性9	0.0503		

四、特征选择方法

● 乳腺癌数据特征分析

- 从上面的特征权重可以看出，属性6“裸核”大小是最主要的影响因素，说明乳腺癌患者的症状最先表现了裸核大小上。
- 该病症将直接导致“裸核”大小的变化，其次是属性1和属性8等，后几个属性权重大小接近。
- 几个重要的属性进行分析



- “块厚度”属性的特征权重在0.19-0.26左右变动，也是权重极高的一个，说明属性在乳腺癌检测指标中是相当重要的判断依据。
- 进一步分析显示，在单独对属性6和属性1进行聚类分析，类别划分的成功率就可以达到91.8%。

四、特征选择方法

包裹式选择

思路：直接把最终将要使用的学习器的性能作为特征子集的评价准则

- 包裹式特征选择的**目的**就是为给定学习器选择最有利于其性能、“量身定做”的特征子集
- **特点：**包裹式选择方法直接针对给定学习器进行优化，因此从最终学习器性能来看，**包裹式特征选择比过滤式特征选择更好**
- **复杂度：**包裹式特征选择过程中需多次训练学习器，**计算开销通常比过滤式特征选择大得多**
- **代表性算法**
 - LVW (Las Vegas Wrapper) 是一个典型的包裹式特征选择方法

四、特征选择方法

LVW (Las Vegas Wrapper) [Liu and Setiono, 1996] 在拉斯维加斯方法框架下使用**随机策略**来进行子集搜索，并以最终分类器的误差作为特征子集评价准则

基本步骤

- 在循环的每一轮随机产生一个特征子集
- 在随机产生的特征子集上通过交叉验证推断当前特征子集的误差
- 进行多次循环，在多个随机产生的特征子集中选择误差最小的特征子集作为最终解*

*若有运行时间限制，则该算法有可能给不出解

四、特征选择方法

LVW算法

- 采用随机策略搜索特征子集，而每次特征子集的评价都需要训练学习器，开销很大
- 若初始特征数很多，迭代次数 T 设置较大，算法可能运行很长时间都达不到停止条件

四、特征选择方法

LVW算法

- 需要通过交叉验证来评估学习器的误差
- 并且，误差只考虑特征子集 A' 上的误差
- 若它比当前 A^* 上误差更小，或误差相当但 A' 上包含特征更少，则保留 A'
- 子集搜索策略是随机搜索
- 每次子集都需要评价学习器，开销很大
- 需要终止条件

输入：数据集 D ;
特征集 A ;
学习算法 $\mathcal{L}$;
停止条件控制参数 T .

过程:

```
1:  $E = \infty$ ;  
2:  $d = |A|$ ;  
3:  $A^* = A$ ;  
4:  $t = 0$ ;  
5: while  $t < T$  do  
6:   随机产生特征子集  $A'$ ;  
7:    $d' = |A'|$ ;  
8:    $E' = \text{CrossValidation}(\mathcal{L}(D^{A'}))$ ;  
9:   if  $(E' < E) \vee ((E' = E) \wedge (d' < d))$  then  
10:     $t = 0$ ;  
11:     $E = E'$ ;  
12:     $d = d'$ ;  
13:     $A^* = A'$   
14:   else  
15:     $t = t + 1$   
16:   end if  
17: end while  
输出：特征子集  $A^*$ 
```

图 11.1 LVW 算法描述

四、特征选择方法

嵌入式选择

常见的特征选择方法大致分为如下三类：

- 过滤式
 - 包裹式
 - 嵌入式
- 特征选择过程与学习器训练过程有明显的分别
- 将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，即在学习器训练过程中自动地进行了特征选择

四、特征选择方法

嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，在学习器训练过程中自动地进行特征选择

- 考虑最简单的线性回归模型，以平方误差为损失函数，并引入 L_2 范数正则化项防止过拟合，则有

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2$$

岭回归 (ridge regression)
[Tikhonov and Arsenin, 1977]

- 将 L_2 范数替换为 L_1 范数，则有**LASSO** [Tibshirani, 1996]


$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_1$$

易获得稀疏解，是一种嵌入式特征选择方法

Z. Zhang, Y. Xu, J. Yang, X. Li, D. Zhang, A Survey of Sparse Representation: Algorithms and Applications, IEEE Access, vol. 3, pp. 490-530, 2015. (ESI高被引，被引用1300多次)

四、特征选择方法

使用 L_1 范数正则化易获得稀疏解



假设 x 仅有两个属性, 那么 w 有两个分量 w_1 和 w_2 . 那么目标优化的解要在平方误差项与正则化项之间折中, 即出现在图中平方误差项等值线与正则化等值线相交处.

从图中看出, 采用 L_1 范数时交点常出现在坐标轴上, 即产生 w_1 或者 w_2 为0的稀疏解.

等值线即取值相同的点的连线

四、特征选择方法

稀疏表示和字典学习

我们将数据集化成一个矩阵，每行为样本，每列为特征，通过整行整列为0，我们可以筛选特征，但是我们来考虑另一种稀疏性，即不是每行每列为0，稀疏表达。

例如，文本数据具有高度稀疏性而线性可分，且有着高效的存储解决方案。为普通稠密表示的样本通过寻求合适的字典而找到一个合适的稀疏表示形式的过程就叫做字典学习，或者稀疏编码。

这二者稍有不同，前者侧重于学习字典，后者侧重于稀疏表示。给定数据集，字典学习最简单的形式为：
重构+稀疏

$$\min_{B, \alpha_i} \sum_{i=1}^m \|x_i - B\alpha_i\|^2 + \lambda \sum_{i=1}^m \|\alpha_i\|_1$$

四、特征选择方法

求解可以采用变量交替优化的方式：

$$\min_{B, \alpha_i} \sum_{i=1}^m \|x_i - B\alpha_i\|^2 + \lambda \sum_{i=1}^m \|\alpha_i\|_1$$

第一步 固定住字典B，参照LASSO的解法求解：

$$\min_{\alpha_i} \|x_i - B\alpha_i\|_2^2 + \lambda \|\alpha_i\|_1$$

第二步 以 α_i 为初值来更新字典B。以逐行更新的KSVD解法为例，首先将优化目标拆成逐行的：

$$\min_B \|X - BA\|_F^2 \rightarrow \min_{b_i} \|E_i - b_i \alpha^i\|_F^2$$

其中， $E_i = X - \sum_{j \neq i} b_j \alpha^j$ 是固定的，奇异值分解以取得最大奇异值所对应的正交向量。

小结

- 特征选择：
 - 子集搜索与评价
 - 过滤式选择
 - 包裹式选择
 - 嵌入式选择：用 L_2 和 L_1 正则化

作业

- 尝试为LVW设计一个改进算法，即便有运行时间限制，该算法也一定能给出解。
- 请对比三类特征选择方法的优缺点。
- 尝试分析岭回归和稀疏表示的关联关系。
- 第五次作业，截止日期：待定