

# 第10章：回归学习

张正



哈尔滨工业大学（深圳）

[zhengzhang@hit.edu.cn](mailto:zhengzhang@hit.edu.cn)

<http://faculty.hitsz.edu.cn/zhangzheng>

# 引言

---

- 监督学习的两个典型：分类和回归

- 分类 (Classification) -----> 标签离散

- ▣ 身高1.85m，体重100kg的男人穿什么尺码的T-shirt？
- ▣ 根据肿瘤的体积、患者的年龄来判断良性或恶性？


- 回归 (Regression、Prediction)-----> 标签连续或离散

- ▣ 如何预测深圳市南山区大学城周边的房价？
- ▣ 未来哈工大（深圳）招生情况的走向？

# 引言

## 线性回归

- 通过属性的线性组合来进行预测的**线性模型**
- **目的**是找到一条直线或者一个平面或者更高维的超平面，使得**预测值与真实值之间的误差最小化**



# 本章内容

---

一、回归学习

二、线性回归

三、逻辑回归

四、正则化Regularization

五、Softmax回归

# 一、回归学习

---

- 回归属于有监督学习中的一种方法。该方法的**核心思想**是从连续型统计数据中得到数学模型，然后将该数学模型用于**预测**或者**分类**。该方法处理的数据可以是多维的。
- 回归是由达尔文的表兄弟Francis Galton发明的。Galton于1877年完成了第一次回归预测，目的是根据上一代豌豆的种子（双亲）的尺寸来预测下一代豌豆种子（孩子）的尺寸（身高）。
- Galton在**大量对象**上应用了回归分析，甚至包括人的身高。他得到的结论是：如果双亲的高度比平均高度高，他们的子女也倾向于平均身高但尚不及双亲，这里就可以表述为：孩子的身高向着平均身高回归。Galton在多项研究上都注意到了这一点，并将此研究方法称为**回归**。

# 一、回归学习


## 问题引入

假设一个房屋销售的数据如下：

| 面积( $m^2$ ) | 销售价钱(万元) |
|-------------|----------|
| 123         | 250      |
| 150         | 320      |
| 87          | 160      |
| 102         | 220      |
| ...         | ...      |

如果来了一个新的面积，假设在销售价钱的记录中没有的，怎么处理？

- 解决方法：用一条曲线去尽量准的拟合这些数据，然后如果有新的输入过来，我们可以在将曲线上这个点对应的值返回。
- 如果用一条直线去拟合，可能是下面的样子：



# 一、回归学习

- 常用概念和符号：


- 房屋销售记录表：训练集(training set)或者训练数据(training data)，是我们流程中的输入数据，一般称为  $x$
- 房屋销售价钱：输出数据，一般称为  $y$
- 拟合函数（或称为假设或者模型）：一般写做  $y=h(x)$
- 训练数据的条目数(#training set)：一条训练数据是由一对输入数据和输出数据组成，输入数据的维度 $d$ （特征的个数，#features）

- 这个例子的特征是两维的，结果是一维的。然而，回归方法能够解决输入特征多维，结果是一维多离散值或一维连续值的问题。

# 一、回归学习

## ● 学习过程

首先给出一个输入数据，算法通过一系列的过程得到一个估计的函数，这个函数有能力对没有见过的新数据给出一个新的估计，也被称为构建一个模型，例如线性回归函数。



一个典型的机器学习的过程



# 一、回归学习

---

- 线性回归 (Linear regression) 是利用称为线性回归方程的最小平方函数对一个或多个自变量和因变量之间关系进行建模的一种回归分析
- 线性回归属于**监督学习**，因此该方法和监督学习应该是一样的，先给定一个训练集，根据这个训练集学习出一个**线性函数**，然后测试这个函数训练的好坏（即此函数是否足够拟合训练集数据），挑选出最好的函数（cost function最小）即可

## 二、线性回归

- 注意：

(1) 因为是线性回归，所以学习到的函数为**线性函数**，即直线函数


(2) 因为是单变量，因此只有一个 $x$ ；

**单变量线性回归模型：**

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$x$ : feature,  $h(x)$ : hypothesis;

**问题：线性函数拟合的好不好？**



# 一、回归学习

- 我们希望根据房屋的面积（平方英尺）和房龄（年）来估算房屋价格（美元）。
- 开发一个能预测房价的模型，收集真实数据集称为训练数据集或训练集，包括数据样本-标签（目标）。
- 预测所依据自变量（面积和房龄）称为特征或协变量。
  - 线性假设是指目标（房屋价格）可以表示为特征（面积和房龄）的加权和，如下面的式子：
$$\text{price} = w_{\text{area}} \cdot \text{area} + w_{\text{age}} \cdot \text{age} + b.$$
  - 权重决定了每个特征对预测值的影响
  - 没有偏置项，我们模型的表达能力将受到限制
  - 通过加权和 $对特征进行线性变换$ ，偏置项来进行平移

## 二、线性回归

- 线性函数的一般形式

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \dots + w_d x_d + b$$

$\mathbf{x} = [x_1, \dots, x_d]$ 是由属性描述的实例， $x_i$ 是 $\mathbf{x}$ 在第 $i$ 个属性上的取值

- 向量形式  $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$

- 引出三个常用概念

- **损失函数** (Loss function) 度量**单样本预测的错误程度**，损失函数值越小，模型越好。常用的损失函数包括：0-1损失函数、平方损失函数、对数损失函数等。
- **代价函数** (Cost Function) 度量**全部样本集的平均误差**。常用的代价函数包括均方误差、均方根误差、平均绝对误差等。
- **目标函数** (Objective Function) 代价函数和正则化函数，最终是要优化的函数。

## 二、线性回归（经典的模型）

### 单一属性的线性回归

- 给定数据集  $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$ , 其中  $x_i \in \mathbb{R}^d$ ,  $y_i \in \mathbb{R}^c$
- 目标:

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

- 参数/模型估计：最小二乘法(least square method)

$$\begin{aligned}(w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2\end{aligned}$$

- 最小化均方误差

$$E_{(w, b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

## 二、线性回归（经典的模型）

- 分别对  $w$  和  $b$  求导，可得

$$\frac{\partial E(w,b)}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right); \quad \frac{\partial E(w,b)}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

- 得到闭式（closed-form）解

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

其中，

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

## 二、线性回归（经典的模型）

### 多元线性回归

- 给定数据集  $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$ , 其中  $x_i \in \mathbb{R}^d$ ,  $y_i \in \mathbb{R}^c$
- 目标:  $f(x_i) = w^T x_i + b$  使得  $f(x_i) \simeq y_i$
- 把  $w$  和  $b$  吸收入向量形式  $\hat{w} = [w; b]$ , 数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix} \quad \mathbf{y} = (y_1; y_2; \dots; y_m)$$

- 最小二乘法  $\hat{w}^* = \arg \min_{\hat{w}} (\mathbf{y} - \mathbf{X}\hat{w}^T) (\mathbf{y} - \mathbf{X}\hat{w})$


$$E_{\hat{w}} = (\mathbf{y} - \mathbf{X}\hat{w})^T (\mathbf{y} - \mathbf{X}\hat{w}) \Longrightarrow \hat{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

新样本的回归结果:  $f(\hat{x}_i) = \hat{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

## 二、线性回归（经典的模型）

### 对数线性回归

- 输出标记的对数为线性模型逼近的目标



$$\ln y = w^T x + b$$



$$y = w^T x + b$$



## 二、线性回归（例题）

调查某市出租车使用年限和该年支出维修费用(万元)，得到数据如下：

|          |     |     |     |     |     |
|----------|-----|-----|-----|-----|-----|
| 使用年限 (x) | 2   | 3   | 4   | 5   | 6   |
| 维修费用 (y) | 2.2 | 3.8 | 5.5 | 6.5 | 7.0 |

- (1) 求线性回归方程
- (2) 由(1)中结论预测第10年所支出的维修费用
- 解：设使用年限为  $x$ ，维修费用为  $y$ ，列出回归方程  $y = wx + b$

$$\begin{aligned}(w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2\end{aligned}$$

平方损失函数

$$E_{(w, b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

最小化均方误差

## 二、线性回归（例题）

调查某市出租车使用年限和该年支出维修费用(万元)，得到数据如下：

|          |     |     |     |     |     |
|----------|-----|-----|-----|-----|-----|
| 使用年限 (x) | 2   | 3   | 4   | 5   | 6   |
| 维修费用 (y) | 2.2 | 3.8 | 5.5 | 6.5 | 7.0 |

- (1) 求线性回归方程
- (2) 由(1)中结论预测第10年所支出的维修费用

$$E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$  $\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$
$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$
$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

一般解析解

## 二、线性回归（例题）

调查某市出租车使用年限和该年支出维修费用(万元)，得到数据如下：

|          |     |     |     |     |     |
|----------|-----|-----|-----|-----|-----|
| 使用年限 (x) | 2   | 3   | 4   | 5   | 6   |
| 维修费用 (y) | 2.2 | 3.8 | 5.5 | 6.5 | 7.0 |

- (1) 求线性回归方程
- (2) 由(1)中结论预测第10年所支出的维修费用


$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2} \quad b = \frac{1}{m} \sum_{i=1}^m (y_i - w x_i) \quad \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

一般解析解

- 代入计算得： $\begin{pmatrix} w \\ b \end{pmatrix} = \begin{pmatrix} 1.23 \\ 0.08 \end{pmatrix}$ ，回归方程是： $y = 1.23x + 0.08$ 。
- $y|_{x=10} = 1.23 \times 10 + 0.08 = 12.38$

## 二、线性回归

- **代价函数 (Cost Function)**：对假设的函数进行评价，cost function越小的函数，说明拟合训练数据拟合的越好



解释：

例如，存在数据集(1,1)、(2,2)、(3,3)，则

$x=[1;2;3]$ ， $y=[1;2;3]$

如果假设预测函数为  $y=x$ ，则发现cost value=0

如果假设预测函数为  $y=2x$ ，则发现cost value=1

如果假设预测函数为  $y=3x$ ，则发现cost value=2

则我们发现  $y=x$  的cost value最小，因此选择  $y=x$  作为我们的hypothesis

## 二、线性回归

### ● 代价函数 (Cost Function) :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$


其中:

$x^{(i)}$ 表示向量  $x$  中的第  $i$  个元素;

$y^{(i)}$ 表示向量  $y$  中的第  $i$  个元素;

$h_{\theta}(x^{(i)})$ 表示已知的假设函数;

$m$ 为训练集的数量;



例: 给定数据集(1,1)、(2,2)、(3,3)

则  $x = [1;2;3]$ ,  $y = [1;2;3]$

(语法Octave语言, 表示3\*1的矩阵)

□ 如果我们预测 $\theta_0 = 0, \theta_1 = 1$ , 则  $h(x) = x$ , 则 cost function:



$$J(0,1) = \frac{1}{2*3} [(h(1)-1)^2 + (h(2)-2)^2 + (h(3)-3)^2] = 0$$

□ 如果我们预测 $\theta_0 = 0, \theta_1 = 0.5$ , 则  $h(x) = 0.5x$ , 则 cost function:

$$J(0,0.5) = \frac{1}{2*3} [(h(1)-1)^2 + (h(2)-2)^2 + (h(3)-3)^2] = 0.58$$

## 二、线性回归

代价函数与参数的关系：
$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



注意：如果是线性回归，则代价函数  $J$  与  $\theta_0$  和  $\theta_1$  的函数一定是碗状的，即只有一个最小值点；

## 二、线性回归

考虑更一般情况：

$$x^{(i)} \in R^d \quad h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n = \theta X$$

$$\min_{\theta} J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad \text{最小二乘损失函数}$$

求解：

- 最小二乘法  $\theta = (X^T X)^{-1} X^T y \quad X \in R^{m \times (d+1)}$

➤ 是一个直接的数学求解公式，不过它要求  $X$  是列满秩的

- 梯度下降法

## 二、线性回归

---

### 再讲 Gradient Descent（梯度下降）

- 找出代价函数的最小值；

梯度下降原理：将函数比作一座山，我们站在某个山坡上，往四周看，从哪个方向向下走一小步，能够下降的最快；

方法：

- (1) 先确定向下一步的步伐大小，我们称为Learning rate；
- (2) 任意给定一个初始值：  $\theta_0$  ,  $\theta_1$  ；
- (3) 确定一个向下方向，并向下走预先规定的步伐，更新：  $\theta_0$  ,  $\theta_1$ ；
- (4) 当下降的高度小于某个定义的值，则停止下降；



## 二、线性回归

### 梯度下降算法：

repeat until convergence{

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{同时更新 } j=0 \text{ 和 } j=1)$$

}

Learning rate  
决定下降步伐大小

决定下降方向

$$temp0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0)$$

$$temp1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

$$\theta_0 := temp0$$

$$\theta_1 := temp1$$

特点：

(1) 初始点不同，获得的最小值也不同，因此梯度下降求得的只是局部最小值；

(2) 越接近最小值时，下降速度越慢；

## 二、线性回归


### 梯度下降算法的问题

➤ 如果 $\theta_0$   $\theta_1$ 初始值就在local minimum的位置，则 $\theta_0$   $\theta_1$ 会如何变化？

答：因为 $\theta_0$   $\theta_1$ 已经在local minimum位置，所以梯度肯定是0，因此 $\theta_0$   $\theta_1$ 不会变化；

➤ 如果取到一个正确的 $\alpha$ 值，则cost function应该越来越小；那么，怎么取 $\alpha$ 值？

答：随时观察 $\alpha$ 值，如果代价函数变小了，则不修改，反之，则取一个更小值；




从上面的图可以看出：初始点不同，获得的最小值也不同，因此梯度下降求得的只是局部最小值；

## 二、线性回归

**注意：**下降的步伐大小非常重要

因为如果太小，则找到函数最小值的速度就很慢；

如果太大，则可能会出现overshoot the minimum的现象；



**策略：**如果Learning rate取值后，发现目标函数J的值反而增长了，则需要减小Learning rate的值

## 二、线性回归

### Gradient Descent for Linear Regression

梯度下降能够求出一个函数的最小值；

线性回归需要求出最优的解，使得cost function的最小；

因此，我们能够对代价函数运用梯度下降，即将梯度下降和线性回归进行整合，如下所示：

#### 梯度下降算法

Repeat until convergence{

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

for (j=1 and j=0)

}

#### 线性回归

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=-1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Repeat until convergence {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=-1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=-1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) * x^{(i)}$$

}

## 二、线性回归

### 牛顿法

牛顿法的基本思路是，在现有极小点估计值的附近对  $f(x)$  做二阶泰勒展开，进而找到极小点的下一个估计值。假设  $w^k$  为当前的极小值估计值，则

$$\varphi(w) = J(w^k) + J'(w^k)(w - w^k) + \frac{1}{2} J''(w^k)(w - w^k)^2$$

然后，令  $\phi'(w) = 0$ ，得到  $w^{k+1} = w^k - \frac{J'(w^k)}{J''(w^k)}$ 。因此，有迭代解：

$$w^{k+1} = w^k - \frac{J'(w^k)}{J''(w^k)} = w^k - H_k^{-1} \cdot g_k$$

其中， $H$  矩阵称为海森矩阵：

$$H_{mn} = \frac{\partial^2 J(w)}{\partial w_m \partial w_n} = h_w(x^{(i)})(1 - h_w(x^{(i)}))x_m^{(i)}x_n^{(i)}$$

此外，这个方法需要目标函数是二阶连续可微的，本文中的  $J(w)$  是符合要求的。

# 三、逻辑回归

---

- 逻辑回归 (Logistic Regression)

- 逻辑回归的模型是一个非线性模型
- sigmoid函数，又称逻辑回归函数，但是，它本质上又是一个线性回归模型，是一种广义线性回归模型
- 因为除去sigmoid映射函数关系，其他的步骤，算法都是线性回归的
- 可以说，逻辑回归，都是以线性回归为理论支持的
- 只不过，线性模型，无法做到sigmoid的非线性形式，sigmoid可以轻松处理0/1分类问题

# 三、逻辑回归

---

## ● 二分类到多分类问题

- 二分类问题是指预测的 $y$ 值只有两个取值（0或1），二分类问题可以扩展到多分类问题
  - 例如：我们要做一个垃圾邮件过滤系统，是邮件的特征，预测的 $y$ 值就是邮件的类别，是垃圾邮件还是正常邮件
  - 对于类别我们通常称为正类（positive class）和负类（negative class），垃圾邮件的例子中，正类就是正常邮件，负类就是垃圾邮件
- 应用举例
  - 是否垃圾邮件分类？
  - 是否肿瘤、癌症诊断？
  - 是否金融欺诈？


# 三、逻辑回归

## ● Logistic函数

- 如果我们忽略二分类问题中 $y$ 的取值是一个离散的取值（0或1），我们继续使用线性回归来预测 $y$ 的取值。这样做会导致 $y$ 的取值并不为0或1。
- 逻辑回归使用一个函数来归一化 $y$ 值，使 $y$ 的取值在区间(0, 1)内，这个函数称为Logistic函数(Logistic function)，也称为Sigmoid函数(sigmoid function)。函数公式如下：

$$g(z) = \frac{1}{1 + e^{-z}}$$

- Logistic函数当 $z$ 趋近于无穷大时， $g(z)$ 趋近于1；当 $z$ 趋近于无穷小时， $g(z)$ 趋近于0。Logistic函数的图形所示：





### 三、逻辑回归

---


- Sigmoid函数 (sigmoid function) 的性质:

$$\begin{aligned} g'(z) &= \frac{d}{dz} \frac{1}{1 + e^{-z}} \\ &= \frac{1}{(1 + e^{-z})^2} (e^{-z}) \\ &= \frac{1}{(1 + e^{-z})} \cdot \left(1 - \frac{1}{(1 + e^{-z})}\right) \\ &= g(z)(1 - g(z)) \end{aligned}$$

# 三、逻辑回归

## ● 分类问题

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$




线性决策边界

$$-3 + x_1 + x_2 \geq 0$$

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2$$

决策边界



非线性决策边界

$$-1 + 0x_1 + 0x_2 + 1x_1^2 + 1x_2^2 \geq 0$$

### 三、逻辑回归

对于线性边界的情况，边界形式如下：

$$\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n = \sum_{i=1}^n \theta_i x_i = \theta^T x$$


构造预测函数为：
$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

函数 $h_{\theta}(x)$ 的值有特殊的含义，它表示结果取1的概率，因此对于输入 $x$ 分类结果

为类别1和类别0的概率分别为：

$$P(y = 1 | x; \theta) = h_{\theta}(x)$$

$$P(y = 0 | x; \theta) = 1 - h_{\theta}(x)$$




线性决策边界

# 三、逻辑回归

## 如何来构造损失函数 J 呢？

代价函数和J函数如下，它们是**基于极大似然估计**推导得到的，则

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



- 如果  $y = 1$ ,  $h_{\theta}(x) = 1$ , 那么  $\text{Cost} = 0$ ;  
但是, 当  $h_{\theta}(x) \rightarrow 0$  时,  $\text{Cost} \rightarrow \infty$ ;
- Logistic regression 代价函数

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))) \end{aligned}$$

函数  $h_{\theta}(x)$  的值有**特殊的含义**, 它**表示结果取1的概率**

交叉熵度量

# 三、逻辑回归

- 线性函数的一般形式  $f(x) = w^T x + b$
- 常用概念
  - **损失函数** (loss function) 度量**单样本预测的错误程度**，损失函数值越小，模型越好。常用的损失函数包括：0-1损失函数、平方损失函数、对数损失函数等。
  - **代价函数** (Cost Function) 度量**全部样本集的平均误差**。常用的代价函数包括均方误差、均方根误差、平均绝对误差等。
  - **目标函数** (Objective Function) 代价函数和正则化函数，最终是要优化的函数。
- **线性回归常采用均方误差；逻辑回归常采用交叉熵度量**
- 衡量的是我们在知道y的真实值的**平均出乎预料程度**
  - 当输出是我们期望的值，出乎意外的程度比较低
  - 当输出不是我们期望时，出乎意外的程度就比较高

# 三、逻辑回归

## 梯度下降算法：

To fit parameters  $\theta$

$\min_{\theta} J(\theta)$  得到： $\theta$

$\theta$  更新过程

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y(i)] x_j^{(i)}$$

$$\frac{\partial(J(\theta))}{\partial \theta_j}$$

对于任意新的样本  $x$  进行预测：


输出：

$$h_{\theta}(x) = \frac{1}{1 + \mathbf{e}^{-\theta^T x}}$$


## 四、正则化Regularization

### 过拟合问题


对于线性回归或逻辑回归的损失函数构成的模型，可能会有些权重很大，有些权重很小，导致过拟合（就是过分拟合了训练数据），使得模型的复杂度提高，泛化能力较差（对未知数据的预测能力）。



欠拟合



合适拟合



过拟合

## 四、正则化Regularization

---

- 问题的主因：

- 过拟合问题往往源自过多的特征

- 解决方法

- 增加数据 (Scaling Law)
- 减少特征数量 (减少特征会失去一些信息，即使特征选的很好)
  - ▣ 可用人工选择要保留的特征
  - ▣ 模型选择算法
- 正则化 (特征较多时比较有效)
  - ▣ 保留所有特征，但减少  $\theta$  的大小




## 四、正则化Regularization


### ● 正则化方法

- 正则化是结构风险最小化策略的实现，是在经验风险上加一个正则化项或惩罚项
- 正则化项一般是模型复杂度的单调递增函数，模型越复杂，正则化项就越大

### ● 房价预测问题，多项式回归




$$\theta_0 + \theta_1 x + \theta_2 x^2$$




$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

## 四、正则化Regularization



$$\theta_0 + \theta_1 x + \theta_2 x^2$$



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

- 直观来看，如果我们想解决这个例子中的过拟合问题，最好能将  $x^3$  和  $x^4$  的影响消除，也就是让  $\theta_3 \approx 0$ ,  $\theta_4 \approx 0$ 。
- 假设我们对  $\theta_3$  和  $\theta_4$  进行惩罚，并且令其很小，一个简单的办法就是给原有的Cost函数**加上两个略大惩罚项**，例如：

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^n (h_{\theta}(x_i) - y_i)^2 + 1000\theta_3^2 + 1000\theta_4^2$$

这样在最小化cost函数的时候，  $\theta_3 \approx 0$ ,  $\theta_4 \approx 0$ 。

## 四、正则化Regularization

- 正则项可以取不同的形式，在回归问题中取平方损失，就是参数的L2范数，也可以取L1范数。取平方损失时，模型的损失函数变为：

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^n \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n \theta_j^2$$

- $\lambda$  是正则项系数
  - 如果它的值很大，说明对模型的复杂度惩罚大，对拟合数据的损失惩罚小，这样它就不会过分拟合数据
  - 在训练数据上的偏差较大，在未知数据上的方差较小，但是可能出现欠拟合的现象
  - 如果它的值很小，说明比较注重对训练数据的拟合，在训练数据上的偏差会小，但是可能会导致过拟合

## 五、Softmax回归

- 假设预测值 $y$ 有 $k$ 种可能, 即 $y \in \{1, 2, \dots, k\}$ 
  - softmax 回归主要估算输入数据 $x$ 归属于每一类的概率
  - 比如 $k=3$ 时, 可以看作是要将一封未知邮件分为垃圾邮件、个人邮件还是工作邮件这三类

$$p(y = i|x; \theta) = \frac{e^{\eta_i}}{\sum_{j=1}^k e^{\eta_j}} = \frac{e^{\theta_i^T x}}{\sum_{j=1}^k e^{\theta_j^T x}}$$


$$h_{\theta}(x^{(i)}) = \begin{bmatrix} p(y^{(i)} = 1 | x^{(i)}; \theta) \\ p(y^{(i)} = 2 | x^{(i)}; \theta) \\ \vdots \\ p(y^{(i)} = k | x^{(i)}; \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}} \begin{bmatrix} e^{\theta_1^T x^{(i)}} \\ e^{\theta_2^T x^{(i)}} \\ \vdots \\ e^{\theta_k^T x^{(i)}} \end{bmatrix}$$

## 五、Softmax回归

Output Layer (Option)采用softmax层

Probability

$$0 \leq y_i \leq 1; y^T \mathbf{1} = 1$$



中间灰色区域表示一层layer，左边输入，右边输出，整体是softmax层。

## 五、Softmax回归

Softmax回归的目标函数：

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right] + \frac{\lambda}{2} \sum_{i=1}^k \sum_{j=0}^n \theta_{ij}^2$$

参数  $(\theta_1, \theta_2, \dots, \theta_k)$  是  $J(\theta)$  的极小值点：

$$\nabla_{\theta_j} J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ x^{(i)} \left( 1\{y^{(i)} = j\} - p(y^{(i)} = j | x^{(i)}; \theta) \right) \right] + \lambda \theta_j$$

$\theta$  更新过程


$$\theta_j := \theta_j - \alpha \nabla_{\theta_j} J(\theta) \text{ (对每个 } j=1, 2, \dots, k \text{)}$$

$1\{\cdot\}$  是示性函数，即  $1\{\text{值为真}\}=1$ ， $1\{\text{值为假}\}=0$

$1\{y=k\}$  表示当  $y=k$  的时候， $1\{y=k\}=1$ ； $1\{y \neq k\}=0$

## 六、从线性回归到深度网络


- 尽管神经网络涵盖了更多更为丰富的模型，我们依然可以用描述神经网络的方式来描述线性模型，从而把线性模型看作一个神经网络。
  - 首先，我们用“层”符号来重写这个模型。
  - 绘制图表来可视化模型，即全连接层或称为稠密层



线性回归是一个单层的神经网络

## 六、线性回归与计算神经科学

- 线性回归发明的时间（1795年）早于计算神经科学，所以将线性回归描述为神经网络似乎不合适。
- 当控制学家、神经生物学家沃伦·麦库洛奇和沃尔特·皮茨开始开发神经元模型时，为什么将线性模型作为一个起点呢？
  - 由树突(输入终端)、细胞核(nucleus)组成的生物神经元图
  - 轴突(axon, 输出线)和轴突端子(axon terminal, 输出端子) 通过突触(synapse)与其他神经元连接。





## 六、线性回归与计算神经科学

- 线性回归发明的时间（1795年）早于计算神经科学，所以将线性回归描述为神经网络似乎不合适。
- 当控制学家、神经生物学家沃伦·麦库洛奇和沃尔特·皮茨开始开发神经元模型时，为什么将线性模型作为一个起点呢？
  - 树突中接收到来自其他神经元（或视网膜等环境传感器）的信息 $x_i$ 。该信息通过突触权重 $w_i$ 来加权，以确定输入的影响（即，通过 $w_i x_i$ 相乘来激活或抑制）。
  - 来自多个源的加权输入以加权和的形式汇聚在细胞核中，然后将这些信息发送到轴突  $y$  中进一步处理，通常会通过激活函数 $\sigma(y)$ 进行一些非线性处理。
  - 之后，它要么到达目的地（例如肌肉），要么通过树突进入另一个神经元。

# 小结

---

- 回归学习的基本概念

- 线性回归

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- 逻辑回归

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})))$$

- 正则化方法

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2$$


- Softmax回归

$$p(y = i | \mathbf{x}; \theta) = \frac{e^{\eta_i}}{\sum_{j=1}^k e^{\eta_j}} = \frac{e^{\theta_i^T \mathbf{x}}}{\sum_{j=1}^k e^{\theta_j^T \mathbf{x}}}$$

# 常用的回归分析模型

## (1) 线性回归


- 定义：通过**线性组合**来说明自变量和因变量之间的关系。这种关系的强弱程度，利用自变量的线性组合可以预测因变量的能力大小。
- 适用场景：当自变量和因变量之间存在**线性关系**时，或需要对结果的影响有明确解释时。
- 举例：在临床试验中，可以使用线性回归来研究血压与年龄、降压药剂量之间的关系。



# 常用的回归分析模型

## (2) 多重线性回归


- 定义：又称为多因素线性回归，研究一个因变量与多个自变量之间的数量依存关系。
- 适用场景：当因变量是连续的数值时，或多个自变量之间存在高度相关时。
- 举例：可以运用多重线性回归来研究吸烟、CA（癌症）、固位方式、性别、年龄等多个因素中，究竟哪些因素对骨吸收产生显著影响。



# 常用的回归分析模型

## (3) 套索回归 (Lasso Regression)


- 定义：通过引入L1正则化项（即变量系数的绝对值之和）来实现变量选择和参数压缩，达到防止模型的过度拟合，并控制模型的复杂度，提高模型的泛化能力。
- 适用场景：通常适用于需要进行特征选择的场景，或者特征数量多于样本数量的情况下。
- 举例：研究从心衰患者的性别、年龄等自变量中筛选特征变量，探究其与心力衰竭严重程度之间的关系。



# 常用的回归分析模型

## (4) Cox回归


- 定义：一种半参数回归模型，主要用于分析生存时间数据。以生存结局（如事件发生或未发生）和生存时间作为因变量，可以同时考虑多个因素对生存时间的影响。
- 适用场景：当处理连续性数据时。
- 举例：研究患者的生存时间以及与生存时间相关的预测因素。



# 常用的回归分析模型

## (5) 岭回归

- 定义：一种线性回归的改进方法，通过引入L2正则化项来避免过拟合，处理共线性问题。
- 适用场景：当数据存在多重共线性，且不希望模型系数缩减到零时。
- 举例：基因表达数据的分析，筛选重要基因。




(b) Ridge regression

# 常用的回归分析模型

## (6) 逐步回归(stepwise Reg)

- 定义：一种通过系统地**添加或删除自变量**来建立最优的多元线性回归模型。
- 适用场景：当处理**高维数据**时，或需要**建立时间序列预测模型**，预测未来的趋势和变化时。
- 举例：用来识别与癌症患者预后（如生存率）相关的生物学标志物。






# 常用的回归分析模型

## (7) 逻辑回归


- 定义：用于**预测二元结果**的回归方法，根据给定的自变量数据集来估计事件的发生概率，因变量的范围在0和1之间。
- 适用场景：用于处理**二分类**问题，如疾病的发生概率、患者的生存率等。
- 举例：预测患者是否患有某种疾病。



# 常用的回归分析模型

## (8) 弹性网络回归


- 定义：结合了岭回归和套索回归的优点，通过同时使用L1和L2正则化项，处理高维数据和多重共线性问题。
- 适用场景：当数据既存在多重共线性又希望进行特征选择时。
- 举例：根据患者的年龄、性别、肿瘤类型、基因表达水平以及临床特征等数据，研究肿瘤标志物与患者预后之间的关系。



# 常用的回归分析模型

## (9) 决策树回归


- 定义：一种基于**树结构的预测模型**，通过递归地将数据集分割成子集，直到满足某些停止条件（如最小数据点数或最大深度）。
- 适用场景：当数据具有复杂的非线性关系或需要自动进行特征选择时。
- 举例：建立一个决策树模型，用来研究银屑病病患者治疗效果的影响因素。



# 常用的回归分析模型

## (10) 随机森林回归


- 定义：一种通过构建多个决策树并结合它们的预测结果来提高预测精度和稳定性的回归模型。
- 适用场景：处理高维数据、处理缺失值、防止过拟合。
- 举例：基于多个基因的表达数据预测药物反应。



# 常用的回归分析模型

## (11) 支持向量回归


- 定义：通过在特征空间中构建一个超平面来最小化预测误差，同时最大化超平面与数据点之间的间隔。
- 适用场景：当数据具有高维特征，且需要模型对异常值不敏感时。
- 举例：通过与DNA序列特征、蛋白质序列特征等结合，实现高效的基因分类。



# 常用的回归分析模型

## (12) 梯度提升回归


- 定义：通过逐步构建多个**弱学习器**（如决策树），并根据前一轮的预测误差调整后续学习器的权重来改进模型。
- 适用场景：处理非线性数据、处理异常值、处理缺失值。
- 举例：基于基因表达数据预测癌症预后。



# 常用的回归分析模型

## (13) XGBoost回归


- 定义：一种高效的**梯度提升决策树算法**，通过引入正则化项和收缩策略来防止过拟合，并支持分布式计算。
- 适用场景：当处理复杂的、非线性的数据情况时。
- 举例：通过分析患者的基因信息以及其他关键特征，来预测某种药物对患者的治疗效果。



# 常用的回归分析模型

## (14) 神经网络回归

- 定义：使用多层神经网络进行回归预测，通过反向传播算法优化模型参数。
- 适用场景：处理非线性关系、处理复杂数据模式、处理图像和文本数据。
- 举例：用于预测小分子药物的活性，毒性和药代动力学特性。





# 常用的回归分析模型

## (15) K最近邻回归

- 定义：基于**样本之间的相似性**（如欧氏距离）进行回归预测，预测值为最近邻样本的响应变量的平均值或加权平均值。
- 适用场景：当数据的**局部结构**对预测结果很重要时，例如空间数据或时间序列数据。
- 举例：根据图像中细胞核的特性，包括半径、纹理等数据，判断肿瘤是否为良性。

