

第12章：深度学习概述

张正




哈尔滨工业大学（深圳）


zhengzhang@hit.edu.cn

<http://faculty.hitsz.edu.cn/zhangzheng>

重要的期刊



First published in January 1979
Tse-Yun Feng, President
King-Sun Fu, EiC




First published in January 1968
Robert Ledley

人工智能与机器学习

世界主要国家把人工智能提升到国家战略高度

- 美国：注重科技领先优势
- 欧洲：注重安全、隐私等
- 日本：注重智能改变社会
- 中国：注重智能提升产业



人工智能与机器学习

2017年7月，国务院印发了《**新一代人工智能发展规划**》，规划提出了面向2030年我国新一代人工智能发展的指导思想、战略目标、重点任务

2017年12月，工业和信息化部印发了《**促进新一代人工智能产业发展三年行动计划（2018-2020年）**》，以新一代人工智能技术的产业化和集成应用为重点，加快制造强国和网络强国建设

2018年4月，教育部印发了《**高等学校人工智能创新行动计划**》，提出高校要不断推动人工智能与实体经济深度融合，鼓励建立人工智能学院/研究院，多种方式开展高层次人才培养

机器学习的流派之争

符号主义者



起源：逻辑学、哲学 | 核心思想：认知即计算，符号的演绎和逆演绎
问题：知识结构 | 代表算法：逆演绎算法，决策树
应用：知识图谱 | 代表人物是：Tom Mitchell, Steve Muggleton, Ross Quinlan



联结主义者



起源：神经科学 | 核心思想：对大脑进行仿真
问题：信度分配 | 代表算法：BP、深度学习
应用：CV、SR | 代表人物是：Bengio, Hinton, LeCun



进化主义



起源：进化生物学 | 核心思想：进化模拟，遗传算法和遗传编程
问题：结构发现 | 代表算法：基因编程（Genetic programming）
应用：海星机器人 | 代表人物：John Koda、John Holland、Hod Lipson



贝叶斯派




起源：统计学 | 核心思想：概率估计，概率修正，最优决策
问题：不确定性 | 代表算法：概率推理（贝叶斯，马尔科夫）
应用：概率预测 | 代表人物：David Heckerman, Judea Pearl, Michael Jordan



行为类比主义



起源：心理学 | 核心思想：新旧知识间的相似性
问题：相似性 | 代表算法：核机器、近邻算法
应用：Netflix推荐系统 | 代表人物：Peter Hart, Vladimir Vapnik, Douglas Hofstadter




人工智能与机器学习

A Visual History of AI




AI Winter Years

人工智能与机器学习



人工智能与机器学习



引言

机器学习 = 表征学习 + 目标 + 优化



输入数据




表征学习



机器学习
系统



特征提取




分类器



汽车
非汽车

传统机器学习框架




特征学习+分类器



汽车
非汽车

深度学习框架



本章内容

一、背景知识

二、计算机视觉概述

三、卷积神经网络概述

四、循环神经网络概述

五、Transformer

一、背景知识

ImageNet: (Fei-Fei Li等 2007年创造)

- (1) 1000类, 100多万张 (2009年的规模)
- (2) 图片大小: 正常图片大小, 像素几百*几百
- (3) WORDNET结构, 拥有多个Node (节点)。一个node (目前) 含有至少500个对应物体的可供训练的图片/图像。

IMAGENET

14,197,122 images, 21841 synsets indexed

[Explore](#) [Download](#) [Challenges](#) [Publications](#) [CoolStuff](#) [About](#)

Not logged in. [Login](#) | [Signup](#)

ImageNet is an image database organized according to the WordNet hierarchy (currently only the nouns), in which each node of the hierarchy is depicted by hundreds and thousands of images. Currently we have an average of over five hundred images per node. We hope ImageNet will become a useful resource for researchers, educators, students and all of you who share our passion for pictures.


[Click here](#) to learn more about ImageNet, [Click here](#) to join the ImageNet mailing list.



What do these images have in common? Find out!


三剑客

- Bag Of Features
- Fisher Vector
- VLDB: vector of locally aggregated descriptors




一、背景知识

深度神经网络在ImageNet挑战赛上的分类错误率表现一览表



Perception-LeNet-5-AlexNet-NIN-Inception-ResNet

一、背景知识



Geoffrey Hinton



Yann LeCun



Yoshua Bengio

深度学习三剑客的坚持


LeCun: “这种算法很有价值，不知为什么要放弃它。”

Hinton: “智能产生于人脑，所以从长远来说，人工智能应该像大脑系统一样工作。”



这三人从2003年开始，一起组成了“Deep learning conspiracy”，悄悄开发了10层以上的人工神经网络。

一、背景知识

2006年是深度学习的起始年，Hinton在SCIENCE上发文，提出一种叫做自动编码器（Auto-encoder）的方法，部分解决了神经网络参数初始化的问题。



一、背景知识



一、背景知识

REVIEW

doi:10.1038/nature14539

Deep learning

Yann LeCun^{1,2}, Yoshua Bengio³ & Geoffrey Hinton^{4,5}

Yann LeCun, Yoshua Bengio & Geoffrey Hinton, Review Article, **Deep learning, Nature, volume 521, pages 436–444, 2015.**

Deep learning allows computational models that are composed of multiple processing layers to learn representations of data with multiple levels of abstraction. These methods have dramatically improved the state-of-the-art in speech recognition, visual object recognition, object detection and many other domains such as drug discovery and genomics. Deep learning discovers intricate structure in large data sets by using the backpropagation algorithm to indicate how a machine should change its internal parameters that are used to compute the representation in each layer from the representation in the previous layer. Deep convolutional nets have brought about breakthroughs in processing images, video, speech and audio, whereas recurrent nets have shone light on sequential data such as text and speech.

Machine-learning technology powers many aspects of modern society: from web searches to content filtering on social networks to recommendations on e-commerce websites, and it is increasingly present in consumer products such as cameras and smartphones. Machine-learning systems are used to identify objects in images, transcribe speech into text, match news items, posts or products with users' interests, and select relevant results of search. Increasingly, these applications make use of a class of techniques called deep learning.

Conventional machine-learning techniques were limited in their ability to process natural data in their raw form. For decades, constructing a pattern-recognition or machine-learning system required careful engineering and considerable domain expertise to design a feature extractor that transformed the raw data (such as the pixel values of an image) into a suitable internal representation or feature vector from which the learning subsystem, often a classifier, could detect or classify patterns in the input.

Representation learning is a set of methods that allows a machine to be fed with raw data and to automatically discover the representations needed for detection or classification. Deep-learning methods are representation-learning methods with multiple levels of representation, obtained by composing simple but non-linear modules that each transform the representation at one level (starting with the raw input) into a representation at a higher, slightly more abstract level. With the composition of enough such transformations, very complex functions can be learned. For classification tasks, higher layers of representation amplify aspects of the input that are important for discrimination and suppress irrelevant variations. An image, for example, comes in the form of an array of pixel values, and the learned features in the first

intricate structures in high-dimensional data and is therefore applicable to many domains of science, business and government. In addition to beating records in image recognition^{1–4} and speech recognition^{5–7}, it has beaten other machine-learning techniques at predicting the activity of potential drug molecules⁸, analysing particle accelerator data^{9,10}, reconstructing brain circuits¹¹, and predicting the effects of mutations in non-coding DNA on gene expression and disease^{12,13}. Perhaps more surprisingly, deep learning has produced extremely promising results for various tasks in natural language understanding¹⁴, particularly topic classification, sentiment analysis, question answering¹⁵ and language translation^{16,17}.

We think that deep learning will have many more successes in the near future because it requires very little engineering by hand, so it can easily take advantage of increases in the amount of available computation and data. New learning algorithms and architectures that are currently being developed for deep neural networks will only accelerate this progress.

Supervised learning

The most common form of machine learning, deep or not, is supervised learning. Imagine that we want to build a system that can classify images as containing, say, a house, a car, a person or a pet. We first collect a large data set of images of houses, cars, people and pets, each labelled with its category. During training, the machine is shown an image and produces an output in the form of a vector of scores, one for each category. We want the desired category to have the highest score of all categories, but this is unlikely to happen before training. We compute an objective function that measures the error (or distance) between the output scores and the desired pattern of scores. The

二、计算视觉概述

- 图像分类
- 目标检测
- 图像分割
- 目标跟踪
- OCR文字识别
- 图像滤波与降噪
- 图像增强
- 风格迁移
- 三维重建
- 图像检索
- GAN



图像获取

提取二维图像、三维图组、图像序列或相关的物理数据，如声波、电磁波或核磁共振的深度、吸收度或反射度



预处理

对图像做一种或一些预处理，使图像满足后继处理的要求，如：二次取样保证图像坐标的正确，平滑、去噪等



特征提取

从图像中提取各种复杂度的特征，如：线，边缘提取和脊侦测，边角检测、斑点检测等局部化的特征点检测



检测/分割

对图像进行分割，提取有价值的内容，用于后继处理，如：筛选特征点，分割含有特定目标的部分



高级处理

验证得到的数据是否匹配前提要求，估测特定系数，对目标进行分类

二、计算视觉概述

- 图像分类任务为先锋




二、计算视觉概述

- 目标检测任务为中流砥柱

one-stage(YOLO,YOLO9000,YOLOV3,YOLOV4, YOLOV5, SSD等)

two-stage(OverFeat, R-CNN, Fast R-CNN, Faster R-CNN 等)



目标检测结合了目标分类和定位两个任务

二、计算视觉概述

● 目标检测任务为中流砥柱





Figure 2. An overview of CentripetalNet. As the corner prediction and feature adaption of top-left corner and bottom-right corner are similar, we only draw top-left corner module for simplicity. Centripetal shift module gets predicted corners and adapted features, then it predicts the centripetal shift of each corner and performs corner matching based on the predicted corners and centripetal shifts. During matching, if the positions of the shifted corners are close enough, they form a bounding box with a high score.




Figure 5: Illustration of the detection results on the target domain. First and second rows: Cityscapes $\rightarrow$ Foggy-Cityscapes. Third and fourth rows: Sim10K $\rightarrow$ Cityscapes. Best view in color.

二、计算视觉概述



- 目标检测任务为中流砥柱

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$





二、计算视觉概述

- 视觉分割任务为研究热点




二、计算视觉概述

● 目标跟踪任务为应用



b.




f.

Figure 2. The overall view of Flow-Fuse-Tracker (FFT) for multiple object tracking. FlowTracker and FuseTracker (in bold grey boxes) are the two DNN modules of our FFT network. In the FlowTracker, the optical flow is generated from two sequential frames, and the target bboxes $\{b_{t-1}^k\}$ (green dashed bboxes) at frame $t-1$ are regressed to the bboxes $\{b_t^k\}$ at frame t through the optical flow. In the FuseTracker, the bboxes from both $\{b_t^k\}$ and public detections D_t (red bboxes) at frame t are refined and fused. The FuseTracker outputs the final tracking results (green bboxes with shadow). (Best viewed in color)



二、计算视觉概述

- 图像的数字表示




一张图片数据量是 $64 \times 64 \times 3$ ，因为每张图片都有3个颜色通道。
如果计算一下的话，可得知数据量为12288

三、卷积神经网络概述



进行卷积计算，处理大量特征


三、卷积神经网络概述




- CNN的核心思想是通过局部感受野和权值共享来实现对图像的高效处理。
- 这一设计受到生物视觉系统的启发，模仿人类视觉神经元对视觉信息的处理方式。
- CNN主要包括卷积层、池化层和全连接层。
- 卷积层用于提取图像的局部特征，池化层用于降低特征的空间维度，全连接层用于实现特征的高级抽象和分类任务。

三、卷积神经网络概述

浅层学到的特征为简单的边缘、角点、纹理、几何形状、表面等




深层学到的特征则更为复杂抽象，为狗、人脸、键盘等等



三、卷积神经网络概述

边缘检测


神经网络的前几层是通常检测边缘的，然后，后面的层有可能检测到物体的部分区域，更靠后的一些层可能检测到完整的物体



Vertical edge detection

3 ¹	0 ⁰	1 ⁻¹	2	7	4
1 ¹	5 ⁰	8 ⁻¹	9	3	1
2 ¹	7 ⁰	2 ⁻¹	5	1	3
0	1	3	1	7	8
4	2	1	6	2	8
2	4	5	2	3	9

6x6




$$\begin{bmatrix} 3 \times 1 & 0 \times 0 & 1 \times (1) \\ 1 \times 1 & 5 \times 0 & 8 \times (-1) \\ 2 \times 1 & 7 \times 0 & 2 \times (-1) \end{bmatrix} = \begin{bmatrix} 3 & 0 & -1 \\ 1 & 0 & -8 \\ 2 & 0 & -2 \end{bmatrix}$$

$$3 + 1 + 2 + 0 + 0 + 0 + (-1) + (-8) + (-2) = -5$$

三、卷积神经网络概述

卷积步长 S



三、卷积神经网络概述


Padding p { **Other** same卷积
0 Valid卷积

卷积操作之前**填充**这幅图像

卷积步长 s

图像尺寸 n

Strided convolution



$$n = 7, p = 0, f = 3, s = 2, \frac{7+0-3}{2} + 1 = 3$$

三、卷积神经网络概述

Input Volume (+pad 1) (7x7x3) Filter W0 (3x3x3)

$x[:, :, 0]$	0	0	0	0	0	0	0
	0	1	0	1	0	1	0
	0	1	2	2	2	2	0

$w0[:, :, 0]$	1	1	-1
	-1	0	-1
	1	0	0

	0	2	1	0	2	1	0
	0	0	1	2	1	2	0
	0	1	1	0	1	2	0
	0	0	0	0	0	0	0

$w0[:, :, 1]$	-1	-1	-1
	-1	0	-1
	1	1	1

$x[:, :, 1]$	0	0	0	0	0	0	0
	0	0	0	2	2	1	0
	0	2	2	0	1	0	0
	0	0	2	0	1	1	0
	0	0	2	1	0	0	0
	0	2	0	2	2	0	0
	0	0	0	0	0	0	0

$w0[:, :, 2]$	-1	-1	-1
	-1	0	1
	1	-1	1

Bias $b0$ (1x1x1)
$b0[:, :, 0]$
1

$x[:, :, 2]$	0	0	0	0	0	0	0
	0	1	2	2	2	1	0
	0	0	1	1	0	1	0
	0	1	1	0	0	0	0
	0	1	2	0	1	1	0
	0	2	1	0	1	0	0
	0	0	0	0	0	0	0

Filter W1 (3x3x3)

$w1[:, :, 0]$	0	0	1
	1	1	-1
	0	-1	-1

$w1[:, :, 1]$	0	1	0
	-1	0	-1
	1	1	1

$w1[:, :, 2]$	0	1	1
	-1	0	1
	0	-1	1

Bias $b1$ (1x1x1)
$b1[:, :, 0]$
0

Output Volume (3x3x2)

$o[:, :, 0]$	8	4	-1
	-4	-2	1
	-5	-7	-2

$o[:, :, 1]$	5	-3	-5
	7	-1	0
	5	1	1

$$8=0+4+3+1$$

0	0	0
0	1	0
0	1	2

1	1	-1
-1	0	-1
1	0	0

$$=0$$

0	0	0
0	0	0
0	2	2

-1	-1	-1
-1	0	-1
1	1	1

$$=4$$

0	0	0
0	1	2
0	0	1

-1	-1	-1
-1	0	1
1	-1	1



$$=3$$

$$=8$$

Bias $b0$ (1x1x1)
$b0[:, :, 0]$
1

$$=1$$


三、卷积神经网络概述




最大池化的输入就是 $n_H \times n_W \times n_c$ ，假设没有padding，则输出 $\lfloor \frac{n_H - f}{s} + 1 \rfloor \times \lfloor \frac{n_W - f}{s} + 1 \rfloor \times n_c$

平均池化不常用


三、卷积神经网络概述



	激活维度	激活尺寸	参数个数
输入	(32,32,3)	3072	0
CONV1 (f=5, s=1, 6filter)	(28,28,6)	6272	$156=(5 \times 5+1) \times 6$
POOL1	(14,14,6)	1568	0
CONV2 (f=5, s=1, 16filter)	(10,10,16)	1600	$416=(5 \times 5+1) \times 16$
POOL2	(5,5,16)	400	0
FC3	(120,1)	120	$48,001=400 \times 120+1$
FC4	(84,1)	84	$10,081=120 \times 84+1$
Softmax	(10,1)	10	$841=84 \times 10+1$



三、卷积神经网络概述



参数个数计算:

第1层(convolutional layer): $(5*5+1)*6=156$

第2层(subsampling layer): 0

第3层(convolutional layer): $(5*5*6+1)*16=2416$

第4层(subsampling layer): 0




第5层(fully connected layer): $(5*5*16+1)*120=48120$

第6层(fully connected layer): $(120+1)*84=10164$

第7层(fully connected layer): $(84+1)*10=850$

参数总数: 61, 706

三、卷积神经网络概述



三、卷积神经网络概述

- 卷积网络的核心思想

- 将局部感受野、权值共享以及时间或空间采样这三种结构思想结合起来获得了某种程度的位移、尺度、形变不变性

- 层间联系和空域信息的紧密关系，使其适于图像处理和理解


- 图像和网络的拓扑结构能很好的吻合

- 避免了显式的特征抽取，而隐式地从训练数据中进行学习

- 特征提取和模式分类同时进行，并同时在训练中产生
- 权重共享可以减少网络的训练参数，使神经网络结构变得更简单，适应性更强


四、循环神经网络概述

- RNN是在自然语言处理领域中最先被用起来的，用来为语言模型建模(Jordan, 80年代末)
 - 比如，我们可以和电脑玩一个游戏，我们写出一个句子前面的一些词，然后，让电脑帮我们写下接下来的一个词。比如下面这句：
 - ✓ 我 昨天 上学 迟到 了 ， 老师 批评 了 ____。
 - ✓ 预测接下来最有可能的一个词是什么
 - ✓ RNN & n-gram
 - RNN理论上可以往前看(往后看)任意多个词



四、循环神经网络概述

- Hidden Layer会有连向下一时间Hidden Layer的边，权为 W
 - x 是输入向量
 - s 隐藏层的值向量
 - ✓ 其实是多个节点，节点数与向量 s 的维度相同
 - U 是输入层到隐藏层的权重矩阵
 - O 输出层向量
 - V 是隐藏层到输出层的权重矩阵
 - s_t 取决于 x_t, s_{t-1}
 - ✓ 权重矩阵 W 就是隐藏层上一次的值作为这一次的输入的权重。



四、循环神经网络概述

● RNN神经元表示

$$o_t = g(Vs_t)$$

$$s_t = f(Ux_t + Ws_{t-1})$$

$$o_t = g(Vs_t)$$

$$= Vf(Ux_t + Ws_{t-1})$$

$$= Vf(Ux_t + Wf(Ux_{t-1} + Ws_{t-2}))$$

$$= Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Ws_{t-3})))$$


$$= Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Wf(Ux_{t-3} + \dots))))$$

$$\begin{bmatrix} s_1^t \\ s_2^t \\ \vdots \\ s_n^t \end{bmatrix} = f\left(\begin{bmatrix} u_{11} & u_{12} & \dots & u_{1m} \\ u_{21} & u_{22} & \dots & u_{2m} \\ & & \ddots & \\ & & & \\ u_{n1} & u_{n2} & \dots & u_{nm} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} + \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & w_{2n} \\ & & \ddots & \\ & & & \\ w_{n1} & w_{n2} & \dots & w_{nn} \end{bmatrix} \begin{bmatrix} s_1^{t-1} \\ s_2^{t-1} \\ \vdots \\ s_n^{t-1} \end{bmatrix} \right)$$

四、循环神经网络概述


一般来说，RNN每一时间的输入和输出是不一样的

- 例，序列学习：将序列项依次传入，每个序列项再对应不同的输出




四、循环神经网络概述

- 堆叠两个以上的隐藏层，这样就得到了深度循环神经网络




四、循环神经网络概述

- 长短时记忆网络（LSTM）的解决思路：原始RNN的隐藏层只有一个状态，即 h ，它对于短期的输入非常敏感。那么，假如我们再增加一个状态，即 c ，让它来保存长期的状态，那么问题就解决了：
 - Hochreiter & Schmidhuber (1997)



四、循环神经网络概述

- 新增加的状态 c ，称为单元状态(cell state)。按照时间维度展开：




- 在 t 时刻，LSTM的输入有三个：当前时刻网络的输入值 x_t 、上一时刻LSTM的输出值 h_{t-1} 、以及上一时刻的单元状态 c_{t-1}
- LSTM的输出有两个：当前时刻LSTM输出值 h_t 和当前时刻的单元状态 c_t

四、循环神经网络概述


- 控制长期状态 c ，使用三个控制开关

- 第一个开关，负责控制继续保存长期状态 c
- 第二个开关，负责控制把即时状态输入到长期状态 c
- 第三个开关，负责控制是否把长期状态 c 作为当前的LSTM的输出。



- 长短时记忆网络的前向计算


- 最终输出，由输出门和单元状态共同确定



五、Transformer概述

为什么需要用Transformer


在没有Transformer的时候，我们都是用什么来完成这系列的任务的呢？



- 其实在之前我们使用的是RNN（或者是其的单向或者双向变种LSTM/GRU等）来作为编解码器。
- RNN模块每次只能够吃进一个输入token和前一次的隐藏状态，然后得到输出。
- 它的时序结构使得这个模型能够得到长距离的依赖关系，但是这也使得它**不能够并行计算**，模型效率十分低。

五、Transformer概述


- Seq2Seq 任务指的是输入和输出都是序列的任务，输出的长度不确定时采用的模型
- 机器翻译任务是代表性任务
 - 将一句中文翻译成英文，这句英文的长度有可能会比中文更短，也可能更长，那么，输出的长度就不确定了。
 - 输入的中文长度为4，输出的英文长度为2。



五、Transformer概述


Encoder-Decoder模型

通常来说，Seq2Seq任务最常见的是使用Encoder+Decoder的模式，先将一个序列编码成一个上下文矩阵，在使用Decoder来解码，我们这里仅把context vector作为编码器到解码器的输入。



五、Transformer概述

2017年google的机器翻译团队在NIPS上发表了**Attention is all you need**的文章，开创性地提出了在序列转录领域，完全抛弃 CNN和RNN，只依赖**Attention-注意力**结构的简单的网络架构，名为**Transformer**；论文实现的任务是机器翻译。




五、Transformer概述

从宏观的视角开始 首先将这个模型看成是一个黑箱操作。在机器翻译中，就是输入一种语言，输出另一种语言。




那么拆开这个黑箱，我们可以看到它是由编码组件、解码组件和它们之间的连接组成。



五、Transformer概述

编码组件部分由一堆编码器（encoder）构成（论文中是将6个编码器叠在一起）。解码组件部分也是由相同数量（与编码器对应）的解码器（decoder）组成的。



五、Transformer概述

Transformer 总结和后续发展

- Transformer 与 RNN 不同，可以比较好地并行训练。
- Transformer 本身是不能利用单词的顺序信息的，因此需要在输入中添加位置 Embedding，否则 Transformer 就是一个词袋模型了。
- Transformer 的重点是 Self-Attention 结构，其中用到的 Q, K, V 矩阵通过输出进行线性变换得到。
- Transformer 中 Multi-Head Attention 中有多个 Self-Attention，可以捕获单词之间多种维度上的相关系数 attention 分数。

大模型的应用与扩展

自动驾驶





场景理解






可行驶区域检测

超分辨率




大模型的应用与扩展

风格迁移（更加逼真）



大模型的应用与扩展



Face detection



Self-driving car




Image segmentation



Robot vision



Image restoration



Image De-raining

Machine Learning




Face recognition



Mobile object tracking

大模型的应用与扩展

基础模型是一类通过大量数据，尤其是没有标签的数据，训练出来的机器学习模型。它最大的特点在于其能被应用到许多不同的场合上。



大模型的应用与扩展

大语言模型(LLM)是一类能理解并且生成人类语言的人工智能模型。它们通常是一些拥有数亿参数的神经网络，并且是在大量的文本数据上训练出来的。


Large Language Models are becoming very large indeed



Small models (<= 100b parameters)




Large models (>100b parameters)




大模型的应用与扩展

Segment Anything Model (SAM) 是一种先进的图像分割模型，它基于Facebook AI在2020年发布的Foundation Model3，能够根据简单的输入提示（如点或框）准确地分割图像中的任何对象，并且无需额外训练就能适应新场景中未见过的对象和图像。它利用了传统的计算机视觉技术和深度学习算法，在一个涵盖1100万张图片 and 11亿个掩码的庞大数据集上进行了训练，展现出了卓越的零样本迁移的性能。



大模型的应用与扩展

CLIP (Contrastive Language-Image Pre-training) 是 OpenAI 提出的多模态深度学习模型，其独特之处在于它可以同时处理文本和图像特征，并能够深入理解文本与图像之间的关联，这使得 CLIP 能够在文本图像预训练、多模态理解以及零样本学习等多种视觉和文本的任务上表现出色。



Food101

guacamole (90.1%) Ranked 1 out of 101 labels



✓ a photo of **guacamole**, a type of food.

✗ a photo of **ceviche**, a type of food.

✗ a photo of **edamame**, a type of food.


✗ a photo of **tuna tartare**, a type of food.

✗ a photo of **hummus**, a type of food.

本章小结

- 简单介绍深度学习的背景知识
- 计算视觉的基本任务及代表性应用
- 卷积神经网络的基础知识
- 循环神经网络的概况
- Transformer的概况

人工智能与机器学习



人工智能无处不在

